信息论基础讲义

李爻
yaoli0508@hit.edu.cn
哈尔滨工业大学数学学院

2023 年 1 月 13 日

摘要

这是一份用于校订和改进的《信息论基础讲义》试行版。如您发现任何错误，请联系作者，我们将十分感谢您对我们完善讲义的帮助。本试行讲义适用于哈工大数学系信息与计算科学大三学生，旨在介绍信息论基本思想，奠定基础，学有所用。

目录

1 信息 **5**

2 信息的度量 **6**

2.1 熵（entropy） 6
2.2 熵的一些性质 7
2.3 联合熵（joint entropy）与条件熵（conditional entropy） . . 9
2.4 相对熵（relative entropy）与互信息（mutual information） . 11
2.5 联合熵、条件熵、相对熵和互信息的一些性质 13
2.6 习题 15

3 渐近均分性 **16**

3.1 回忆：随机变量的收敛与大数定律 16
3.2 渐近均分性定理 17
3.3 典型集（typical set） 17
3.4 高概率集 19
3.5 独立同分布随机序列的编码长度 21
3.6 习题 22

4 随机过程的熵率 **24**

4.1 简述：随机过程（random process） 24
4.2 马尔可夫过程（Markov process） 24
4.3 熵率（entropy rate） 27
4.4 马尔可夫过程的熵率 29
4.5 习题 29

5 变长无损压缩 **31**

5.1 信源编码（source code） 31
5.2 应用：UPC 条形码（Universal Product Code） 32
5.3 前缀码（prefix code） 33
5.4 应用：摩尔斯码（Morse code） 34
5.5 Kraft 不等式 35
5.6 前缀码期望长度的下界 38
5.7 香农码（Shannon coding）和最优码 40

5.8 赫夫曼码（Huffman coding） 43
5.9 赫夫曼码的最优性 45
5.10 其他无损压缩编码 48
5.11 习题 49

6 信道容量 52
6.1 通信系统与离散无记忆信道 52
6.2 信道容量 55
6.3 信道容量的例子 56
6.4 联合渐近均分性（joint AEP） 59
6.5 信道编码定理 63

7 微分熵与高斯信道 68
7.1 微分熵（differential entropy） 68
7.2 微分熵与离散熵的关系 69
7.3 联合微分熵与条件微分熵 70
7.4 相对熵与互信息 72
7.5 微分熵、相对熵及互信息的性质 73
7.6 连续随机变量的渐近均分性 75
7.7 高斯信道 76

8 有损压缩与率失真理论 79
8.1 压缩问题 81
8.2 率失真函数（rate distortion function） 81
8.3 率失真函数计算的例子 83

9 型方法（type） 86

10 上机实验 88
10.1 熵、相对熵、联合熵、互信息的 Python 实现 88
10.1.1 上机作业 88
10.2 决策树-特征选择 91
10.2.1 决策树简介 91
10.2.2 经验熵 92
10.2.3 经验条件熵 92

10.2.4 决策树中的经验条件熵 92
10.2.5 上机作业 94
10.3 决策树-训练与预测 97
10.3.1 决策树的构建 97
10.3.2 上机作业 99
10.4 JPEG 图片压缩 103

1 信息

这是介绍什么是信息的，很宏观的，又没什么实质内容的一章，我还没想好写什么。

2 信息的度量

2.1 熵（entropy）

熵 是香农（Claude Shannon）在 1984 年提出的，对**随机变量不确定度的一个度量**。

对于度量随机变量的不确定度，我们可能第一个想到的统计量是方差。假设 X 是一个随机变量，$Pr(X=0)=1/2$，$Pr(X=1)=1/2$。它的期望是 $E[X]=1/2$，方差是 $Var[X]=E[X-E[X]]^2=1/2\times(1/2)^2+1/2\times(1/2)^2=1/4$。而另一个随机变量 $Y=2X$，即 $Pr(Y=0)=1/2$，$Pr(Y=2)=1/2$。它的期望是 $E[Y]=1$，方差是 $Var[Y]=2^2E[X]=1$。而当我们仅仅从不确定度的角度去思考，当 X 确定以后，Y 也同时确定了，所以 X 和 Y 的不确定度应该是一样的，所以使用方差去度量随机变量的不确定度并不合适。因此，我们引入一个对不确定度更好的度量：熵。

$H(X) = -\sum_{i=1}^{n} p(x_i)\log p(x_i)$

定义 2.1. 一个离散随机变量 X 的 熵 $H(X)$ 定义为

$$H(X) = -\sum_{x\in\mathcal{X}} p(x)\log p(x) \tag{2.1}$$

n:表示随机变量可能的取值数 $i=1,2,\cdots,n$

x:表示随机变量

p(x):表示随机变量X的概率函数

其中，$\mathcal{X}$ 为 X 的取值空间，$p(x)=Pr(X=x)$，$x\in\mathcal{X}$ 是 X 的概率密度函数。并约定，当 $p(x)=0$ 时，$p(x)\log p(x)|_{p(x)=0}=\lim_{p(x)\to 0} p(x)\log p(x)=0$。一般情况下，默认 log 的底为 2，因为现代计算机中使用的是二进制，这种定义在使用时更为方便，此时熵的单位为比特（bit）。如果使用底为 b 的对数，则相应的熵记作 $H_b(X)$。当对数的底为 e 时，熵的单位用奈特（nat）。当讨论 X 的不同分布 p 和 q 时，$H(X)$ 也记做 $H(p)$ 和 $H(q)$ 以区分其分布。

关于熵定义的合理性，假设有一个随机变量 $Z=-\log p(X)$，那

$$H(X)=E[-\log p(X)]=E[Z] \tag{2.2}$$

这个定义是与热力学的熵有联系的（Boltzmann's H-theorem）（仅相差一个常数倍数）。另一个解释来源于信息理论，假如我们想定义一个 信息函数 $h(p(x))$ 来表示我们通过对随机事件 $X=x$ 的观测获得的信息量，那 $h(p(x))$ 需要遵循以下几个公理

- $h(p(x))$ 随 $p(x)$ 单调递减，因为如果一个事件发生的概率增大，那观测到这个数据带来的信息就会减少。（一个并不严谨的例子：就像收集盲盒，发生概率大的物品带来的惊喜（信息）很少。）

- $h(p(x)) \geq 0$，因为信息量不能是小于 0 的。
- $h(1) = 0$，一个事件总是发生，观测到他就没传递任何信息。
- $h(p(x_1)p(x_2)) = h(p(x_1)) + h(p(x_2))$，从独立事件中获得的信息等于各自信息的和。

满足公理的解为 $h(p(x)) = -k \log p(x)$，$k > 0$。香农选择了 $k = 1$。此时 $H(X) = \sum_{x \in \mathcal{X}} p(x)h(p(x))$ 是 X 信息量的期望。

由上述公理我们发现，熵是随机变量不确定度的度量，同时也是**平均意义上描述随机变量所需的信息量的度量**。举一个例子，假如随机变量 X 等于 $a, b, c, ..., h$ 的概率均为 1/8。X 的熵为

$$H(X) = (-\frac{1}{8} \log \frac{1}{8}) \times 8 = 3 \tag{2.3}$$

即，$H(X)$ 的熵是 3 比特，相当于一个 3 位数的 2 进制的信息。而这恰好是编码 X 所用的的信息长度，我们可以记二进制数 $000 := a$，$001 := b$，...，$111 := h$，对 X 进行编码。

回到我们最初的例子，$Pr(X = 0) = 1/2$，$Pr(X = 1) = 1/2$，$Y = 2X$，X 和 Y 的熵相等

$$\begin{aligned} H(X) &= -p(X=0)\log p(X=0) - p(X=1)\log p(X=1) \\ &= -\frac{1}{2}\log\frac{1}{2} - \frac{1}{2}\log\frac{1}{2} = 1 \end{aligned} \tag{2.4}$$

$$\begin{aligned} H(Y) &= -p(Y=0)\log p(Y=0) - p(Y=1)\log p(Y=1) \\ &= -\frac{1}{2}\log\frac{1}{2} - \frac{1}{2}\log\frac{1}{2} = 1 \end{aligned} \tag{2.5}$$

当然对于非均匀分布的随机变量，我们无法这样简单地构造一个 1 对 1 的编码，使其码长等于 $H(X)$，相关的编码理论将在下一章阐述。

2.2 熵的一些性质

定义 2.2. 若对于任意的 $x_1, x_2 \in (a, b)$ 及 $0 \leq \lambda \leq 1$，满足

$$\lambda f(x_1) + (1-\lambda) f(x_2) \geq f(\lambda x_1 + (1-\lambda) x_2) \tag{2.6}$$

则称函数 $f(x)$ 在区间 (a, b) 上是凸（*convex*）的。如果仅当 $\lambda = 0$ 或 $\lambda = 1$，上式成立，则称函数 f 是严格凸（*strictly convex*）的。

引理 2.3. *(琴生不等式（Jensen's inequality）)* 假设 f 是随机变量 X 的一个函数，且 f 是一个凸函数，有

$$E[f(X)] \geq f(E[X]) \tag{2.7}$$

进一步，如果 f 是严格凸的，那么当且仅当 X 是一个确定量，上述不等式取等。

证明. 我们只证明离散分布的情形，且对分布点的个数进行归纳证明。

对于两点分布，所需证明的不等式为

$$p_1 f(x_1) + p_2 f(x_2) \geq f(p_1 x_1 + p_2 x_2) \tag{2.8}$$

由凸函数的性质，上述等式成立。假设不等式在分布点个数为 $k-1$ 时成立，对于分布点个数为 k 时，

$$\begin{aligned}
\sum_{i=1}^{k} p_i f(x_i) &= p_k f(x_k) + \sum_{i=1}^{k-1} p_i f(x_i) \\
&= p_k f(x_k) + (1-p_k) \sum_{i=1}^{k-1} \frac{p_i}{1-p_k} f(x_i) \\
k-1\text{时成立} &\geq p_k f(x_k) + (1-p_k) f\left(\sum_{i=1}^{k-1} \frac{p_i}{1-p_k} x_i\right) \\
\text{凸函数性质} &\geq f\left(p_k x_k + (1-p_k) \sum_{i=1}^{k-1} \frac{p_i}{1-p_k} x_i\right) \\
&= f\left(\sum_{i=1}^{k} p_i x_i\right)
\end{aligned} \tag{2.9}$$

对于等号成立条件和连续分布情况此处不给出证明。 □

凹函数与凸函数在定义上仅不等式符号相反，即 $\lambda f(x_1) + (1-\lambda) f(x_2) \leq f(\lambda x_1 + (1-\lambda) x_2)$，对于凹函数的琴生不等式也只是不等式符号相反，即 $E[f(X)] \leq f(E[X])$。

定理 2.4. （最大熵分布）$H(X) \leq \log |\mathcal{X}|$，其中 $|\mathcal{X}|$ 表示 X 的取值空间中元素的个数，当且仅当 X 在 $\mathcal{X}$ 上服从均匀分布，等号成立。

证明.

$$
\begin{aligned}
H(X) &= E[\log \frac{1}{p(X)}] \\
\text{Jensen 不等式} &\leq \log E[\frac{1}{p(X)}] \\
&= \log \sum_{X \in \mathcal{X}} p(x) \frac{1}{p(x)} \\
&= \log |\mathcal{X}|
\end{aligned} \tag{2.10}
$$

由于对数函数是严格凹函数，Jensen 不等式取等条件为，当且仅当 $\frac{1}{p(X)}$ 是确定的，也就是 p(X) 恒为常值。已知 X 的取值空间中元素的个数为 $|\mathcal{X}|$，那么 $p(x) = \frac{1}{|\mathcal{X}|}$，$\forall x \in \mathcal{X}$。 □

定理 2.5. （熵的非负性）$H(X) \geq 0$，当且仅当 X 是确定的等号成立。

证明.

$$
H(X) = -\sum_{x \in \mathcal{X}} p(x) \log p(x) \tag{2.11}
$$

当 $0 < p(x) < 1$，有 $p(x) \log p(x) < 0$，则 $H(x) \geq 0$；当 $p(x) = 0$，由熵的定义有 $p(x) \log p(x) = 0$，则 $H(X) = 0$；当 $p(x) = 1$，有 $p(x) \log p(x) = 0$，则 $H(X) = 0$。取等条件只有当 $p(X) = 1$ 时满足，即 X 为确定的。 □

2.3 联合熵（joint entropy）与条件熵（conditional entropy）

我们将定义 2.1中的熵推广到两个随机变量的情形。

定义 2.6. 离散随机变量 (X, Y) 服从联合分布（*joint distribution*）$p(x, y)$，其联合熵 $H(X, Y)$ 定义为 $F(x,y) = P(\{X \leq x \cap Y \leq y\}) = P(X \leq x, Y \leq y)$

$$
H(X, Y) = -\sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(x, y) \tag{2.12}
$$

或记做

$$
H(X, Y) = E[-\log p(X, Y)] \tag{2.13}
$$

也可以定义一个随机变量在给定另一个随机变量下的条件熵，它是熵在条件下的期望。

定义 2.7. 若 $(X,Y)\sim p(x,y)$，条件熵 $H(Y|X)$ 定义为：

$$\begin{aligned}
H(Y|X) &= \sum_{x\in\mathcal{X}} p(x)H(Y|X=x) \\
&= -\sum_{x\in\mathcal{X}} p(x)\sum_{y\in\mathcal{Y}} p(y|x)\log p(y|x) \\
&= -\sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} p(x,y)\log p(y|x) \\
&= E[-\log p(Y|X)]
\end{aligned} \tag{2.14}$$

联合熵和条件熵定义的合理性可以在以下这个事实中得到体现，即一对随机变量的熵 $H(X,Y)$ 等于其中一个的熵 $H(X)$ 加上另一个随机变量的条件熵 $H(Y|X)$。

定理 2.8. （链式法则）

$$H(X,Y) = H(X) + H(Y|X) \tag{2.15}$$

证明.

$$\begin{aligned}
H(X,Y) &= -\sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} p(x,y)\log p(x,y) \\
&= -\sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} p(x,y)\log(p(x)p(y|x)) \\
&= -\sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} p(x,y)\log p(x) - \sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} p(x,y)\log p(y|x) \\
&= -\sum_{x\in\mathcal{X}} p(x)\log p(x) - \sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} p(x,y)\log p(y|x) \\
&= H(X) + H(Y|X)
\end{aligned} \tag{2.16}$$

或对等价形式两边同时取期望也可证明本定理

$$\log p(X,Y) = \log p(X) + \log p(Y|X) \tag{2.17}$$

□

从信息的角度上来理解，X 和 Y 的联合熵 $H(X,Y)$ 表示两个随机变量含有的信息总量。条件熵 $H(Y|X)$ 表示在已知 X 后，我们可能对 Y 有了进一步了解，此时 Y 还剩余的信息量为 $H(Y|X)$。此时链式法则就十分的合理，即 $H(X,Y) = H(Y|X) + H(X)$。

KL散度：是两个概率分布间差异的非对称性度量
通信流法：KL散度是用来衡量同一个随机变量的两个不同分布之间的距离

2.4 相对熵(relative entropy)与互信息(mutual information)

相对熵 是**两个随机分布之间距离的度量**，也可以理解为两个随机分布的不相同程度。

定义 2.9. 在取值空间 $\mathcal{X}$ 上的两个概率密度函数 $p(x)$ 和 $q(x)$ 之间的相对熵或 KL-散度 (*Kullback-Leibler divergence*) 定义为 $D_{KL}(p\|q) = \sum_{i=1}^{n} p(x_i)\log\left(\frac{p(x_i)}{q(x_i)}\right)$

$$D(p||q) = \sum_{x\in\mathcal{X}} p(x)\log\frac{p(x)}{q(x)} \tag{2.18}$$

$$= E_p \log\frac{p(X)}{q(X)} \tag{2.19}$$

并约定 $0\log\frac{0}{0} = 0$，$0\log\frac{0}{q} = 0$ 和 $p\log\frac{p}{0} = \infty$。

相对熵其实并不是两个分布之间的真正“距离”，因为只满足 $D(p||p) = 0$ 和 $D(p||q) \geq 0$，而不满足对称性和三角不等式。但将相对熵视作分布间的距离往往很有用，如相对熵 $D(p||q)$ 度量当真实分布为 p 而假定分布为 q 时的无效性，或**度量真实分布为 p 而假定分布为 q 时的信息差**。

例如在做统计分析或假设检验的时候，我们经常并不知道一个随机变量的真实分布，而对这个变量的分布做一个假设（有很多时候我们会草率地假设一个随机变量是高斯分布的）。相对熵则可以度量我们的分布假设有多么不合理，或者度量多种分布假设中哪一个更为合理。

以一个例子来说，假设随机变量 $X \in \mathcal{X} = \{a, b, c, d\}$，

1. 若真实分布为 $p(a) = p(b) = \frac{1}{2}$，而假设其分布为 $q(a) = q(b) = q(c) = q(d) = \frac{1}{4}$，有

$$D(p||q) = 2 * \frac{1}{2}\log\frac{\frac{1}{2}}{\frac{1}{4}} + 2 * 0 * \log\frac{0}{\frac{1}{4}} = 1 \text{ bit}$$

2. 若真实分布为 $p(a) = p(b) = \frac{1}{2}$，而假设其分布为 $q(a) = 1$，$q(b) = q(c) = \frac{1}{4}$，有

$$D(p||q) = \frac{1}{2}\log\frac{\frac{1}{2}}{\frac{1}{2}} + \frac{1}{2}\log\frac{\frac{1}{2}}{\frac{1}{4}} + 0 * \log\frac{0}{\frac{1}{4}} + 0 * \log\frac{0}{0} = \frac{1}{2} \text{ bit}$$

3. 若真实分布为 $p(a) = p(b) = p(c) = p(d) = \frac{1}{4}$，而假设其分布为 $q(a) = q(b) = \frac{1}{2}$，有

$$D(p||q) = 2 * \frac{1}{4}\log\frac{\frac{1}{4}}{\frac{1}{2}} + 2 * \frac{1}{4}\log\frac{\frac{1}{4}}{0} = \infty$$

KL散度的特性：
① 非对称性
$D_{KL}(p\|q) \neq D_{KL}(q\|p)$
p和q的概率分布完全一样才相等
② 非负性(吉布斯不等式推导)
$D_{KL}(p\|q)$ 恒大于等于0
p和q的概率分布完全一样才等于0

$$D_{KL}(p\|q) = \sum_{i=1}^{n} p(x_i)\log\left(\frac{p(x_i)}{q(x_i)}\right)$$
$$= \sum_{i=1}^{n} p(x_i)\log p(x_i) - \sum_{i=1}^{n} p(x_i)\log q(x_i)$$
$$= -\left(-\sum_{i=1}^{n} p(x_i)\log p(x_i)\right) - \sum_{i=1}^{n} p(x_i)\log q(x_i)$$
$$= H(p,Q) - H(p) = \text{交叉熵} - \text{信息熵}$$

交叉熵公式

$$H(p,Q) = -\sum_{i=1}^{n} p(x_i)\log q(x_i)$$
$$H(p,Q) = \sum_{x} p(x)\cdot\log\left(\frac{1}{q(x)}\right)$$

结论 1：预测越准确，交叉熵越小

2：交叉熵只跟真实标签的预测概率值有关

对比上述例子的 1 和 2 可以发现，当假设分布更接近真实分布时，相对熵越小；对比例子的 1 和 3 可发现，$D(p||q) \neq D(q||p)$，即相对熵不满足距离函数的对称性公理。

互信息 是**一个随机变量包含另一个随机变量信息量的度量**。也可理解为，已知一个随机变量，它其中包含了另一随机变量的多少信息。

定义 2.10. 随机变量 X 和 Y 的联合概率密度函数为 $p(x,y)$，其边际概率密度函数分别是 $p(x)$ 和 $p(y)$。互信息 $I(X;Y)$ 为联合分布 $p(x,y)$ 和边际分布乘积 $p(x)p(y)$ 之间的相对熵，即

$$I(X;Y) = D(p(x,y)||p(x)p(y)) \tag{2.20}$$

我们注意到如果 X 与 Y 相互独立，有 $p(x,y) = p(x)p(y)$，那么 $I(X;Y) = 0$。互信息的这个定义可理解为，如果我们假设 X 与 Y 相互独立，并衡量真实概率密度函数 $p(x,y)$ 与假设概率密度函数 $p(x)p(y)$ 之间的距离或信息量差。

定理 2.11.

$$I(X;Y) = H(Y) - H(Y|X) \tag{2.21}$$
$$= H(X) + H(Y) - H(X,Y) \tag{2.22}$$

证明.

$$\begin{aligned}
I(X;Y) &= D(p(x,y)||p(x)p(y)) \\
&= E_{p(x,y)}\log\frac{p(X,Y)}{p(X)p(Y)} \\
&= E_{p(x,y)}\log\frac{p(Y|X)}{p(Y)} \\
&= E_{p(x,y)}\log p(Y|X) - E_{p(x,y)}\log p(Y) \\
&= H(Y) - H(Y|X)
\end{aligned} \tag{2.23}$$

由定理 2.8，

$$I(X;Y) = H(X) - H(X|Y) = H(X) + H(Y) - H(X,Y) \tag{2.24}$$

□

由此，互信息 $I(X;Y)$ 是在**给定 X 的条件下 Y 的不确定度的缩减量**。也可理解为，知道了 X 会对 Y 的不确定度减少多少。由公式 (2.22) 我们也可以注意到互信息是对称的，即 $I(X;Y)=I(Y;X)$。联合熵、条件熵和互信息间的关系可由图（2.1）表示

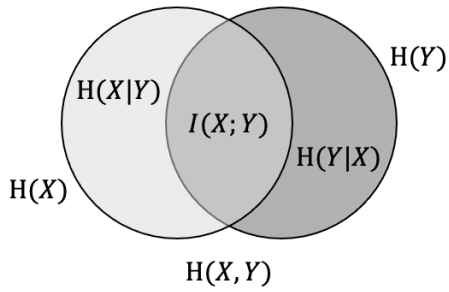

图 2.1: 联合熵、条件熵与互信息间的关系：随机变量 X 与 Y 的联合分布所含有的信息（信息量为 $H(X,Y)$）是 X 所含信息（信息量为 $H(X)$）与 Y 所含信息（信息量为 $H(Y)$）的并集；X 与 Y 所含信息的交集的信息量为其互信息 $I(X;Y)$；X 中含有的不能通过 Y 获得的信息的信息量为 $H(X|Y)$。

2.5 联合熵、条件熵、相对熵和互信息的一些性质

定理 2.12. *(信息不等式)* 设 $p(x)$ 和 $q(x)$ 是两个概率密度函数，$x\in\mathcal{X}$，则

$$D(p||q)\geq 0 \tag{2.25}$$

当且仅当 $\forall x\in\mathcal{X}$，$p(x)=q(x)$，等号成立。

证明. 设 $A=\{x:p(x)>0\}$ 为 $p(x)$ 的支撑集，则

$$
\begin{aligned}
-D(p||q) &= -\sum_{x\in A} p(x)\log\frac{p(x)}{q(x)} \\
&= \sum_{x\in A} p(x)\log\frac{q(x)}{p(x)} \\
\text{Jensen 不等式} &\le \log\sum_{x\in A} p(x)\frac{q(x)}{p(x)} \\
&= \log\sum_{x\in A} q(x) \\
&\le \log\sum_{x\in \mathcal{X}} q(x) = \log 1 = 0
\end{aligned} \tag{2.26}
$$

由于 $\log x$ 是关于 x 的严格凸函数，式 2.26 使用了琴生不等式，当且仅当 $q(x)/p(x)$ 恒为常数时，等号成立，即 $q(x)/p(x) = c$。对取值空间中所有 x 求和有

$$
\sum_{x\in A} q(x) = c\sum_{x\in A} p(x) = c = 1 \tag{2.27}
$$

因此，当且仅当对任意 x，有 $p(x) = q(x)$，琴生不等式取等。而此时，式 2.26中第二个不等式也恰好取等。即证，当且仅当 $\forall x \in \mathcal{X}$，$p(x) = q(x)$ 时，$D(p||q) = 0$。

注：此证明中使用 $A = \{x : p(x) > 0\}$ 是为了避免使用 Jensen 不等式时 $\log p(x)$ 定义为 0。 □

利用信息不等式，我们也可以证明定理 2.4。

证明. 设 $p(x)$ 是随机变量 X 的概率密度函数，但假设随机变量在 $\mathcal{X}$ 上均匀分布，即 $u(x) = \frac{1}{|\mathcal{X}|}$，有

$$
D(p||u) = \sum p(x)\log\frac{p(x)}{u(x)} = \log|\mathcal{X}| - H(X) \ge 0 \tag{2.28}
$$

当且仅当 $\forall x$，$p(x) = u(x)$ 不等式取等。 □

推论 2.13. *(互信息非负)* 对任意两个随机变量 X 和 Y，

$$
I(X;Y) \ge 0 \tag{2.29}
$$

当且仅当 X 和 Y 互相独立，等号成立。

证明.

$$I(X;Y) = D(p(x,y)||p(x)p(y)) \geq 0 \tag{2.30}$$

当且仅当 $p(x,y) = p(x)p(y)$ 等号成立。 □

2.6 习题

1. (熵的链式法则) 证明:

   设随机变量 $X_1, X_2, \ldots, X_n$ 服从 $p(x_1, x_2, \ldots, x_n)$, 则

$$H(X_1, X_2, \ldots, X_n) = \sum_{i=1}^{n} H(X_i|X_{i-1}, \ldots, X_1)$$

2. (相对熵的链式法则) 证明:

$$D(p(x,y)||q(x,y)) = D(p(x)||q(x)) + D(p(y|x)||q(y|x))$$

3. (互信息的链式法则) 随机变量 X 和 Y 在给出随机变量 Z 时的 <u>条件互信息</u> 定义为

$$I(X;Y|Z) = H(X|Z) - H(X|Y,Z) = E_{(x,y,z)} \log \frac{p(X,Y|Z)}{p(X|Z)p(Y|Z)}$$

   证明:

$$I(X_1, X_2, \ldots, X_n; Y) = \sum_{i=1}^{n} I(X_i; Y|X_{i-1}, X_{i-2}, \ldots, X_1)$$

4. (条件作用使熵减小) 证明:

   $H(X|Y) \leq H(X)$, 当且仅当 X 与 Y 独立, 等号成立。

5. (熵的独立界) 证明:

   设 $X_1, X_2, \ldots, X_n$ 服从 $p(x_1, x_2, \ldots, x_n)$, 则

$$H(X_1, X_2, \ldots, X_n) \leq \sum_{i=1}^{n} H(X_i)$$

3 渐近均分性

3.1 回忆：随机变量的收敛与大数定律

定义 3.1. （随机变量的收敛）给定一个随机变量序列 $X_1, X_2, \ldots$，它收敛于随机变量 X 的定义有很多种。其中最常用两种：

1. 如果对任意的 $\epsilon > 0$，$Pr\{|X_n - X| > \epsilon\} \to 0$，则称为依概率收敛（*in probability*），记为 $X_n \xrightarrow{P} X$。
2. 如果 $Pr\{\lim_{n\to\infty} X_n = X\} = 1$，则称为以概率 *1* 收敛（*with probability 1*）或几乎处处收敛（*almost surely, a.s.*），记为 $X_n \xrightarrow{a.s.} X$。

依概率收敛可以理解为，随着序列逐渐进行，异常的结果出现的概率越来越小。以 1 概率收敛可以理解为，随着序列逐渐进行，X_n 一定会变成 X。以 1 概率收敛比依概率收敛更强，如果以 1 概率收敛，则必然依概率收敛。

依概率收敛的例子：假如我们在 0 到 1 之间随机生成一个实数 X，X_n 是 $[X - \frac{1}{n}, X + \frac{1}{n}]$ 区间内均匀分布的一个随机实数，那么 X_n 依概率收敛于 X。

以 1 概率收敛的例子：假如我们以同样的概率随机生成一个 0 或 1 的数，一旦生成 0 以后就一直固定生成 0。X_n 为第 n 次生成的数，X 是 0，那么 X_n 以 1 概率收敛于 X。（我们几乎确定，从某次开始 0 就会出现，且一直持续下去）。

定理 3.2. （大数定律，*law of large numbers*）$X_1, X_2, \ldots$ 是 *i.i.d.* 随机变量，$E[X_1] = E[X_2] = \ldots = \mu$，$\bar{X}_n = \frac{1}{n}(X_1 + \ldots + X_n)$，有 独立同分布

（强大数定律，以 *1* 概率收敛）

$$\bar{X}_n \xrightarrow{a.s.} \mu \tag{3.1}$$

（弱大数定律，依概率收敛）

$$\bar{X}_n \xrightarrow{P} \mu \tag{3.2}$$

在信息论中，有一个和大数定律类似的概念，叫渐近均分性（asymptotic equipartition property, AEP），大概是说，我们对一个随机变量采集很多不同的样本集，当样本集的大小趋于无穷时，这些样本集都大概率可以很好的反应这个随机变量的真实分布，得到这些样本集的概率也几乎相同。

3.2 渐近均分性定理

定理 3.3. *(渐近均分性，AEP)* 随机变量 $X \sim p(x)$，若 $X_1, X_2, \ldots, X_n$ 为 *i.i.d.* $\sim p(x)$，则

$$-\frac{1}{n}\log p(X_1, X_2, \ldots, X_n) \xrightarrow{P} H(X) \tag{3.3}$$

证明. 由于 X_i 是 i.i.d.，从而 $\log p(X_i)$ 也是 i.i.d.。由弱大数定律，

$$\begin{aligned} -\frac{1}{n}\log p(X_1, X_2, \ldots, X_n) &= -\frac{1}{n}\sum_i \log p(X_i) \\ &\xrightarrow{P} -E[\log p(X)] \\ &= H(X) \end{aligned} \tag{3.4}$$

□

渐近均分性定理有些抽象，举一个例子，设随机变量 $X \in \{0, 1\}$ 的概率密度函数为 $p(1) = p$ 和 $p(0) = 1 - p$。若 $X_1, X_2, \ldots, X_n$ 为 i.i.d. 且服从 $p(x)$，则序列 $x_1, x_2, \ldots, x_n$ 出现的概率为 $p^{\sum x_i}(1-p)^{n-\sum x_i}$。很显然，并不是所有的序列都有同样的概率。我们考虑这个随机观测序列 $X_1, X_2, \ldots, X_n$，它出现的概率则为 $p^{\sum X_i}(1-p)^{n-\sum X_i}$。在 $n \to \infty$ 时，$\sum X_i \xrightarrow{P} np$。那么 $p(X_1, X_2, \ldots, X_n) \xrightarrow{P} p^{np}(1-p)^{n-np} = 2^{-nH(X)}$。此时，所有 $X_1, X_2, \ldots, X_n$ 发生的概率都趋于相等了。虽然渐近均分性定理并不容易直观感受到，但从典型集去理解会容易得多。

3.3 典型集（typical set）

定义 3.4. 对随机变量 X 的 n 次 *i.i.d.* 观测序列 $(x_1, x_2, \ldots, x_n) \in \mathcal{X}^n$ 是<u>ϵ-典型</u> 的，如果存在 $\epsilon > 0$ 满足

$$\left| -\frac{1}{n}\log p(x_1, x_2, \ldots, x_n) - H(X) \right| \le \epsilon \tag{3.5}$$

由所有 ϵ-典型观测序列组成的集合是<u>典型集</u>，记做 $A_\epsilon^{(n)}$。

公式 *3.5* 的一个等价形式为

$$2^{-n(H(X)+\epsilon)} \le p(x_1, x_2, \ldots, x_n) \le 2^{-n(H(X)-\epsilon)} \tag{3.6}$$

典型集可以理解为，对随机变量 X 的一个 i.i.d. 样本集，如果取到这个样本集的概率很符合这个随机变量 X 的分布，那么这样的样本集是典型

的，属于典型集。例如，如果有一个不均匀的硬币，正面向上的概率是背面向上的两倍，那么“正正正正正正”这样的序列并不属于典型集，而“正正正正反反”这样的序列属于典型集，因为这样的序列发生的概率更符合随机变量的分布。这个解释可能并不是完全严密的，但可以用来理解典型集。

定理 3.5. （典型集覆盖几乎所有概率）$\forall \epsilon > 0$，当 $n \to \infty$ 有

$$Pr\{A_\epsilon^{(n)}\} \equiv Pr\{(X_1, X_2, \ldots, X_n) \in A_\epsilon^{(n)}\} \to 1 \tag{3.7}$$

证明. 由定理 3.3 可知，当 $n \to \infty$ 时，$\forall \epsilon > 0$，事件 $(X_1, X_2, \ldots, X_n) \in A_\epsilon^{(n)}$ 的概率趋于 1。也就是 $\forall \delta > 0$，存在 n_0，对于所有 $n \geq n_0$，有

$$Pr\{|-\frac{1}{n}\log p(X_1, X_2, \ldots, X_n) - H(X)| < \epsilon\} > 1 - \delta \tag{3.8}$$

□

定理 3.5 可以有两重理解，1. **当样本集足够大，它很有可能属于典型集，即它很有可能可以反映随机变量的分布，**这与大数定律和我们的直觉都是很吻合的；2. **当 $n \to \infty$ 时，典型集几乎覆盖了所有的概率，即在整个取值空间中非典型集所占的概率几乎为 0。**

定理 3.6. （典型集大小的界）$\forall \epsilon > 0$，当 n 充分大时，典型集 $A_\epsilon^{(n)}$ 中元素的个数 $|A_\epsilon^{(n)}|$ 有

$$(1-\epsilon)2^{n(H(X)-\epsilon)} \leq |A_\epsilon^{(n)}| \leq 2^{n(H(X)+\epsilon)} \tag{3.9}$$

证明. 上界：

$$\begin{aligned}
1 &= \sum_{(x_1, x_2, \ldots, x_n) \in \mathcal{X}^n} p(x_1, x_2, \ldots, x_n) \\
&\geq \sum_{(x_1, x_2, \ldots, x_n) \in A_\epsilon^{(n)}} p(x_1, x_2, \ldots, x_n) \\
&\geq \sum_{(x_1, x_2, \ldots, x_n) \in A_\epsilon^{(n)}} 2^{-n(H(X)+\epsilon)} \\
&= 2^{-n(H(X)+\epsilon)} |A_\epsilon^{(n)}|
\end{aligned} \tag{3.10}$$

下界：当 n 充分大时，$Pr\{A_\epsilon^{(n)}\} > 1-\epsilon$，所以

$$\begin{aligned}
1-\epsilon &< Pr\{A_\epsilon^{(n)}\} \\
&= \sum_{(x_1,x_2,\ldots,x_n)\in A_\epsilon^{(n)}} p(x_1,x_2,\ldots,x_n) \\
&\le \sum_{(x_1,x_2,\ldots,x_n)\in A_\epsilon^{(n)}} 2^{-n(H(X)-\epsilon)} \\
&= 2^{-n(H(X)-\epsilon)}|A_\epsilon^{(n)}|
\end{aligned} \tag{3.11}$$

□

定理 3.6 给出了典型集元素个数的上下界，我们可以将随机变量 X 的 i.i.d. 序列 $X_1, X_2, \ldots, X_n$ 的取值空间 $\mathcal{X}^n$ 划分为两个集合：典型集 $A_\epsilon^{(n)}$ 和它的补集（图 3.1，左）。取值空间 $\mathcal{X}^n$ 的大小为 $|\mathcal{X}|^n$，而典型集只是取值空间的一个很小很小的子集，大小约为 $2^{nH(X)}$。两者大小的比值

$$\frac{|A_\epsilon^{(n)}|}{|\mathcal{X}^n|} \approx \frac{2^{nH(X)}}{|\mathcal{X}|^n} = \frac{2^{nH(X)}}{2^{n\log|\mathcal{X}|}} = 2^{-n(\log|\mathcal{X}|-H(X))} \tag{3.12}$$

除非 X 是均匀分布的，$A_\epsilon^{(n)}$ 以指数的比值小于 $\mathcal{X}^n$。

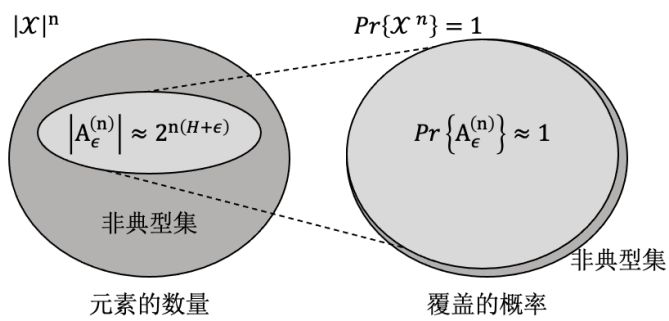

图 3.1: 典型集

3.4 高概率集

由典型集的定义，不难发现 $A_\epsilon^{(n)}$ 中的元素并不是那些发生概率最高的观测序列（或样本集），而是那些有最多同样发生概率的观测序列。回到不均匀硬币的例子，如果有一个不均匀的硬币，正面向上的概率是背面向上的

两倍，那么“正正正正正正”是发生概率最高的序列，它并不属于典型集；而“正正正正反反”、“正正反反正正”、“正正反正正反”等等这样的序列有相同的发生概率，且有最多的序列是同样的发生概率的，他们属于典型集。此时，取值空间 $\mathcal{X}^n$ 中含有 $2^6 = 64$ 个元素，而典型集中含有 $C_6^2 = 15$ 个元素。但 $A_\epsilon^{(n)}$ 覆盖了 $C_6^2(\frac{2}{3})^4(\frac{1}{3})^2 \approx 32.9\%$ 的取值概率。而且，由定理 3.5 可知，当 n 充分大时，$A_\epsilon^{(n)}$ 将几乎覆盖所有的取值概率（图 3.1，右）。这是典型集的一个很好的性质，**含有很少的元素，但覆盖了几乎全部的取值概率**。

我们把这种包含了几乎所有取值概率的集合叫做高概率集，那 $A_\epsilon^{(n)}$ 是否是最小的高概率集呢？最小的高概率集是多大呢？

定理 3.7. （最小高概率集）对于一个固定的 $\delta > 0$ 和 $\mathcal{X}^n$ 的一个子集 $B^{(n)}$，当 $|B^{(n)}| \leq 2^{n(H(X)-\delta)}$ 时，

$$Pr\{B^{(n)}\} \xrightarrow{n\to\infty} 0 \tag{3.13}$$

证明.

$$\begin{aligned}
Pr\{B^{(n)}\} &= Pr\{B^{(n)} \cap A_\epsilon^{(n)}\} + Pr\{B^{(n)} \cap (A_\epsilon^{(n)})^C\} \\
&\leq Pr\{B^{(n)} \cap A_\epsilon^{(n)}\} + Pr\{(A_\epsilon^{(n)})^C\} \\
&= \sum_{(x_1,x_2,\ldots,x_n)\in B^{(n)}\cap A_\epsilon^{(n)}} p(x_1,x_2,\ldots,x_n) + Pr\{(A_\epsilon^{(n)})^C\} \\
&\leq \sum_{(x_1,x_2,\ldots,x_n)\in B^{(n)}\cap A_\epsilon^{(n)}} 2^{-n(H(X)-\epsilon)} + Pr\{(A_\epsilon^{(n)})^C\} \\
&= |B^{(n)} \cap A_\epsilon^{(n)}| \cdot 2^{-n(H(X)-\epsilon)} + Pr\{(A_\epsilon^{(n)})^C\} \\
&\leq |B^{(n)}| \cdot 2^{-n(H(X)-\epsilon)} + Pr\{(A_\epsilon^{(n)})^C\} \\
&\leq 2^{n(H(X)-\delta)} \cdot 2^{-n(H(X)-\epsilon)} + Pr\{(A_\epsilon^{(n)})^C\} \\
&= 2^{-n(\delta-\epsilon)} + Pr\{(A_\epsilon^{(n)})^C\} \\
&\xrightarrow{n\to\infty} 0
\end{aligned} \tag{3.14}$$

□

定理 3.7 表示，$\mathcal{X}^n$ 的任意一个元素个数小于 $2^{nH(X)}$ 的子集，都无法包含全部的有最多同样发生概率的观测序列。当 n 足够大时，无法包含的部分将覆盖几乎全部的概率。也就是说，高概率集至少要有 $2^{nH(X)}$ 个元素，而典型集中有 $2^{n(H(X)+\epsilon)}$ 个元素，大小差不多是相同的。

3.5 独立同分布随机序列的编码长度

渐近均分性表明，$A_\epsilon^{(n)}$ 中含有很少的元素，但覆盖了大多数的取值概率。当需要对 i.i.d. 随机变量序列 $X_1, X_2, \ldots, X_n$ 进行编码，且 n 充分大时，如果只对 $A_\epsilon^{(n)}$ 进行编码，那么编码只有极小的概率是错误的，且只用很短的码就可以。

定理 3.8. （*i.i.d. 序列编码正定理*）设 $X^n \equiv (X_1, X_2, \ldots, X_n)$ 是服从 $p(x)$ 的 *i.i.d.* 序列，$\forall R > H(X)$ 和 $\forall \delta > 0$，都存在一个足够大的 N 使得对 X^N 进行 *1-1* 编码时，平均码长 $r < R$ 并且错误率 $Pr\{\hat{X}^N \neq X^N\} < \delta$，其中 $\hat{X}^N$ 为 X^N 编码后的解码。

证明. 选择 $\epsilon > 0$ 使得 $H(X) + \epsilon < R$，然后给 $A_\epsilon^{(N)}$ 中的序列集合标号，将 $x^N \in A_\epsilon^{(N)}$ 的标号记为 $I(x^N)$。然后对 $A_\epsilon^{(N)}$ 中的序列集合采取如下的编码

1. 如果 $x^N \in A_\epsilon^{(N)}$，输出一个对应 $I(x^N)$ 的 m-比特的编码
2. 如果 $x^N \notin A_\epsilon^{(N)}$，输出任意一个编码

解码时，简单地根据编码找到输入的 $I(x^N)$ 再找到对应的 x^N。可以发现，当 $x^N \notin A_\epsilon^{(N)}$ 时，解码就会产生错误。这种编码方式需要 $m = \log |A_\epsilon^{(N)}|$ 比特来编码 $A_\epsilon^{(N)}$ 中的所有序列。此时就会得到如下的平均码长和错误率

$$r = \frac{m}{N} = \frac{\log |A_\epsilon^{(N)}|}{N} \leq \frac{N(H(X) + \epsilon)}{N} = H(X) + \epsilon < R \tag{3.15}$$

$$Pr\{\hat{X}^N \neq X^N\} = Pr\{X^N \notin A_\epsilon^{(N)}\} < \delta \text{ 当 N 足够大} \tag{3.16}$$

□

定理 3.8 简单来说就是，**当 N 足够大时，编码 $(X_1, X_2, \ldots, X_N)$ 只需要长度为 $NH(X)$ 的码就可以做到几乎不会错，因为我们只对典型集中的序列进行编码，而典型集发生的概率趋于 1**。

定理 3.9. （*i.i.d. 序列编码逆定理*）如果 $R < H(X)$，那么如果使用平均码长 $r \leq R$ 去编码，那么当 $n \to \infty$ 时，错误率 $Pr\{\hat{X}^n \neq X^n\} \to 1$。

证明. 对于序列 X^N，平均长度为 r 的码最多可以没有错误地表示 2^{Nr} 个不同的序列。我们将这些序列的集合记为 $B^{(N)}$。

$$Pr\{\hat{X}^N \neq X^N\} = Pr\{X^N \notin B^{(N)}\} = 1 - Pr\{X^N \in B^{(N)}\} \tag{3.17}$$

因为 $r \leq R < H(X)$，那么存在一个 $\delta > 0$，使得 $r + \delta < H(X)$。因此 $|B^{(N)}| \leq 2^{N(H(X)-\delta)}$，由定理 3.7，

$$Pr\{X^N \in B^{(N)}\} \xrightarrow{N\to\infty} 0 \tag{3.18}$$

□

定理 3.9 简单来说就是，编码 $(X_1, X_2, \ldots, X_N)$ 时，如果使用长度小于 $NH(X)$ 的码，那么当 N 足够大时，错误率将趋于 1，因为根据最小高概率集，编码错误的部分将覆盖几乎全部概率。

由定理 3.8 和定理 3.9 可以得出，在编码长度为 n 的 i.i.d. 随机序列时，当 n 足够大，最短只需要长度为 $nH(X)$ 码，平均每个随机变量的平均码长为 $H(X)$，这也佐证了在上一章时提到的熵是平均意义下随机变量的编码长度。

3.6 习题

1. （乘积）随机变量 X，$Pr\{X = 1\} = \frac{1}{2}$，$Pr\{X = 2\} = \frac{1}{4}$，$Pr\{X = 3\} = \frac{1}{4}$。设 $X_1, X_2, \ldots$ 是与 X 分布相同的 i.i.d. 序列，请找出如下乘积的极限

$$(X_1 X_2 \ldots X_n)^{\frac{1}{n}}$$

2. （AEP）设 X_i 为 i.i.d.$\sim p(x)$，$\mu = E[X]$，$H = -\sum p(x) \log p(x)$。设

$$A^n = \{x^n \in \mathcal{X}^n : |-\frac{1}{n}\log p(x^n) - H| \leq \epsilon\}$$
$$B^n = \{x^n \in \mathcal{X}^n : |\frac{1}{n}\sum_{i=1}^{n} X_i - \mu| \leq \epsilon\}$$

求

(a) $\lim_{n\to\infty} Pr\{X^n \in A^n\}$

(b) $\lim_{n\to\infty} Pr\{X^n \in A^n \cap B^n\}$

(c) 证明：对任意的 n，$|A^n \cap B^n| \leq 2^{(n(H+\epsilon))}$

(d) 证明：当 n 充分大时，$|A^n \cap B^n| \geq (\frac{1}{2})2^{n(H-\epsilon)}$

(e) $A^n \subseteq B^n$ 吗?

(f) $B^n \subseteq A^n$ 吗?

3. (i.i.d. 序列错误分布假设的有效性指数衰减) 设 X_i 为 i.i.d.$\sim$ $p(x)$, $x \in \{1, 2, \ldots, m\}$, 于是, 有 $p(x_1, x_2, \ldots, x_n) = \prod_{i=1}^{n} p(x_i)$, 且 $-\frac{1}{n} \log p(X_1, X_2, \ldots, X_n) \to H(X)$。设 $q(x_1, x_2, \ldots, x_n) = \prod_{i=1}^{n} q(x_i)$ 是 $x \in \{1, 2, \ldots, m\}$ 上的另一个概率密度函数。

   (a) 证明
$$-\frac{1}{n} \log q(X_1, \ldots, X_n) \to D(p||q) + H(p) \tag{3.19}$$

   (b) 证明
$$-\frac{1}{n} \log \frac{q(X_1, \ldots, X_n)}{p(X_1, \ldots, X_n)} \to D(p||q) \tag{3.20}$$

4. (马尔可夫不等式, Markov's inequality) 对任意非负随机变量 X 以及任意的 $t > 0$, 证明
$$Pr\{X \geq t\} \leq \frac{E[X]}{t}$$

5. (切比雪夫不等式, Chebyshev's inequality) 设随机变量 Y 的均值与方差分别为 μ 和 σ^2。设 $X = (Y - \mu)^2$, 证明对任意的 $\epsilon > 0$,
$$Pr\{|Y - \mu| > \epsilon\} \leq \frac{\sigma^2}{\epsilon^2}$$

4 随机过程的熵率

在上一章中，渐近均分性表明，在平均意义下使用 $nH(X)$ 比特足以描述 n 个独立同分布的随机变量。但是，如果随机变量不独立，尤其是随机变量为平稳过程时，情况又如何呢?

4.1 简述：随机过程（random process）

随机过程$\{X_t\}$，$t \in \mathbb{T}$ 是一个随机变量序列，序列中的所有随机变量都在相同的概率空间 $(\Omega, \mathcal{F}, P)$ 中。在很多应用中，这个序列下标是一个关于时间的集合。如果下标 t 是整数集 $\mathbb{Z}$（或一个包含连续整数的集合），那么 $\{X_t\}$ 被称为离散时间随机过程（discrete-time random process）；如果下标是实数集 $\mathbb{R}$（或一个实数集的区间），那么那么 $\{X_t\}$ 被称为连续时间随机过程（continuous-time random process）。随机变量可以从一下三种角度去解释：

1. 对于一个固定的下标 t，X_t 是样本空间 Ω 上的一个函数。
2. $\{X_t\}$ 是在 $\mathbb{T} \times \Omega$ 的一个函数，对于给定的 $t \in \mathbb{T}$，$\omega \in \Omega$ 取值为 $X_t(w)$。
3. 对于每一个取定的 $\omega \in \Omega$，$X_t(\omega)$ 是 t 的函数，叫做关于 ω 的样本路径（sample path）。

对于一个离散时间随机过程，本文中为了记述简便，将下标 t 换为 i。如果 X_i 对于每个 i 都是离散随机变量，那么 $\{X_i\}$ 的概率质量函数（pmf）定义为

$$Pr\{(X_1, X_2, \ldots, X_n) = (x_1, x_2, \ldots, x_n)\} = p(x_1, x_2, \ldots, x_n) \tag{4.1}$$

定义 4.1. *如果随机变量序列的任何有限子集的联合分布关于时间下标的位移不变，即对于每个 n 和位移 l，以及任意的 $x_1, x_2, \ldots, x_n \in \mathcal{X}$，均满足*

$$\begin{aligned} &Pr\{X_1 = x_1, X_2 = x_2, \ldots, X_n = x_n\} \\ =&Pr\{X_{1+l} = x_1, X_{2+l} = x_2, \ldots, X_{n+l} = x_n\} \end{aligned} \tag{4.2}$$

则称该随机过程是平稳（stationary）的。

4.2 马尔可夫过程（Markov process）

如果一个随机序列中每个随机变量仅和它前一个随机变量相关，而条件独立于其他前面的所有随机变量，这样的过程称为马尔可夫过程。比如，

一个人当前所在地 X_i 只取决于他/她上一秒的所在地 X_{i-1} 和在这一秒钟的位移 $Pr\{X_i|X_{i-1}\}$，当这两个信息已知，我们并不需要知道再之前的位置 $X_{i-2},\ldots$ 就可以确定 X_i，这就是个马尔可夫过程。

定义 4.2. 如果对 $n=1,2,\ldots$，及所有的 $x_1,x_2,\ldots,x_n\in\mathcal{X}$，有

$$\begin{aligned}&Pr\{X_{n+1}=x_{n+1}|X_n=x_n,X_{n-1}=x_{n-1},\ldots,X_1=x_1\}\\=&Pr\{X_{n+1}=x_{n+1}|X_n=x_n\}\end{aligned}\tag{4.3}$$

则称离散随机过程 $X_1,X_2,\ldots$ 为马尔可夫链 或马尔可夫过程。此时，联合概率概率密度函数可以写成

$$p(x_1,x_2,\ldots,x_n)=p(x_1)p(x_2|x_1)p(x_3|x_2)\ldots p(x_n|x_{n-1})\tag{4.4}$$

一般我们会假设 $Pr\{X_{n+1}|X_n\}$，$\forall n\geq 1$ 是不变的。对应我们刚才的例子，也就是这个人无论当前在哪里，向各个方向走的概率都是不随时间改变的。

定义 4.3. 如果条件概率 $p(x_{n+1}|x_n)$ 不依赖于 n，即对 $n=1,2,\ldots$，对于任意 $a,b\in\mathcal{X}$ 有

$$Pr\{X_{n+1}=b|X_n=a\}=Pr\{X_2=b|X_1=a\}\tag{4.5}$$

则称马尔可夫链是时间不变的（*time invariant*）。

若无特别声明，总假设马尔可夫链是时间不变的。

如果 $\{X_i\}$ 是马尔可夫链，则称 X_n 为 n 时刻的状态。一个时间不变的马尔可夫链完全由其初始状态和概率转移矩阵$P=[P_{ab}]$ 所表征，其中 $P_{ab}=Pr\{X_{n+1}=a|X_n=b\}$，$a,b\in\mathcal{X}$。如果将 X_n 的概率密度函数写成一个向量 $\pi(X_n)=[Pr(X_n=a),Pr(X_n=b),\ldots]$，$\forall a,b,\ldots\in\mathcal{X}$，那么

$$\pi(X_{n+1})=\pi(X_n)\cdot P\tag{4.6}$$

也就得到了 $n+1$ 时刻的状态 X_{n+1}。

例如，$\{X_i\}$ 是马尔可夫链，$Pr\{X_1=0\}=p$，$Pr\{X_1=1\}=1-p$，$Pr\{X_{n+1}=0|X_n=0\}=1-\alpha$，$Pr\{X_{n+1}=1|X_n=0\}=\alpha$，$Pr\{X_{n+1}=0|X_n=1\}=\beta$，$Pr\{X_{n+1}=1|X_n=1\}=1-\beta$。那么 X_1 的概率密度函数为

$$\pi(X_1)=\pi(X_0)\cdot P=\begin{bmatrix}p & 1-p\end{bmatrix}\begin{bmatrix}1-\alpha & \alpha\\ \beta & 1-\beta\end{bmatrix}\tag{4.7}$$

如果马尔可夫链可以从任意状态经过有限步转移到另一任意状态，且转移概率为正，那么称这个马尔可夫链是不可约（irreducible）的。例如，转移矩阵为

$$P = \begin{bmatrix} 0.1 & 0.9 & 0 & 0 \\ 0.3 & 0.7 & 0 & 0 \\ 0 & 0 & 0.2 & 0.8 \\ 0 & 0 & 0.4 & 0.6 \end{bmatrix} \tag{4.8}$$

这样的马尔可夫链，从状态 3、4 无法到达状态 1、2，因此不是不可约的。它可以简化成两个独立的马尔可夫链。

如果马尔可夫链从一个状态转移到它自身的不同路径长度的最大公因子为 1，那么称这个马尔可夫链是非周期的（aperiodic）的。例如，转移矩阵为

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.5 & 0 & 0.5 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix} \tag{4.9}$$

这样的马尔可夫链，从状态 1 要经过 $1 \to 2 \to 3 \to 4 \to 1$ 或 $1 \to 2 \to 5 \to 6 \to 3 \to 4 \to 1$ 两种路径回到状态 1，路径长度分别为 4 和 6，因此这个马尔可夫链是周期的，周期为 2。

若马尔可夫过程在 $n+1$ 时刻，状态空间上的分布与在 n 时刻的分布相同，则称此分布为平稳分布。假设马尔可夫链的平稳分布为 π，它可以简单地通过求解 $\pi = \pi P$ 来得到，以刚刚的例子

$$\begin{aligned} \pi = \begin{bmatrix} p & 1-p \end{bmatrix} &= \begin{bmatrix} p & 1-p \end{bmatrix} \begin{bmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{bmatrix} \\ &= \begin{bmatrix} (1-\alpha)p + \beta(1-p) & \alpha p + (1-p)(1-\beta) \end{bmatrix} \end{aligned} \tag{4.10}$$

解得该马尔可夫过程的平稳分布为 $\pi = \begin{bmatrix} \frac{\beta}{\alpha+\beta} & \frac{\alpha}{\alpha+\beta} \end{bmatrix}$。由此可以看出，当马尔可夫过程在 X_n 时刻达到了平稳分布，那么之后的所有时刻都将维持在平稳分布上。若其从初始状态就是平稳状态，即 $\pi(X_1) = \pi$，那么该马尔可夫过程为平稳过程。在上面的例子中，若 $\pi(X_1) = \begin{bmatrix} \frac{\beta}{\alpha+\beta} & \frac{\alpha}{\alpha+\beta} \end{bmatrix}$，则是一个平稳过程。

如果初始状态不是平稳分布，随着马尔可夫过程的进行，状态的分布仍有可能趋向于平稳分布。例如从公式 4.7 中的 P，可以得到

$$P^n = \frac{1}{\alpha+\beta}\begin{bmatrix}\beta & \alpha \\ \beta & \alpha\end{bmatrix} + \frac{(1-\alpha-\beta)^n}{(\alpha+\beta)}\begin{bmatrix}\alpha & -\alpha \\ -\beta & \beta\end{bmatrix} \tag{4.11}$$

$$\lim_{n\to\infty} P^n = \frac{1}{\alpha+\beta}\begin{bmatrix}\beta & \alpha \\ \beta & \alpha\end{bmatrix} \tag{4.12}$$

$$\lim_{n\to\infty} \pi(X_n) = \begin{bmatrix}\frac{\beta}{\alpha+\beta} & \frac{\alpha}{\alpha+\beta}\end{bmatrix} \tag{4.13}$$

该马尔可夫过程在 $n \to \infty$ 时，趋于平稳分布。**若有限马尔可夫链是不可约的和非周期的，则它的平稳分布唯一，从任意的初始分布出发，当 $n \to \infty$ 时，X_n 的分布必趋向于此平稳分布**。本书将不提供此定理的证明。

此时，这个马尔可夫链在 n 时刻的熵为

$$H(X_n) = -(\frac{\beta}{\alpha+\beta}\log\frac{\beta}{\alpha+\beta} + \frac{\alpha}{\alpha+\beta}\log\frac{\alpha}{\alpha+\beta}) \tag{4.14}$$

但马尔可夫链 $\{X_n\}$ 的熵不会随 n 的增加，以 $H(X_n)$ 为增长速率线性增加，因为 X_i 之间并不是相互独立的。我们在下一节定义随机变量序列的增长速率。

4.3 熵率（entropy rate）

定义 4.4. 当如下极限存在时，随机过程 $\{X_i\}$ 的熵率 定义为

$$H(\mathcal{X}) = \lim_{n\to\infty}\frac{1}{n}H(X_1, X_2, \ldots, X_n) \tag{4.15}$$

对于 i.i.d. 随机变量序列，有

$$H(\mathcal{X}) = \lim_{n\to\infty}\frac{1}{n}H(X_1, X_2, \ldots, X_n) = \lim_{n\to\infty}\frac{1}{n}nH(X) = H(X) \tag{4.16}$$

对于独立但不同分布的随机变量序列，有

$$H(\mathcal{X}) = \lim_{n\to\infty}\frac{1}{n}H(X_1, X_2, \ldots, X_n) = \lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n}H(X_i) \tag{4.17}$$

由于 $H(X_i)$ 并不全相等，上式中的极限可能不存在。于是也有对熵率的另一种定义

定义 4.5. 当如下极限存在时，随机过程 $\{X_i\}$ 的熵率 定义为

$$H'(\mathcal{X}) = \lim_{n\to\infty} H(X_n|X_1, X_2, \ldots, X_{n-1}) \tag{4.18}$$

熵率的两个定义 $H(\mathcal{X})$ 和 $H'(\mathcal{X})$ 反映了熵率的两个不同方面，$H(\mathcal{X})$ 体现的是 n 个随机变量每个的熵，$H'(\mathcal{X})$ 体现的是已知前面 $n-1$ 个随机变量的情况下最后一个随机变量的条件熵。对于平稳过程来说，两者的极限均存在且相等。

引理 4.6. （平稳过程熵率 $H'(\mathcal{X})$ 的存在性）对于平稳随机过程，$H(X_n|X_1, X_2, \ldots, X_{n-1})$ 随 n 递减且存在极限 $H'(\mathcal{X})$。

证明.

$$\begin{aligned} &H(X_{n+1}|X_1, X_2, \ldots, X_n) \\ &\qquad \text{条件作用使熵变小} \le H(X_{n+1}|X_2, \ldots, X_n) \\ &\qquad \text{随机过程平稳性} = H(X_n|X_1, \ldots, X_{n-1}) \end{aligned} \tag{4.19}$$

由于 $H(X_n|X_1, \ldots, X_{n-1})$ 非负且递减，故极限 $H'(\mathcal{X})$ 存在。 □

引理 4.7. （*Cesáro* 均值）若 $a_n \to a$，且 $b_n = \frac{1}{n}\sum_{i=1}^{n} a_i$，则 $b_n \to a$。

证明. 设 $\epsilon > 0$，由于 $a_n \to a$，则存在 $N(\epsilon)$，使得对任意的 $n \ge N(\epsilon)$，有 $|a_n - a| \le \epsilon$。因此，对任意的 $n \ge N(\epsilon)$，有

$$\begin{aligned} |b_n - a| &= |\frac{1}{n}\sum_{i=1}^{n}(a_i - a)| \\ &\le \frac{1}{n}\sum_{i=1}^{n}|(a_i - a)| \\ &\le \frac{1}{n}\sum_{i=1}^{N(\epsilon)}|a_i - a| + \frac{n - N(\epsilon)}{n}\epsilon \\ &\le \frac{1}{n}\sum_{i=1}^{N(\epsilon)}|a_i - a| + \epsilon \end{aligned} \tag{4.20}$$

当 $n \to \infty$ 时，第一项趋于 0，故可选充分大的 n，使得 $|b_n - a| \le 2\epsilon$。因此，当 $n \to \infty$ 时，$b_n \to a$。 □

定理 4.8. 对于平稳随机过程，式 *4.15* 和式 *4.18* 中的极限均存在且相等

$$H(\mathcal{X}) = H'(\mathcal{X}) \tag{4.21}$$

证明.

$$
\begin{aligned}
H(\mathcal{X}) &= \lim_{n\to\infty} \frac{1}{n} H(X_1, X_2, \ldots, X_n) \\
\text{链式法则} &= \lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} H(X_i | X_1, \ldots, X_{i-1}) \\
\text{由引理 4.6 和 4.7} &= H'(\mathcal{X})
\end{aligned} \tag{4.22}
$$

□

4.4 马尔可夫过程的熵率

定理 4.9. （马尔可夫过程熵率）设 $\{X_n\}$ 为平稳马尔可夫链，其平稳分布 π，转移矩阵为 P。则熵率为

$$
H(\mathcal{X}) = -\sum_{ij} \pi_i P_{ij} \log P_{ij} \tag{4.23}
$$

证明.

$$
\begin{aligned}
H(\mathcal{X}) &= H'(\mathcal{X}) \\
&= \lim_{n\to\infty} H(X_n | X_1, \ldots, X_{n-1}) \\
&= \lim_{n\to\infty} H(X_n | X_{n-1}) \\
&= H(X_2 | X_1) \qquad (4.24) \\
&= \sum_i \pi_i \sum_j -P_{ij} \log P_{ij} \\
&= -\sum_{ij} \pi_i P_{ij} \log P_{ij} \qquad (4.25)
\end{aligned}
$$

□

非周期不可约的马尔可夫过程在 $n \to \infty$ 时，趋于平稳分布。由式 4.18 中对熵率的定义，初始状态对熵率并不产生影响，即使该马尔可夫过程的初始状态不是平稳分布，熵率和平稳过程的时候也是相同的。

4.5 习题

1. （历史与未来）设 $\{X_i\}_{i=-\infty}^{\infty}$ 为平稳随机过程，证明：

$$
H(X_0 | X_{-1}, X_{-2}, \ldots, X_{-n}) = H(X_0 | X_1, X_2, \ldots, X_n)
$$

2. (相对熵随时间递减) 设 $\{X_i\}_{i=1}^n$ 为马尔可夫过程，$\pi_i = \pi(X_i)$，$\pi_{i+1} = \pi(X_{i+1})$ 为第 i 和第 $i+1$ 时刻的某一可能状态的概率密度函数，$\pi'_i = \pi'(X_i)$，$\pi'_{i+1} = \pi'(X_{i+1})$ 为第 i 和第 $i+1$ 时刻的另一可能状态的概率密度函数，$p(x_{i+1}|x_i)$ 为状态 x_i 到状态 x_{i+1} 的转移概率。证明：

$$D(\pi_i||\pi'_i) \geq D(\pi_{i+1}||\pi'_{i+1})$$

提示：假设 $q(x_i, x_{i+1})$ 为随机变量 X_i 和 X_{i+1} 的在状态 π_i 下的联合概率密度函数，$q'(x_i, x_{i+1})$ 为随机变量 X_i 和 X_{i+1} 的在状态 π'_i 下的联合概率密度函数，有

$$q(x_i, x_{i+1}) = \pi_i p(x_{i+1}|x_i)$$
$$q'(x_i, x_{i+1}) = \pi'_i p(x_{i+1}|x_i)$$

利用相对熵的链式法则，对 $D(q(x_i, x_{i+1})||q'(x_i, x_{i+1}))$ 有两种可能的展开。

3. (分布趋于平稳分布) 在上一题中，假设马尔可夫过程的平稳分布为 π^*，证明随 i 的增加，该马尔可夫过程在时刻 i 的状态 π_i 与平稳分布 π^* 间的相对熵减小。
提示：利用上题结论可直接证明。

4. (平稳是均匀分布时熵增加) 在上一题中，假设马尔可夫过程的平稳分布 π^* 为均匀分布，证明随 i 的增加，该马尔可夫过程在时刻 i 的状态 π_i 的熵 $H(\pi_i)$ 增加。(这就是热力学第二定律独立系统的熵增加。)
提示：利用上题结论可直接证明。

5 变长无损压缩

5.1 信源编码（source code）

定义 5.1. 随机变量 X 的信源编码 C 是从 X 的取值空间 $\mathcal{X}$ 到 $\mathcal{C}^*$ 的一个映射，其中 $\mathcal{C}^*$ 表示含有 c 个元素的编码字母表 $\mathcal{C}$ 上的有限长度的字符串所构成的集合，随机变量 X 也称为信源（*source*）。用 $C(x)$ 表示 x 的码字，并用 $l(x)$ 表示 $C(x)$ 的长度。

例如，$C(\text{红}) = 00$，$C(\text{蓝}) = 11$ 是 $\mathcal{X} = \{\text{红}, \text{蓝}\}$ 关于编码字母表 $\mathcal{C} = \{0, 1\}$ 的一个信源编码，$00 \in \mathcal{C}^*$，$11 \in \mathcal{C}^*$。

定义 5.2. 如果编码将 X 的取值空间中的每个元素映射成 $\mathcal{C}^*$ 中不同的字符串，即

$$x' \neq x \Rightarrow C(x) \neq C(x') \tag{5.1}$$

则称这个编码是非奇异的（*nonsingular*）。也就是从信源到编码是**单射**的。

例如，$C(\text{红}) = 00$，$C(\text{蓝}) = 00$ 是奇异的。

定义 5.3. 编码 C 的扩展（*extension*）是从 $\mathcal{X}$ 上的有限长字符串到 $\mathcal{C}$ 上的有限长字符串的映射，定义为

$$C(x_1 x_2 \ldots x_n) = C(x_1)C(x_2)\ldots C(x_n) \tag{5.2}$$

其中 $C(x_1)C(x_2)\ldots C(x_n)$ 表示相应码字的串联。

例如，$C(\text{红蓝}) = 0011$。

定义 5.4. 设随机变量 X 的概率密度为 $p(x)$，信源编码 $C(x)$ 的期望长度（*expected length*）$L(C)$ 为

$$L(C) = \sum_{x \in \mathcal{X}} p(x) l(x) \tag{5.3}$$

其中，$l(x)$ 表示对应于信源 x 的码字长度。

例如，信源 $X_1, X_2, \ldots \sim X \in \mathcal{X} = \{a, b, c\}$ 是 i.i.d. 随机变量序列。X 的概率密度分布为 $P(X = a) = 0.7$，$P(X = b) = 0.15$，$P(X = c) = 0.15$。考虑一个信源编码，$C(a) = 00$，$C(b) = 01$，$C(c) = 11$。这样每个信源需要两位的编码。期望长度为 $L = 0.7 * 2 + 0.15 * 2 + 0.15 * 2 = 2$ bit/symbol。显

然，我们可以让发生概率高的 A 有更短的编码，例如 $C(a)=0$，$C(b)=10$，$C(c)=11$，这样 $L=0.7*1+0.15*2+0.15*2=1.3$ bit/symbol。而且，这种编码序列当从左向右读的时候，有唯一的解码，就像 001101001101011 可以被唯一地解码为 $AACABACABC$。

像上面的例子里那样，使用非等长的编码对取值空间中所有取值可能进行非奇异编码，称为变长无损压缩（variable length lossless compression）。当使用长度为 $nH(X)$ 的码，对 i.i.d 随机变量序列中的典型集进行编码，使得当 $n\to\infty$ 时编码对所有取值可能的覆盖概率趋于 1，这种编码方式称为近无损压缩（near-lossless compression），但仍然，这种压缩方式是有信息损失的。对用奇异编码的编码方式称为有损压缩(lossy compression）。有损压缩可以更大限度地降低数据大小，尽管信息会相对损失，但有很强的实用性。例如，MP3 格式是去掉了人耳分听力范围外的频率的音频有损压缩，JPEG 图片格式是对图片的有损压缩，（而 PNG 格式则是无损压缩）。

5.2 应用：UPC 条形码（Universal Product Code）

条形码 (Barcodes) 与 UPC 编码一起诞生于 1973 年。条形码是指 UPC 编码及其变体和拓展，是一种图形式的、机器可读的编码表示。

在条形码中，编码的每个数字都由七个大小相等的黑色或白色条表示。视觉上，两个或多个相邻的黑条显示为一个宽条；白条显示为黑条之间的空间分隔符（大小也不同）。如果我们将这样的宽条（黑色或白色）称为广义条，那么一个数字的表示总是由四个这样的广义条组成，它们必然是交错的：“白-黑-白-黑”或“黑-白-黑-白”。图 5.1 为 UPC 编码的一种常用形式 UPC-A，它采用形如 $S\bar{L}LLLLLLMRRRRRR\bar{R}E$ 的序列，其中 S、M 和 E 表示开始、中间和结束，都由”黑-白-黑”的窄条来编码。L 为左半区数字，每个数字由 7 个窄条组成，第一个窄条为白色，最后一个为黑色，且每个数字必包含 2 个宽条 2 个窄条，数字的编码如图 5.1 右侧所示。R 为右半区数字，编码与左半区基本相同，只是黑白颜色完全相反。加入右半区的本意是当反向扫描条形码时，可以做到区分。$\bar{L}$ 与 $\bar{R}$ 一般做为校验码来使用。

从编码的理论来说，UPC 每个半区的数字编码是奇异的，对 0 到 9 的数字进行编码，其实只需要 4 位二进制编码，但这样无法保证每个数字都有两个黑条和两个白条，所以每个数字由 5 位二进制码来表示。每个数字两个黑条和两个白条的要求其实是由于读码的机器经常会发生错误，这样限制可以自动校验错误的发生。在 UPC 中使用了等长码，加入了码字间的

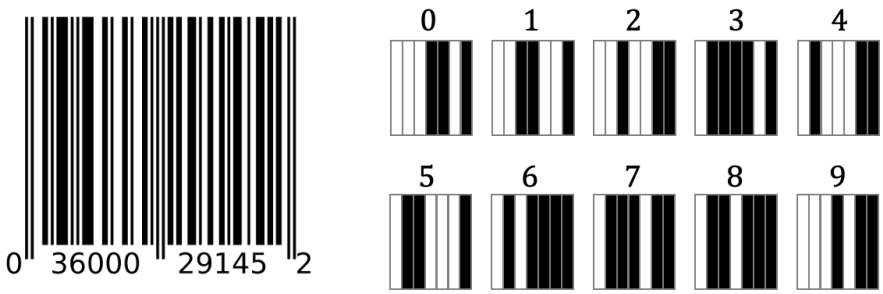

图 5.1: UPC-A 条形码

分隔符、开始中间和结束的标识、左右半区的不同编码，这些都是牺牲了期望长度，为了在实际应用中读取时可以更为准确。

5.3 前缀码（prefix code）

非奇异性可以保证表示 X 的每个值都有对应的不同编码，但我们往往需要发送 X 的一个序列。对此，可以通过在两个码之间添加分隔符（比如逗号），来确保整个序列可以翻译。但这样使用额外的符号会降低编码的效率。如果构造特殊的编码，让这个序列不需要分隔符就能唯一确定每个码，这样的效果会更好。

定义 5.5. 如果一个编码的拓展编码是非奇异的，则称该编码是唯一可译的（*uniquely decodable*）。

唯一可译的任一编码字符串只来源于唯一可能的信源字符串。但是，仍然可能需要通观整个编码字符串，才能最终确定信源字符串。

定义 5.6. 若码中无任何码字是其他码字的前缀，则称该编码为前缀码（*prefix code*）或即时码（*instantaneous code*）。

前缀码指任何一个码字在结束时就可以立即辨认出来。我们举一个例子来理解上述的这些定义。首先考虑编码 C_1

$$C_1(A) = 0$$
$$C_1(B) = 10$$
$$C_1(C) = 110$$
$$C_1(D) = 111$$

是前缀码，因为每次看到编码 0，或编码 111 的时候，我们就可以断定这个字的编码结束了。就像 01110100 这组编码，第一个 0 可以解码为 A，后面的 111 解码为 D，0 解码为 A，10 解码为 B，最后 0 解码为 A。这个编码唯一对应信源 $ADABA$，它是唯一可译的，同时这组编码也是非奇异的。

考虑另一组编码

$$
\begin{aligned}
C_2(A) &= 10 \\
C_2(B) &= 00 \\
C_2(C) &= 11 \\
C_2(D) &= 110
\end{aligned}
$$

编码 11011 是唯一可译的，因为它只对应 DC。但如果只看前两位 11，无法判定它是对应 C，还是要与后面的 0 连起来对应 D，但如果观察整个编码，会发现第一个字只能是 D。所以，这组编码是唯一可译的，但却不是前缀码。

如果编码为

$$
\begin{aligned}
C_2(A) &= 0 \\
C_2(B) &= 010 \\
C_2(C) &= 01 \\
C_2(D) &= 10
\end{aligned}
$$

编码 01010 的解码可以是 CB、BD、ADD 或 CCA 中的任意一种。所以该编码不是唯一可译的，但是是奇异的。

高效编码目标是**构造期望长度最小的前缀码**。前缀码的定义为“码中无任何码字是其他码字的前缀”，那么 01 和 010 这两个码字就是违反前缀规则的，因为 01 和 010 的前两位是一样的。如果没有任何码字是其他码字的前缀，当出现与某一个码字匹配的码时，就可以唯一确定是这个码字。

5.4 应用：摩尔斯码（Morse code）

摩尔斯码是电子通信中常使用的一种编码，它是将文本字符编码为两种不同持续时间的信号标准化序列，短持续时间的码称为滴（dits），长持续时间的码称为嗒（dahs）。摩尔斯码以电报的发明者之一塞缪尔 · 摩尔斯命名。图 5.2 即为国际摩尔斯码，为了缩短整个电码的传输速率，英文中使用

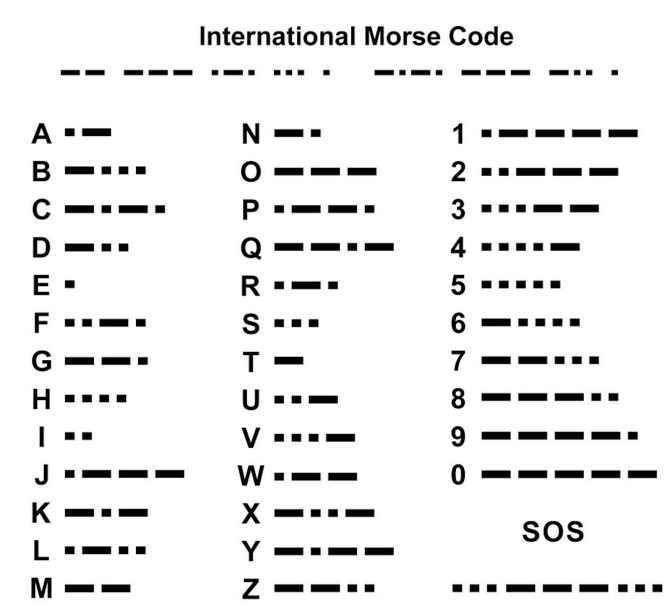

图 5.2: 国际摩尔斯码

频率越高的字母，被指定为越短的码。比如英文中频率最高的字母 E、I 和 S 分别被指定为 $\cdot$、$\cdot\cdot$ 和 $\cdots$。

根据上一节的定义，不难发现摩尔斯码是奇异的，但不是唯一可译的。例如 $\cdots\cdot\cdot$ 可以被译为 H、II、ES、SE 和 EIE 中的任意一个，所以在传递摩尔斯码的时候，必须通过间隔来分隔不同的码字。摩尔斯电码使用一个三倍于一个‘滴’时常的间断来分隔在两个字母，使用一个七倍于一个‘滴’时常的间断来分隔在两个单词。这个间断就像图 5.2 中最上边 Morse Code 的电码那样。这种间隔实际上减慢了信号传递的速率，因此前缀码就体现了其优越性。

5.5 Kraft 不等式

由于前缀码有着这样的限制，因此不可能将短的码字分配给所有的信源字符而仍保持是无前缀的。前缀码的码长满足如下不等式

定理 5.7. （*Kraft 不等式*）*若使用含有 c 个元素的编码字母表对 m 个信源*

构造前缀码，码字长度为 $l_1, l_2, \ldots, l_m$，必满足不等式

$$\sum_{i=1}^{m} c^{-l_i} \leq 1 \tag{5.4}$$

反之，若给定满足以上不等式的一组码字长度，则存在一个相应的前缀码，其码字长度等于给定的码字长度。

证明. 首先构造一个 c 叉树，即每一节点均含有 c 个子节点的树。假定树的每层代表码字的每一个字符，每个节点出发的 c 条树枝代表着每个码字字符的 c 个可能值，那么从根节点出发的每条路径即可代表一个码字。例如，对于 $c = 2$ 的情况，即 0、1 二进制编码，这个树由图 5.3所示。图中黑色的节点组成了前缀码，这是因为黑色的节点**没有一个是另一个的母节点**，而且黑色的节点也都**不再有子节点**。这样，由黑色节点代表的码字，没有任何一个码字是另一码字的前缀。因此，这种树状结构按这种方式选择节点，就可以构成一个前缀码。

另 l_{max} 为码字集中最长的码字长度，那么树在第 l_{max} 层一共有 $c^{l_{max}}$ 个节点。现在考虑在树的第 l_i 层的一个码字（即一个黑色节点），因为它不再有子节点，那么它会使第 l_{max} 层中的 $c^{l_{max}-l_i}$ 个节点无法成为码字。而且由于没有任何一个码字是另一个码字的母节点，那么长度为 $l_1, l_2, \ldots, l_m$ 的 m 个码字会使第 l_{max} 层中的 $\sum_{i=1}^{m} c^{l_{max}-l_i}$ 个节点无法成为码字，这些节点不会重复。因为这些无法成为码字的节点数必然小于 l_{max} 层一共有的节点数 $c^{l_{max}}$。则

$$\begin{aligned} \sum_{i=1}^{m} c^{l_{max}-l_i} &\leq c^{l_{max}} \\ \sum_{i=1}^{m} c^{-l_i} &\leq 1 \end{aligned} \tag{5.5}$$

反之，若给定任意一组满足不等式的码字长度 $l_1, l_2, \ldots, l_m$，总可以构造出一个 c 叉树。按码字长度从短到长的顺序，从 c 叉树中找到一个对应长度的节点记为该码字，并消除其所有子节点。按照从短到长的顺序可以保证没有任何一个码字是另一个的母节点。以此则可以构造出一个前缀码。 □

例如图 5.3中所示，使用编码字母表 $\{0, 1\}$ 对 4 个信源构造前缀码 $\{0, 10, 110, 111\}$，码字长度分别为 $1, 2, 3, 3$，因而有 $2^{-1}+2^{-2}+2^{-3}+2^{-3} = 1$。

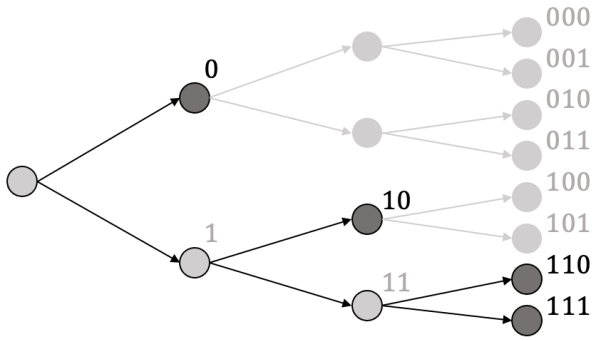

图 5.3: Kraft 不等式编码树

定理 5.8. （推广的 *Kraft* 不等式）若使用含有 c 个元素的编码字母表对无限可数个信源构造前缀码，码字长度为 $l_1, l_2, \ldots$，必满足不等式

$$\sum_{i=1}^{\infty} c^{-l_i} \leq 1 \tag{5.6}$$

反之，若给定满足以上不等式的一组码字长度，则存在一个相应的前缀码，其码字长度等于给定的码字长度。

证明. 证明思路与 Kraft 不等式证明思路相似，假设第 i 个信源的编码为 $y_1 y_2 \ldots y_{l_i}$，$y_\cdot \in \{0, 1, \ldots, c-1\}$，将其记做一个 c 进制的实数 $0.y_1 y_2 \ldots y_{l_i}$（这种记法其实与无限长度的 c 叉树相似）。由于编码为前缀码，那么区间

$$[0.y_1 y_2 \ldots y_{l_i},\ 0.y_1 y_2 \ldots y_{l_i} + c^{-l_i}) \tag{5.7}$$

中无其他码字。又因前缀码条件，这些区间互不相交。它们的区间的并集总是区间 $[0, 1]$ 的子集，因此区间长度小于或等于 1。

反之亦然，将每个区间代表的编码分配给对应码字长度的信源，则可构造一组前缀码。 □

其实不只是前缀码，任意的唯一可译码也都必然满足 Kraft 不等式（Kraft-McMillan 不等式），本书在此并不给出详细的证明过程。但这个事实表明，从编码长度的角度去看，唯一可译码虽然比前缀码有更多的选择可能，但编码长度并不会比前缀码更短。因此，相比于其他的唯一可译码，使用前缀码更为便捷，因为前缀码是即时可译的。

5.6 前缀码期望长度的下界

在上一节中的 Kraft 不等式证明了，如果对一组信源构造前缀码，码字长度必然要满足 Kraft 不等式。同时也证明了，只要码字长度满足了 Kraft 不等式，那必然可以构造一组前缀码。在定义 5.4中，我们定义了编码的期望长度，并希望将发生概率高的信源给予更短的编码，以此减少编码长度的期望。因此，我们在这一节将探讨如何构造一个期望长度最短的前缀码。

该问题是一个标准的优化问题，即

$$\begin{aligned} \arg\min_{l_1,l_2,\ldots,l_m} \sum_{i=1}^{m} p_i l_i \\ \text{s.t.} \sum_{i=1}^{m} c^{-l_i} \leq 1 \\ l_i \in \mathbb{Z}^* \end{aligned} \tag{5.8}$$

其中，p_i 为第 i 个信源发生的概率，l_i 为第 i 个信源的编码长度，c 为编码字母表元素的个数。

由于 l_i 为非负整数，该问题实际上是整数优化问题，并还需增加关于 l_i 非负的限制条件。但此处，我们为了计算理论上平均意义下的编码长度，放松编码长度的整数限制，考虑 l_i 为实数。而且该问题是一个线性优化问题，必在约束的边界上取得最优，因此不等式约束可等价为等式约束，

$$\begin{aligned} \arg\min_{l_1,l_2,\ldots,l_m} \sum_{i=1}^{m} p_i l_i \\ \text{s.t.} \sum_{i=1}^{m} c^{-l_i} - 1 = 0 \end{aligned} \tag{5.9}$$

使用拉格朗日乘子法（Lagrange multiplier），将带约束的优化问题转化为

$$\arg\min_{l_1,l_2,\ldots,l_m} \sum_{i=1}^{m} p_i l_i + \lambda(\sum_{i=1}^{m} c^{-l_i} - 1) \tag{5.10}$$

求解其最小值，我们对 l_i 求微分，可得

$$J = \sum_{i=1}^{m} p_i l_i + \lambda(\sum_{i=1}^{m} c^{-l_i} - 1) \tag{5.11}$$

$$\frac{\partial J}{\partial l_i} = p_i - \lambda c^{-l_i} \log_e c \tag{5.12}$$

令偏导数为 0，有 $p_i - \lambda c^{-l_i} \log_e c = 0$。其解为

$$c^{-l_i} = \frac{p_i}{\lambda \log_e c} \tag{5.13}$$

将其带入原约束条件 $\sum_{i=1}^{m} c^{-l_i} - 1 = 0$ 中，解得

$$\lambda = \frac{1}{\log_e c} \tag{5.14}$$

因而，将 λ 带入式 5.13，可得到最优长度

$$l_i^* = -\log_c p_i \tag{5.15}$$

那么，若码字长度可以为非整数，最优的期望长度为

$$L^* = \sum_{i=1}^{m} p_i l_i = \sum_{i=1}^{m} p_i - \log_c p_i = H_c(X) \tag{5.16}$$

但事实上，l_i 必须为整数，因而码字长度不可能总设置为式 5.15中的长度，我们只能在整数中选择与其接近的码字长度，使期望长度接近于最优期望长度。在一下定理中，我们将直接从结论入手去证明期望长度的下界。

定理 5.9. （前缀码期望长度下界）使用含有 c 个元素的编码字母表对随机变量 X 构造前缀码，其编码的期望长度必定大于或等于熵 $H_c(X)$，即

$$L \geq H_c(X) \tag{5.17}$$

当且仅当 X 的任意取值 a_i 的编码长度满足 $l_i = -\log_c p_i$ 时等号成立，其中 $p_i = Pr(X = a_i)$。

证明.

$$\begin{aligned} L - H_c(X) &= \sum_{i=1}^{m} p_i l_i + \sum_{i=1}^{m} p_i \log_c p_i \\ &= \sum_{i=1}^{m} (-p_i \log_c c^{-l_i} + p_i \log_c p_i) \\ &= \sum_{i=1}^{m} (-p_i \log_c \frac{c^{-l_i}}{\sum_{i=1}^{m} c^{-l_i}} + p_i \log_c p_i - p_i \log_c \sum_{i=1}^{m} c^{-l_i}) \end{aligned} \tag{5.18}$$

令 $q_i = \frac{c^{-l_i}}{\sum c^{-li}}$，

$$
\begin{aligned}
L - H_c(X) &= \sum_{i=1}^{m}(-p_i \log_c q_i + p_i \log_c p_i - p_i \log_c \sum_{i=1}^{m} c^{-l_i}) \\
&= \sum_{i=1}^{m}(p_i \log_c \frac{p_i}{q_i} - p_i \log_c \sum_{i=1}^{m} c^{-l_i}) \\
\text{Kraft 不等式} &\geq \sum_{i=1}^{m} -p_i \log_c \frac{p_i}{q_i} \\
&= D(p||q) \\
\text{相对熵非负性} &\geq 0
\end{aligned} \tag{5.19}
$$

当且仅当 $p_i = c^{-l_i}$，$\sum_{i=1}^{m} c^{-l_i} = 1$ 时，Kraft 不等式和相对熵非负性两处不等式取等。 □

5.7 香农码（Shannon coding）和最优码

在上节中我们证明了前缀码的期望长度存在一个下界，即 $H_c(X)$，而且由于每个编码长度为必须为整数，达到这个下界是十分困难的，既需要所有的码长满足 $l_i = -\log_c p_i$ 又需要都为整数。那么如果要找到一个期望长度尽可能接近下界 $H_c(X)$ 的前缀码，同时为了确保可以构造出前缀码还要满足 Kraft 不等式，我们可以通过对 $l_i = -\log_c p_i$ 向上取整，来得到一个期望长度较短的前缀码，这套编码方式称为香农码。

定义 5.10. 用含有 c 个元素的编码字母表对随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$ 构造前缀码，若其编码长度 $l_1, l_2, \ldots, l_m$ 满足

$$
l_i = \lceil -\log_c p_i \rceil \tag{5.20}
$$

则称该编码为<u>香农码</u>。其中 $l_i = l(x_i)$ 为 X 取值 a_i 的编码长度，$p_i = Pr(X = a_i)$。

由于香农码将所有的编码长度都向上取整，其必然满足 Kraft 不等式，

$$
\sum_{i=1}^{m} c^{-\lceil -\log_c p_i \rceil} \leq \sum_{i=1}^{m} c^{\log_c p_i} = \sum_{i=1}^{m} p_i = 1 \tag{5.21}
$$

即必然可以构造出一组前缀码。

定理 5.11. （香农码期望码长的界）使用含有 c 个元素的编码字母表对随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$ 构造香农码，即 $l_i = \lceil -\log_c p_i \rceil$，$p_i = Pr(X = a_i)$。则其期望码长 $L_s = \sum_{i=1}^{m} p_i l_i$ 有

$$H_c(X) \leq L_s < H_c(X) + 1 \tag{5.22}$$

证明. 对于随机变量每个取值的码字长度

$$-\log_c p_i \leq l_i = \lceil -\log_c p_i \rceil < -\log_c p_i + 1 \tag{5.23}$$

对式 5.23的左右两边同乘以 p_i 并对 i 求和，有

$$H_c(X) \leq L_s < H_c(X) + 1 \tag{5.24}$$

□

由上述定理可知，香农码的期望长度比期望长度最多只多出一位编码之内。我们还可以通过组合编码的方式，来进一步缩短香农码的期望长度。

由于信息都是一串一串储存或发送地，假设 $X_1, X_2, \ldots, X_n$ 是与 $X \in \{a_1, a_2, \ldots, a_m\}$ 分布相同的 i.i.d. 随机序列，如果我们不对 $X_1, X_2, \ldots, X_n$ 的每一个信源进行编码，而是对这个序列整体进行编码，那么整个序列 $X_1, X_2, \ldots, X_n$ 的取值可能有 m^n 种。假设序列的一个取值为 $x_1, x_2, \ldots, x_n$，$x_j \in \{a_1, a_2, \ldots, a_m\}$，该取值的发生概率为 $p(x_1, x_2, \ldots, x_n)$，对应的编码长度为 $l(x_1, x_2, \ldots, x_n)$。那么如果使用 c 元香农码，其编码长度

$$\begin{aligned} l(x_1, x_2, \ldots, x_n) &= \lceil -\log_c p(x_1, x_2, \ldots, x_n) \rceil \\ &< -\log_c p(x_1, x_2, \ldots, x_n) + 1 \end{aligned} \tag{5.25}$$

$$\begin{aligned} l(x_1, x_2, \ldots, x_n) &= \lceil -\log_c p(x_1, x_2, \ldots, x_n) \rceil \\ &\geq -\log_c p(x_1, x_2, \ldots, x_n) \end{aligned} \tag{5.26}$$

同样对两个式子两边同时乘以 $p(x_1, x_2, \ldots, x_n)$ 并对所有的 $x_1, x_2, \ldots, x_n$ 取值加和，可以得到整个随机序列期望长度的界

$$H_c(X_1, X_2, \ldots, X_n) \leq L_s^{(n)} < H_c(X_1, X_2, \ldots, X_n) + 1 \tag{5.27}$$

因为 $X_1, X_2, \ldots, X_n$ 为 i.i.d. 随机序列，即

$$H_c(X_1, X_2, \ldots, X_n) = \sum_{j=1}^{n} H_c(X_j) = nH_c(X) \tag{5.28}$$

所以有

$$nH_c(X) \le L_s^{(n)} < nH_c(X) + 1 \tag{5.29}$$

因此平均每个信源的编码长度

$$H_c(X) \le L_s < H_c(X) + \frac{1}{n} \tag{5.30}$$

从这里可以看出，当我们对信源组合后再编码，其期望长度可以进一步缩短，而且当 $n \to \infty$ 时，期望长度会趋向下界。

其实,如果 $X_1, X_2, \ldots, X_n$ 不是独立同分布的,而是平稳随机过程 $\{X_j\}$，式 5.27将变为

$$\frac{H_c(X_1, X_2, \ldots, X_n)}{n} \le L_s < \frac{H_c(X_1, X_2, \ldots, X_n)}{n} + \frac{1}{n} \tag{5.31}$$

当 $n \to \infty$ 时，$H_c(X_1, X_2, \ldots, X_n) \to nH_c(\mathcal{X})$，其中 $H_c(\mathcal{X})$ 为平稳随机过程 $\{X_j\}$ 的熵率。因此，$L_s \to H_c(\mathcal{X})$。

虽然香农码已经很接近期望长度的下界，但仍然可能不是最短的。

定义 5.12. 如果 $C(X)$ 是随机变量 X 的一组前缀码，且不存在对 X 期望长度更短的前缀码编码，则 $C(X)$ 是<u>最优前缀码</u>。

由定义 5.12，最优码长 L^* 小于或等于 L_s，因而有如下定理。

定理 5.13. （最优码长的界）使用含有 c 个元素的编码字母表对随机变量 X 构造前缀码，若 $l_1^*, l_2^*, \ldots, l_m^*$ 是其一组最优码的码长，L^* 是最优码的期望长度，即 $L^* = \sum_{i=1}^m p_i l_i^*$，则

$$H_c(X) \le L^* < H_c(X) + 1 \tag{5.32}$$

证明. 由式 5.17和式 5.24，

$$H_c(X) \le L^* \le L_s < H_c(X) + 1 \tag{5.33}$$

□

例如，假设随机变量 X 的取值空间为 $\mathcal{X} = \{1, 2, 3, 4, 5\}$，对应的概率分别为 0.25，0.25，0.2，0.15 和 0.15，若使用 0、1 进行二元前缀码编码，其期望长度的下界为

$$H(X) = -(2 * 0.25 \log 0.25 + 0.2 \log 0.2 + 2 * 0.15 \log 0.15) \approx 2.285 \tag{5.34}$$

此时每个取值对应的码长约为 $\log 0.25 = 2$，$\log 0.25 = 2$，$\log 0.2 \approx 2.322$，$\log 0.15 \approx 2.737$ 和 $\log 0.15 \approx 2.737$。如果我们选用香农码，对应码长向上取整，那实际的码长为 2、2、3、3 和 3。对应的一组可能的前缀码可以为 00、01、100、101 和 110。香农码的期望长度为

$$L_s = 0.25 * 2 + 0.25 * 2 + 0.2 * 3 + 0.15 * 3 + 0.15 * 3 = 2.5 \tag{5.35}$$

如果把 1、4、5 分为一组，编码首位用 0 表示；2、3 为另一组，编码首位用 1 表示。进而，把 4、5 再分到一个小组中，编码前两位用 00 表示，而把 1 用 01 表示。那么得到的取值对应编码为 01、10、11、000 和 001。编码长度为 2、2、2、3 和 3。期望长度为

$$L = 0.25 * 2 + 0.25 * 2 + 0.2 * 2 + 0.15 * 3 + 0.15 * 3 = 2.3 \tag{5.36}$$

由此可以看出，通过这样分组的方法，可以构造出更优的前缀码。那为什么这样的分组可以构造更短的码？要回答这个问题，我们首先要看一下什么是赫夫曼码。

5.8 赫夫曼码（Huffman coding）

对于如何构造最优前缀码，赫夫曼给出了一个算法，而且可以证明，由此算法所构造的编码比其他为相同信源字母表构造的编码有更短的期望长度。这种编码方式叫做赫夫曼码。c 元赫夫曼码构造方法为：

1. 找到 c 个概率最小的信源，把他们归为一组，整体看作一个新的信源。
2. 重复以上步骤直到只有一个信源。

这样我们就得到了一个树，对其分配编码即为赫夫曼码。当 $c > 2$ 时，有时候信源的数量无法凑足 c 个为一组，因此要**事先增加发生概率为 0 的假的信源进去**。因为每次都是以 c 个为一组，那么当有 $k(c-1)+1$ 个信源的时候（$k \in \mathbb{N}$），信源的数量就一定是足够的。

举一个例子，随机变量 X 取值为 $\{a_1, a_2, \ldots, a_6\}$ 的概率为 $p_1 = 0.25$、$p_2 = 0.25$、$p_3 = 0.2$、$p_4 = 0.15$、$p_5 = 0.1$ 和 $p_6 = 0.05$，对其构造 3 元赫夫曼码。首先，信源数量为 $6 < 3 * (3-1) + 1 = 7$，因此补充一个假信源 a_7，$p_7 = 0$。然后找到概率最小的三个信源 a_5、a_6 和 a_7，将他们组合成一个新的信源 a_{567}，$p_{567} = 0.15$。接着重复上述过程，将 a_3、a_4 和 a_{567} 组合成一个新的信源 a_{34567}，$p_{34567} = 0.5$。最后将 a_1、a_2 和 a_{34567} 组合成一个新的信源。组

合所构成的树如图 5.4，对树的节点赋予编码即构成赫夫曼码。赫夫曼码及码长见表 1，期望长度为 $2*0.25*1+0.2*2+0.15*2+0.1*3+0.05*3=1.65$，期望长度下界熵为

$$\begin{aligned} H_3(X) =& 2*0.25*\log_3 0.25+0.2*\log_3 0.2+0.15*\log_3 0.15 \\ &+0.1*\log_3 0.1+0.05*\log_3 0.05 \approx 1.529 \end{aligned} \tag{5.37}$$

如果使用香农码，码长分别为 2、2、2、2、3、3，编码可为 00、01、02、10、110、111，期望长度为 2.15。

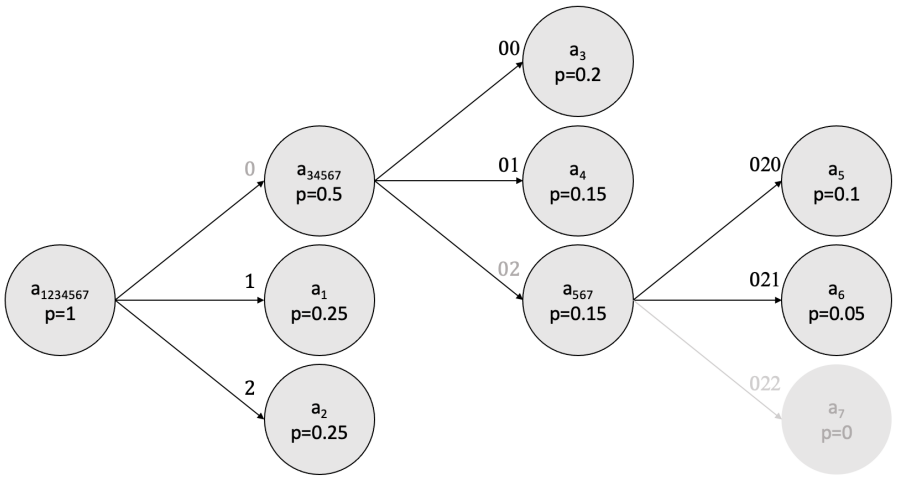

图 5.4: 赫夫曼编码树

表 1: 赫夫曼编码

x	$p(x)$	$c(x)$	$l(x)$
a_1	0.25	1	1
a_2	0.25	2	1
a_3	0.2	00	2
a_4	0.15	01	2
a_5	0.1	020	3
a_6	0.05	021	3

5.9 赫夫曼码的最优性

对于二元赫夫曼码，可以利用数学归纳法来证明它是最优码。该证明也可以进一步推广，进而证明任意 c 元赫夫曼码都是最优码。但要注意，最优码有很多，而不是只有唯一的一组。

引理 5.14. （最优码的性质）*对于任意分布，必然存在一个满足以下性质的最优前缀码：*

1. *其编码按编码长度排序与按发生概率排序的排列相反。*
2. *最长的两个码字长度相同。*
3. *最长的两个码字仅在最后一位不同。*

证明. 假设随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$，可以不失一般性地假设，每个取值对应的概率为 $p_1, p_2, \ldots, p_m$，且 $p_1 \geq p_2 \geq \ldots \geq p_m$。假设为 X 构造了一组最优码 $C(a_1), C(a_2), \ldots, C(a_m)$，$l_1^*, l_2^*, \ldots, l_m^*$ 是其对应码长。

1. *其编码按编码长度排序与按发生概率排序的排列相反，即 $\forall j, k$，若 $p_j > p_k$，则 $l_j \leq l_k$。*

可以通过反证法来证明。对于一组最优码，若其中存在 $p_j > p_k$，$l_j > l_k$。那么如果交换信源 j 和 k 的编码，编码的期望长度将增加

$$
\begin{aligned}
L' - L &= \sum_{i=1}^{m} p_i l_i' - \sum_{i=1}^{m} p_i l_i \\
&= p_j l_k + p_k l_j - p_j l_j - p_k l_k \\
&= (p_j - p_k)(l_k - l_j) \\
&< 0
\end{aligned} \tag{5.38}
$$

即，通过交换编码，期望长度减小了。这与该编码为最优码是矛盾的。因此所有最优码都满足性质 1。

2. *最长的两个码字长度相同，即 $l_{m-1}^* = l_m^*$。*

同样可以通过反证法来证明。对于一组最优码，若 $l_{m-1}^* < l_m^*$，编码树中节点 a_m 的母节点必然只有一个子节点，即 a_m。（若存在除 a_m^* 外的子节点，那该子节点的码长必与 a_m 的码长相同，即等于 l_m^*。）既然 a_m 的母节点只有一个子节点，那可以将 a_m 的母节点直接做为 a_m 节点，这样期望码长就变短了，这与该编码为最优码是矛盾的。因此所有最优码都满足性质 2。

3. 最长的两个码字仅在最后一位不同。

由性质 2 可知，节点 a_m 和节点 a_{m-1} 是有相同编码长度的。若 a_m 与 a_{m-1} 有共同的母节点（我们称这种有共同母节点的子节点们为兄弟节点），那这两个节点就只有最后一位不同，性质 3 自然满足；若 a_m 的兄弟节点不是 a_{m-1}，因为 a_m 和 a_{m-1} 有相同的码长，我们总可以将 a_{m-1} 与 a_m 的兄弟节点交换，那么交换之后该编码仍为最优码，且满足性质 3；若 a_m 没有兄弟节点，我们同样可以将 a_{m-1} 移到 a_m 的兄弟节点上去，且编码仍为最优码，满足性质 3。因此总存在一组最优码都满足性质 2。 □

引理 5.15. （分裂仍是赫夫曼码）假设随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$ 每个取值对应的概率为 $p_1, p_2, \ldots, p_m$ 且 $p_1 \geq p_2 \geq \ldots \geq p_m$；随机变量 $Y \in \{a_1, a_2, \ldots, a_m, a_{m+1}\}$ 每个取值对应的概率为 $p_1, p_2, \ldots, p'_m, p'_{m+1}$，即 $p'_m + p'_{m+1} = p_m$。若 X 的一组二元前缀码为 $C(a_j)$，我们依据 $C(a_j)$ 为 Y 构造编码 $C'(a_j)$，

$$C'(a_j) = \begin{cases} C(a_j), & \text{if } j < m \\ C(a_j)0, & \text{if } j = m \\ C(a_j)1, & \text{if } j = m+1 \end{cases} \tag{5.39}$$

则称 C' 为二元前缀码为 C 的分裂。若 C 是一个二元赫夫曼码，则它的分裂 C' 仍是一个二元赫夫曼码。

证明. 由于 p_m 为随机变量 X 取值中最小的概率，$p'_m + p'_{m+1} = p_m$，那么 p'_m 和 p'_{m+1} 是随机变量 Y 取值中发生概率最小的两个。若对 Y 构造二元赫夫曼码编码树，首先将对 a_m 和 a_{m+1} 进行组合，组合的发生概率为 p_m。此时如果再进一步对 Y 构造赫夫曼编码树，所有的流程将与对 X 构造赫夫曼编码树一样。即，若将 X 编码树的 a_m 节点后分出 0 和 1 两个子节点，分别做为 Y 的 a_m 和 a_{m+1} 节点，就与 Y 的编码树一样了。因此，$C'(a_j)$ 的编码方式与二元赫夫曼码的编码方式相同，$C'(a_j)$ 也是二元赫夫曼码。 □

我们注意到，一个通过分裂构造的前缀码必满足引理 5.14中所有的三个性质的。反过来，如果前缀码满足引理 5.14中所有的三个性质，那它必然可以由另一个前缀码通过分裂来构造得到。即，满足引理 5.14的前缀码的集合与通过分裂构造的前缀码的集合是相等的。在引理 5.14的证明过程中可知，最优码必然满足性质 1 与性质 2，且最优码的集合与性质 3 的交集必不为空。那么最优码集合、满足引理 5.14性质的码的集合和分裂构造出的码的

集合就可由图 5.5表示。从图中可以得到的重要结论是：**通过分裂构造出的前缀码中，一定存在最优码**。

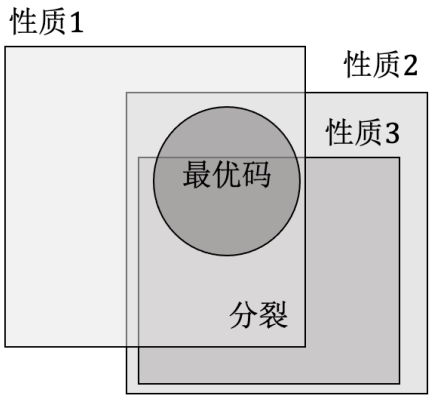

图 5.5: 最优码与通过分裂构造的码：最优码的集合为圆形区域；通过分裂构造出的码的集合为三个满足性质 1、2、3 的方形区域的交集。

引理 5.16. （分裂仍是最优码）假设随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$ 取值 a_j 的编码为 $C(a_j)$，随机变量 $Y \in \{a_1, a_2, \ldots, a_m, a_{m+1}\}$ 取值 a_j 的编码为 $C'(a_j)$ 是 $C(a_j)$ 的分裂。若 $C(a_j)$ 为最优码，则 $C'(a_j)$ 也是最优码。

证明. 假设随机变量 X 取值对应的发生概率为 $p_1 \geq p_2 \geq \ldots \geq p_m$，随机变量 Y 取值对应的发生概率为 $p_1, p_2, \ldots, p'_m, p'_{m+1}$，编码 C 为任意一组前缀码，码长为 $l_1, l_2, \ldots, l_m$，$l_1 \leq l_2 \leq \ldots \leq l_m$，那么通过分裂构造的编码 C' 的码长为 $l_1, l_2, \ldots, l_m + 1, l_m + 1$。若假设分裂前期望码长为 L，分裂后的期望码长为

$$
\begin{aligned}
L' &= \sum_{j=1}^{m-1} p_j l_j + p'_m(l_m + 1) + p'_{m+1}(l_m + 1) \\
&= \sum_{j=1}^{m-1} p_j l_j + (p'_m + p'_{m+1}) l_m + p'_m + p'_{m+1} \\
&= \sum_{j=1}^{m} p_j l_j + p'_m + p'_{m+1} \\
&= L + p'_m + p'_{m+1}
\end{aligned} \tag{5.40}
$$

那么，根据刚才图中的重要结论，通过分裂构造的编码 C' 中必存在最优码。上式中的 L' 是通过分裂构造的编码的期望码长的一般形式，那么通过优化 L'，必然能得到最优码所对应的期望码长。由于式 5.40中，$p'_m + p'_{m+1}$ 为常数无法进一步优化，那么当且仅当 L 为最小时，L' 有最小值，即是最优码的期望码长。那如果 C 是最优码，L 就正是最小值，此时 L' 也是最小值。因此，证明了最优码通过分裂构造的码也是最优码。 □

定理 5.17. （二元赫夫曼码是最优码）假设随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$，其一组二元赫夫曼码为 $C(a_j)$，则 C 为最优码。

证明. 通过引理 5.15和引理 5.16可以通过简单的归纳法来证明定理。若需证明 C 为最优码，只需要证明通过组合（分裂的逆操作）构造的赫夫曼码是最优码。因为，如果通过组合构造的码是赫夫曼码，同时也是最优码，C 为其分裂，那么由引理 5.15和引理 5.16，C 必为赫夫曼码，也是最优码。因此，只要通过不断地将概率最低的两个信源组合到一起，组合到只有两个信源时，证明这个时候是赫夫曼码，也是最优码即可。此时因为只有两个信源，我们给一个分配码字 0，另一个分配码字 1，该编码为赫夫曼码，也是最优码。 □

定理 5.18. （赫夫曼码是最优码）假设随机变量 $X \in \{a_1, a_2, \ldots, a_m\}$，其一组 c 元赫夫曼码为 $C(a_j)$，则 C 为最优码。

定理 5.17的证明过程可推广到 c 元，对于 c 元的情形，赫夫曼码的最优性也是成立的。

5.10 其他无损压缩编码

虽然赫夫曼码可以证明是最优码，但也有其适应性。首先，我们必须知道每个信源发生的概率；其次，被编码的信号/数据需要服从信源的概率分布等等。因此，在现实中，我们见到的最多的编码，可能并不是赫夫曼码。一些其他的编码如下，

- Shannon–Fano–Elias coding：算术码的前身，利用累积分布函数（cumulative distribution function，cdf）来分配码字；
- 算术码（Arithmetic Coding）：把分布概率转化为二进制小数，来分配码字；

- 通用码：针对概率分布未知的自适应编码
  - Lempel-Ziv Coding：将数据字符串解析成一个个重复出现的词组，利用指针替换词组，指针指向过去出现相同词组的位置。“gzip”所使用的就是这个编码。

本章将不对这些编码做更多的解释与讨论。

5.11 习题

1. （二进制分布前缀码）设随机变量 X 的取值空间为 $\{a_1, a_2, \ldots\}$，取值概率为 $p(a_i) = 2^{-i}$，请为随机变量 X 构造一个二元前缀码。

2. （偏码，wrong code）对分布为 p 的随机变量 X，分配长度为 $l(x) = \lceil \log \frac{1}{q(x)} \rceil$ 的码，证明期望码长 $E_p l(X)$ 满足

$$H(p) + D(p||q) \leq E_p l(X) < H(p) + D(p||q) + 1$$

3. （香农码与赫夫曼码）设随机变量 X 有 4 个取值可能，其概率分布为 $(\frac{1}{3}, \frac{1}{3}, \frac{1}{4}, \frac{1}{12})$。
   （1）请为 X 构造赫夫曼码。
   （2）证明存在两个不同的码字最优长度集，即 $(1, 2, 3, 3)$ 与 $(2, 2, 2, 2)$ 均是最优的。
   （3）为 X 构造香农码，并说明有时最优码的某个码字的长度会大于香农码。

4. （三元码）下列哪组码字长度可以成为三元赫夫曼码的码字长度？为什么？
   （1）(1,2,2,2,3,3)
   （2）(2,2,2,2,2,2,2,2,3,3,3)

5. （非奇异码）在本章中我们提到了唯一可译码并不比前缀码更优，其实非奇异码也不会比前缀码更优。如果要使用非奇异码，由于它不是唯一可译的，那么就需要知道每一个码字的结尾。下面假设随机变量 X 有 m 个可能取值，概率分布为 $p_1, p_2, \cdots p_m$，并且其概率分布案降序排列：$p_1 \geq p_2 \geq \cdots \geq p_m$。

(a) 将非奇异二元码视为三个字符 0，1 和 STOP 的三元码，证明随机变量 X 的非奇异码的期望长度 $L_{1:1}$ 满足下面的不等式

$$L_{1:1} \geq \frac{H_2(X)}{\log_2^3} - 1$$

其中，$H_2(X)$ 是 X 的熵，单位为比特。于是，非奇异码的平均长度与即时码的平均长度至少相差一个比例常数。

提示：将非奇异二元码视为三个字符 0，1 和 STOP 的三元码时，它成为了一个前缀码。

(b) 设 L^*_{prefix} 为最佳前缀码的期望长度，$L^*_{1:1}$ 为 X 的最佳非奇异码的期望长度，证明：$L^*_{1:1} \leq L^*_{prefix} \leq H(X) + 1$。

(c) 给出非奇异码的期望长度小于熵的一个简单例子。

(d) 对非奇异码可行的码字集为：$\{0, 1, 00, 01, 10, 11, 000, \cdots\}$。证明：如果将最短的码字分配给概率最大的字符，那么 $L_{1:1} = \sum\limits_{m}^{i=1} p_i l_i$ 达到最小值。于是，有 $l_1 = l_2 = 1$，$l_3 = l_4 = l_5 = l_6 = 2$ 等等。证明码字长度的通项公式为 $l_i = \lceil \log\left(\frac{i}{2} + 1\right) \rceil$，因而 $L^*_{1:1} = \sum\limits_{i=1}^{m} p_i \lceil \log\left(\frac{i}{2} + 1\right) \rceil$。

(e) 在 (d) 中已经表明很容易找出分布的最优非奇异码。只不过在处理平均长度时需要有点技巧。现在来估计这个平均长度的界。从 (d) 可以推出 $L^*_{1:1} \geq \tilde{L} := \sum\limits_{i=1}^{m} p_i \lceil \log\left(\frac{i}{2} + 1\right) \rceil$。考虑下面的差值

$$F(\mathbf{p}) = H(X) - \tilde{L} = -\sum_{i=1}^{m} p_i \log p_i - \sum_{i=1}^{m} p_i \log\left(\frac{i}{2} + 1\right)$$

用拉格朗日乘子法证明 $F(\mathbf{p})$ 的最大值在 $p_i = c/(i+2)$ 达到，其中 $c = 1/(H_{m+2} - H_2)$，H_k 是调和级数

$$H_k := \sum_{i=1}^{k} \frac{1}{i}$$

（这也可以利用相对熵的非负性完成。）

提示：拉格朗日乘子法的等式约束条件为 $\sum p_i = 1$，对 p_i 求偏导并等于 0，得到 p_i 与 λ 的关系式，然后带入 $\sum p_i = 1$ 中。利用相对熵的证明过程会更简单一些。

(f) 继续证明如下不等式：

$$\begin{aligned} H(X) - L_{1:1}^{*} &\leq H(X) - \tilde{L} \\ &\leq \log\left(2\left(H_{m+2} - H_2\right)\right) \end{aligned}$$

由调和级数性质 $H_k \leq \ln k + 1$，可以推出

$$H(X) - L_{1:1}^{*} < \log\log m + 2 \tag{5.41}$$

于是，我们得到

$$H(X) - \log\log|\mathcal{X}| - 2 \leq L_{1:1}^{*} \leq H(X) + 1$$

这表明，即使不考虑是否是唯一可译的，**非奇异码也不能比前缀码好很多**。

提示：利用 (e) 中 F 的最大值。在后面不等式放缩中，先利用调和级数定义，再 $\ln(m+2) = \frac{\log(m+2)}{\log e} \leq \log(m+2) \leq \log m^2$，当 $m \geq 2$ 时。

6 信道容量

6.1 通信系统与离散无记忆信道

在上一章介绍了信息论中的一个重要问题“压缩”，即将信息经过编码后存储，再通过解码读取的过程。当编码与信源是一一对应时，就可以做到无损压缩。在本章中将介绍另一重要问题“通信”，也就是信息的传输。通信需要将信息先编码，然后通过发射器发送，再从接收器接收，最后通过解码将信息还原。在整个通信的过程中，编码后的信息在发射与接收这一步骤上，可能会产生一些错误，也就是接收的编码并不等于发送的编码，这就会导致解码之后的信息与原信息存在误差。因此，如何设计编码使这种错误的发生可能性降到最低，就是本章重点讨论的内容。

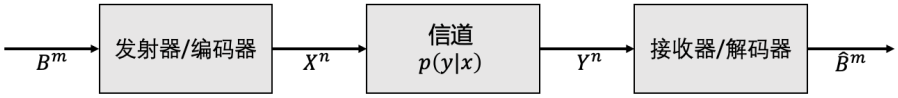

图 6.1: 通信系统

本章中的随机变量定义将与上一章存在一些差别。图 6.1展示的是通信系统，其中 $B^m = (B_1, B_2, \ldots, B_m)$ 是待传输的原始信息，也就是信源序列。$B_1, B_2, \ldots, B_m$ 分别代表其中的第 1 到第 m 位信源。单个信源的取值空间为单字信源字母表 $\mathcal{B}$，即 $B_1, B_2, \ldots, B_m \in \mathcal{B}$。但在信源不独立时，直接定义整个 m 位的信源序列的取值空间将含有更少的元素，因此将信源序列 B^m 的取值空间记作信源字母表 $\mathcal{B}^m$，即 $(B_1, B_2, \ldots, B_m) \in \mathcal{B}^m$，并假设 $\mathcal{B}^m$ 中含有 M 个元素，不失一般性地，我们可以将 $\mathcal{B}^m$ 记为 $\{1, 2, \ldots, M\}$。

相似地，$\hat{B}^m = (\hat{B}_1, \hat{B}_2, \ldots, \hat{B}_m)$ 是接收到的解码后的信息，叫做信宿序列。单个信宿的取值空间为单字信宿字母表 $\hat{\mathcal{B}}$，整个信宿序列的取值空间记作信宿字母表 $\hat{\mathcal{B}}^m$。为了保证接收的消息与发送的消息可以一一对应，一般在通信系统中假设 $\mathcal{B}^m = \hat{\mathcal{B}}^m$。

$X^n = (X_1, X_2, \ldots, X_n)$ 是信源序列 B^m 的编码，X^n 是在输入字母表 $\mathcal{X}$ 上的 n 位编码，$X_1, X_2, \ldots, X_n$ 代表其编码的第 1 到第 n 位（注意这里的定义与信息压缩中的定义不同，此处 X_i 为编码的第 i 位，而不再是一个完整的编码，这样定义是因为在信息传输过程中，每一位都可能出现错误，这里的 $\mathcal{X}$ 与上一章的编码字母表 $\mathcal{C}$ 是等价的），即 $X_1, X_2, \ldots, X_n \in \mathcal{X}$。同

样地，一般假设 $\mathcal{X}=\mathcal{Y}$，但他们也可能是不同的。

概率转移矩阵 $p(y|x)$ 是发送的编码中的一位是 x，但接收到的是 y 的概率，$x\in\mathcal{X}$，$y\in\mathcal{Y}$。之后我们也会考虑发送的整个编码为 x^n，但接收到的是 y^n 的概率，$x^n\in\mathcal{X}^n$，$y^n\in\mathcal{Y}^n$，概率转移矩阵记做 $p(y^n|x^n)$。

例如，我们要通过通信系统发送由 3 个字母构成的单词，那么 $m=3$，B^m 是一个 3 字母的单词。单字信源字母表 $\mathcal{B}=\{a,b,\ldots,z\}$ 是 26 个英文字母。但其实 3 个字母的单词并没有 26^3 那么多，因此定义信源字母表 $\mathcal{B}^m=\{cat,dog,red,\ldots\}$ 为所有的 3 字母单词集合，$M=|\mathcal{B}^m|$。现在我们对 B^m 进行编码，假设采用 7 位的 4 进制编码，即输入字母表 $\mathcal{X}=\{1,2,3,4\}$ 含有四个元素，X^n 是一个 8 位 4 元的编码，$n=8$。比如，$B^3=cat$，$X^8=C(cat)=12344321$，即 $X_1=1,X_2=2,\ldots,X_8=1$。在接收时，可能会收到 $Y^8=12344325$，即在输出字母表 $\mathcal{Y}=\{1,2,3,4,5\}$ 上的编码，此时 $\mathcal{X}\neq\mathcal{Y}$。若每一位编码的概率转移矩阵相互独立，假设收到与发送相同的编码的概率为 $p(Y=x|X=x)=0.8$，发送的是 1 而收到的是 5 的概率为 $p(Y=5|X=1)=0.1$，那么该事件发生的概率为 $p(Y=x|X=x)^7p(Y=5|X=1)\approx 0.02$。

定义 6.1. 离散信道（*discrete channel*）记做 $(\mathcal{X},p(y|x),\mathcal{Y})$，是由输入字母表 $\mathcal{X}$、输出字母表 $\mathcal{Y}$ 和概率转移矩阵（或称信道转移函数）$p(y|x)$ 构成的系统，其中 $p(y|x)$ 表示发送字符 x 的条件下收到输出字符 y 的概率，$x\in\mathcal{X}$，$y\in\mathcal{Y}$。X 和 Y 分别是 $\mathcal{X}$ 和 $\mathcal{Y}$ 上的随机变量，并分别代表信道的输入与输出。

信道就是在通信系统中，只考虑中间的那一段信息传输的过程，即从 X^n 到 Y^n 的过程。

定义 6.2. 如果输出的概率分布仅依赖于它所对应的输入，而与先前信道的输入或输出条件独立，就称这个信道是无记忆的（*memoryless*）。特殊地，离散无记忆信道（*discrete memoryless channel*，*DMC*）的 n 次拓展是指信道 $(\mathcal{X}^n,p(y^n|x^n),\mathcal{Y}^n)$，其中

$$p(y_i|x_1,\ldots,x_i,y_1,\ldots,y_{i-1})=p(y_i|x_i),i=1,2,\ldots,n \tag{6.1}$$

或记做

$$p(y_i|x^i,y^{i-1})=p(y_i|x_i),i=1,2,\ldots,n \tag{6.2}$$

离散无记忆信道指 Y_i 只与 X_i 相关，与 $Y_1,\ldots,Y_{i-1}$ 无关，同时也与 $X_1,\ldots,X_{i-1}$ 无关。事实上，因为 Y_n 与 $Y_1,\ldots,Y_{n-1}$ 都无关，我们可以**发现 Y_i 之间相互独立**。如果 X_j 与 X_i 之间相关，那 Y_i 与 Y_j 之间也相关，这与 Y_i 之间相互独立矛盾，**因此 X_i 之间相互独立**。离散无记忆信道的随机变量间相关性如图 6.2所示。

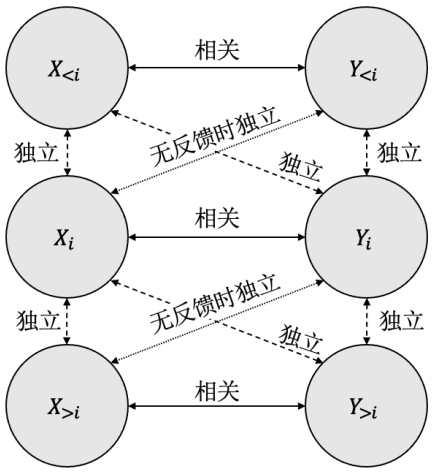

图 6.2: 离散无记忆信道中随机变量的相关性。$X_{<i}$ 代表随机变量序列 $\{X_i\}$ 中，下标小于 i 的一个随机变量，$X_{>i}$ 代表下标大于 i 的一个随机变量。$Y_{<i}$ 与 $Y_{>i}$ 同理。

定义 6.3. 如果输入的概率分布不依赖于过去的输出字符，则称这个信道是不带反馈的（*channel without feedback*）。即

$$p(x_i|x^{i-1},y^{i-1}) = p(x_i|x^{i-1}), i = 1,2,\ldots,n \tag{6.3}$$

在不带反馈的信道中 X_i 只与 $X_1,\ldots,X_{i-1}$ 相关，与 $Y_1,\ldots,Y_{i-1}$ 无关。除非有特殊说明，在一般情况下，我们都假设离散无记忆信道是不带反馈的。此时，Y_i 与 $X_1,\ldots,X_{i-1},X_{i+1},\ldots,X_n$ 都无关，Y_i 之间又是相互独立的。如图 6.2所示。离散无记忆信道的 n 次拓展的信道转移函数可简化为

$$p(y^n|x^n) = \prod_{i=1}^{n} p(y_i|x^n) = \prod_{i=1}^{n} p(y_i|x_i) \tag{6.4}$$

由此可以看出，**不带反馈的离散无记忆信道的 n 次拓展的传输实际上是 n 次独立的单字符传输**。

6.2 信道容量

定义 6.4. 信道 $(\mathcal{X}, p(y|x), \mathcal{Y})$ 的$\underline{(M,n)\ 码}$ 由以下部分构成：

1. 信源的下标集 $\{1, 2, \ldots, M\}$
2. 编码函数 $f : \{1, 2, \ldots, M\} \to \mathcal{X}^n$，
   生成码字 $x^n(1), x^n(2), \ldots, x^n(M)$。
   所有码字的集合称为$\underline{码簿\ (codebook)}$。
3. 译码函数 $g : \mathcal{Y}^n \to \{1, 2, \ldots, M\}$

定义 6.5. (M,n) 码的$\underline{码率\ (rate)}$ R 定义为：

$$R := \frac{\log M}{n} \textit{bits/transmission} \tag{6.5}$$

码率描述的是每次通信所传输的信息量，单位是“比特/传输”，或“比特/信道使用次数”。当码率越高时，信息传递的速率越高效。

定义 6.6. 通信系统的$\underline{错误率}$ [1] 是发送信息与接收信息不相同的概率

$$P_e^{(n)} := Pr\{\hat{B}^m \neq B^m\} \tag{6.8}$$

定义 6.7. 如果存在一个使用 $(\lceil 2^{nR} \rceil, n)$ 码的通信系统，当错误率在信道使用次数 $n \to \infty$ 时趋于 *0*，即

$$P_e^{(n)} \xrightarrow{n\to\infty} 0 \tag{6.9}$$

称码率 R 是$\underline{可达码率\ (achievable\ rate)}$。

可达码率可以理解为，当通信系统使用这种码率通信时，都可以实现错误率趋于 0 的可靠通信。

[1] 此处我们对错误率的定义实际上是平均错误率，即

$$\begin{aligned} P_e^{(n)} &:= Pr\{\hat{B}^m \neq B^m\} \\ &= \sum_{b^m \in \mathcal{B}^m} Pr(B^m = b^m) Pr\{\hat{B}^m \neq B^m | B^m = b^m\} \end{aligned} \tag{6.6}$$

在有些教材中使用的是更严格的最大错误率，即

$$P_e^{(n)} = \max_{b^m \in \mathcal{B}^m} Pr\{\hat{B}^m \neq B^m | B^m = b^m\} \tag{6.7}$$

信道编码正定理对于两种定义都是成立的。

定义 6.8. 信道容量（*channel capacity*）是可达码率的上确界，即

$$C := sup\{R|R\ is\ achievable\} \tag{6.10}$$

信道容量可以理解为**可靠通信的最大码率**。

对于离散无记忆信道而言，由式 6.4我们发现了离散无记忆信道的 n 次拓展的传输实际上是 n 次独立的单字符传输。那对于离散无记忆信道的信息传输问题，我们只需要关注每个字符的传输 $(\mathcal{X}, p(y|x), \mathcal{Y})$ 就好。此时，发送的是随机变量 X，经过有噪声的信道，接收的是随机变量 Y。其中正确接收到 X 中的信息则为 $I(X;Y)$，即 Y 中所含有的 X 中的信息量。当我们调整对 B^m 的编码 X，就会改变 X 的分布。通过这样，就可以选择一个 $p(x)$ 使得 $I(X;Y)$ 最大，也就是信息传递的准确率最高（或误差最小）。那么我就可以从另一个角度定义信道容量，即

$$C^{(I)} := \max_{p(x)} I(X;Y) \tag{6.11}$$

也就是**在所有可能的输入分布下，信息传递误差最小时，每次传输收到的正确信息量**。这种信道容量的定义将信道的可靠传输信息量与互信息联系起来，使得计算信道容量的问题变成了一个通过寻找输入分布使互信息最大化的清晰的优化问题。我们将在本章证明，对于离散无记忆信道 $C^{(I)} = C$。

6.3 信道容量的例子

1. 二元对称信道的信道容量（binary symmetric channel，BSC）

二元对称信道是有误差信道的最简单模型，它表示每个输入字符都可能以 p 的概率被误传，这个例子可以反映出有误差信道问题的复杂度的普遍特点。假设输入字母表和输出字母表 $\mathcal{X} = \mathcal{Y} = \{0, 1\}$，二元对称信道的概率质量函数为：

$$p(y|x) = \begin{cases} p & y \neq x \\ 1-p & y = x \end{cases} \tag{6.12}$$

这个信道转移函数 $p(y|x)$ 等价于概率转移矩阵

$$p(y|x) = \begin{bmatrix} 1-p & p \\ p & 1-p \end{bmatrix} \tag{6.13}$$

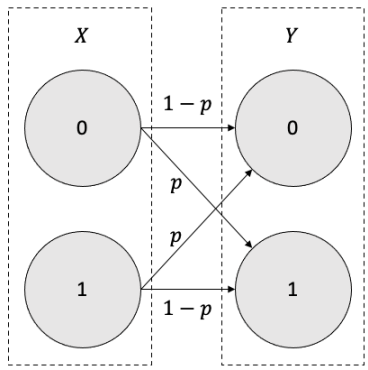

图 6.3: 二元对称信道

它的定义与之前马尔可夫链的转移矩阵的定义是相似的，即每一行对应输入的字母表，每一列对应输出的字母表。它的图示表示如图 6.3。为了得到二元对称信道的信道容量，根据公式 6.11中的定义，我们需要找到互信息的最大值。

$$
\begin{aligned}
I(X;Y) &= H(Y) - H(Y|X) \\
&= H(Y) - \sum_{x\in\mathcal{X}} p(x) H(Y|X=x) \\
&= H(Y) - \sum_{x\in\mathcal{X}} p(x) \sum_{y\in\mathcal{Y}} p(y|x)\log p(y|x) \\
&= H(Y) - \sum_{x\in\mathcal{X}} p(x)(-p\log p - (1-p)\log(1-p)) \\
h_2(p) := H(Ber(p))\text{有} &= H(Y) - \sum_{x\in\mathcal{X}} p(x) h_2(p) \\
&= H(Y) - h_2(p) \\
\text{由}H(Y)\le 1\text{有} &\le 1 - h_2(p)
\end{aligned}
\tag{6.14}
$$

最后的不等式取等条件为输出 Y 是均匀分布的。在二元对称信道中，输出的分布完全取决于输入的分布，即 $\pi(Y) = \pi(X)p(Y|X)$。因此当且仅当 X 是均匀分布时，Y 是均匀分布，不等式取等。由此，可以得到二元对称信道的信道容量 $C^{(I)} = 1 - h_2(p)$，当输入是均匀分布时达到。

2. 二元擦除信道的信道容量（binary erasure channel，BEC）

假设输入字母表为 $\mathcal{X} = \{0,1\}$，输出字母表为 $\mathcal{Y} = \{0,1,e\}$，其中 e 表

示被擦除。任何的输入 X 都有 $1-\alpha$ 的概率被正确传输，有 α 的概率被擦除掉，而且接收者可以观测到这个输入被擦除了（即接收者观测到输出 e）。从图 6.4中我们可以看到二元擦除信道的两个输入可能和全部三个输入可能。二元擦除信道的信道容量

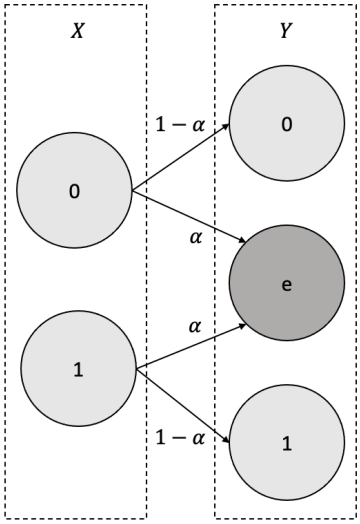

图 6.4: 二元擦除信道

$$
\begin{aligned}
I(X;Y) &= H(Y) - H(Y|X) \\
\text{与公式6.14中相似地} &= H(Y) - h_2(\alpha) \qquad (6.15)
\end{aligned}
$$

但此时 $H(Y)$ 的最大值已不能取得 $\log_2 3$，因为无论 $p(x)$ 是什么样的分布，Y 可能都达不到均匀分布。那么就只能计算 $H(Y)$ 可以达到的最大值。

$$
\begin{aligned}
H(Y) =& -p(Y=0)\log p(Y=0) - p(Y=1)\log p(Y=1) \\
& - p(Y=e)\log p(Y=e) \\
\text{前两项概率相等} \leq& -(1-p(Y=e))\log\frac{1-p(Y=e)}{2} \\
& - p(Y=e)\log p(Y=e) \qquad (6.16) \\
=& -(1-p(Y=e))\log(1-p(Y=e)) + (1-p(Y=e)) \\
& - p(Y=e)\log p(Y=e) \\
\text{二元擦除信道定义} =& h_2(\alpha) + (1-\alpha) \qquad (6.17)
\end{aligned}
$$

公式 6.16的取等条件为 $p(Y=0)=p(Y=1)$，即 $p(X=0)=p(X=1)$。因此有二元擦除信道的信道容量 $C^{(I)}=h_2(\alpha)+(1-\alpha)-h_2(\alpha)=(1-\alpha)$，当输入是均匀分布时达到。考虑这样的情形，当观测到 e 发生后，让发射器重新发送这个字符，这样平均每个字符的传输速率就是 $1-\alpha$。

在以上的两个例子中可以看出，使用如公式 6.11的定义，可以通过优化输入与输出间的互信息，很好地计算出信道容量 $C^{(I)}$。在本章接下来的内容中，我们将证明两种信道容量的定义是等价的，即 $C=C^{(n)}$，但首先需要引入联合典型序列的概念。

6.4 联合渐近均分性（joint AEP）

定义 6.9. 联合典型序列（*jointly ϵ-typical sequence*）是指由服从 $p(x,y)$ 的 *i.i.d.* 随机变量对 (X,Y) 所组成的长为 n 的序列 (x^n,y^n) 且其经验熵与真实熵 ϵ 接近。所有联合典型序列所构成的集合为

$$\begin{aligned}A_\epsilon^{(n)}(X,Y)=\{(x^n,y^n)\in\mathcal{X}^n\times\mathcal{Y}^n:&|-\frac{1}{n}\log p(x^n)-H(X)|<\epsilon,\\&|-\frac{1}{n}\log p(y^n)-H(Y)|<\epsilon,\\&|-\frac{1}{n}\log p(x^n,y^n)-H(X,Y)|<\epsilon\}\end{aligned}\tag{6.18}$$

由于随便变量对 (X_i,Y_i) 间为 i.i.d.，那么有 X_i 间是 i.i.d. 的，Y_i 间也是 i.i.d. 的。因为假设 (X_i,Y_i) 与 (X_j,Y_j) 间相互独立，那么有

$$\begin{aligned}p(x_i,x_j)&=\sum_{y_i}\sum_{y_j}p(x_i,y_i,x_j,y_j)\\&=\sum_{y_i}\sum_{y_j}p(x_i,y_i)p(x_j,y_j)\\&=\sum_{y_i}p(x_i,y_i)\sum_{y_j}p(x_j,y_j)\\&=p(x_i)p(x_j)\end{aligned}\tag{6.19}$$

同理也有 $p(y_i, y_j) = p(y_i)p(y_j)$。因此，这些序列的概率有

$$p(x^n, y^n) = \prod_{i=1}^{n} p(x_i, y_i) \tag{6.20}$$

$$p(x^n) = \prod_{i=1}^{n} p(x_i) \tag{6.21}$$

$$p(y^n) = \prod_{i=1}^{n} p(y_i) \tag{6.22}$$

定理 6.10. （联合渐近均分性）假设 (X^n, Y^n) 是由 *i.i.d.* 的 (X_i, Y_i) 组成的长为 n 的随机变量序列，那么

1. 当 $n \to \infty$ 时，$Pr\{(X^n, Y^n) \in A_\epsilon^{(n)}(X, Y)\} \to 1$。
2. $(1-\epsilon)2^{n(H(X,Y)-\epsilon)} \leq |A_\epsilon^{(n)}(X, Y)| \leq 2^{n(H(X,Y)+\epsilon)}$，左边的不等号对 n 充分大时成立，右边不等号对任意 n 成立。
3. 如果随机变量序列 $(\tilde{X}^n, \tilde{Y}^n)$ 中 $\tilde{X}^n$ 与 $\tilde{Y}^n$ 相互独立，且它们的分布 $p(x^n)p(y^n)$ 中的 $p(x^n)$ 与 $p(y^n)$ 与 X^n 和 Y^n 的边际分布相同，那么

$$Pr\{(\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)}(X, Y)\} \leq 2^{-n(I(X;Y)-3\epsilon)} \tag{6.23}$$

而且当 n 充分大时有，

$$Pr\{(\tilde{X}^n, \tilde{Y}^n) \in A_\epsilon^{(n)}(X, Y)\} \geq (1-\epsilon)2^{-n(I(X;Y)+3\epsilon)} \tag{6.24}$$

证明. 1. 由于 X_i 之间是 i.i.d.，根据定理 3.5典型集覆盖几乎所有概率，于是 $\forall\epsilon > 0$，$\forall\delta > 0$，存在 N_1，对于所有 $n \geq N_1$，有

$$Pr\{|-\frac{1}{n}\log p(X^n) - H(X)| < \epsilon\} > 1 - \frac{\delta}{3} \tag{6.25}$$

同理，由于 Y_i 之间也是 i.i.d.，存在 N_2，对于所有 $n \geq N_2$，有

$$Pr\{|-\frac{1}{n}\log p(Y^n) - H(Y)| < \epsilon\} > 1 - \frac{\delta}{3} \tag{6.26}$$

同样的 (X_i, Y_i) 之间也是 i.i.d. 的，存在 N_3，对于所有 $n \geq N_3$，有

$$Pr\{|-\frac{1}{n}\log p((X^n, Y^n)) - H(X, Y)| < \epsilon\} > 1 - \frac{\delta}{3} \tag{6.27}$$

这三个集合的交集发生的概率，大于 $1-\delta$，因为交集发生的概率大于等于它们补集都是互斥的情况。因此当 $n \to \infty$ 时，$Pr\{(X^n, Y^n) \in A_\epsilon^{(n)}(X, Y)\} \to 1$。

2. 使用于定理 3.6相似的证明方法，

$$
\begin{aligned}
1 &= \sum_{(x^n,y^n)\in\mathcal{X}^n\times\mathcal{Y}^n} p(x^n,y^n) \\
&\geq \sum_{(x^n,y^n)\in A_\epsilon^{(n)}(X,Y)} p(x^n,y^n) \\
&\geq 2^{-n(H(X,Y)+\epsilon)}|A_\epsilon^{(n)}(X,Y)|
\end{aligned} \tag{6.28}
$$

因此，$|A_\epsilon^{(n)}| \leq 2^{n(H(X,Y)+\epsilon)}$。同样地，当 n 充分大时，

$$
\begin{aligned}
1-\epsilon &\leq \sum_{(x^n,y^n)\in A_\epsilon^{(n)}(X,Y)} p(x^n,y^n) \\
&\leq 2^{-n(H(X,Y)-\epsilon)}|A_\epsilon^{(n)}(X,Y)|
\end{aligned} \tag{6.29}
$$

因此，$|A_\epsilon^{(n)}(X,Y)| \geq (1-\epsilon)2^{n(H(X,Y)-\epsilon)}$。

3. 对于任意的 n 有

$$
\begin{aligned}
& Pr\{(\tilde{X}^n,\tilde{Y}^n)\in A_\epsilon^{(n)}(X,Y)\} \\
&= \sum_{(x^n,y^n)\in A_\epsilon^{(n)}(X,Y)} p(x^n,y^n) \\
\tilde{X}^n\text{与}\tilde{Y}^n\text{独立} &= \sum_{(x^n,y^n)\in A_\epsilon^{(n)}(X,Y)} p(x^n)p(y^n) \\
\text{边际分布相同} &\leq 2^{n(H(X,Y)+\epsilon)}2^{-n(H(X)-\epsilon)}2^{-n(H(Y)-\epsilon)} \\
&= 2^{n((H(X,Y)-H(X)-H(Y))+3\epsilon)} \\
&= 2^{-n((I(X;Y)-3\epsilon)}
\end{aligned} \tag{6.30}
$$

当 n 充分大时有

$$
\begin{aligned}
& Pr\{(\tilde{X}^n,\tilde{Y}^n)\in A_\epsilon^{(n)}(X,Y)\} \\
&= \sum_{(x^n,y^n)\in A_\epsilon^{(n)}(X,Y)} p(x^n)p(y^n) \\
&\geq (1-\epsilon)2^{n(H(X,Y)-\epsilon)}2^{-n(H(X)+\epsilon)}2^{-n(H(Y)+\epsilon)} \\
&= (1-\epsilon)2^{-n((I(X;Y)+3\epsilon)}
\end{aligned} \tag{6.31}
$$

□

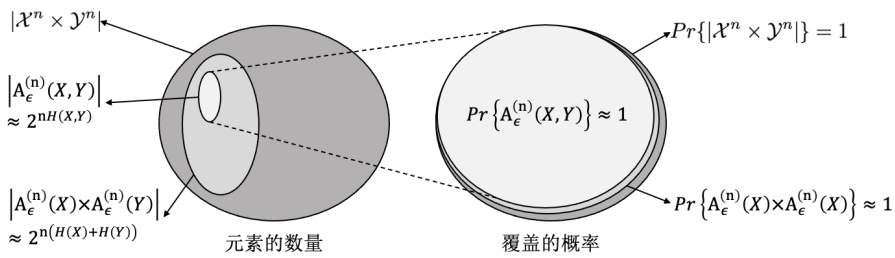

图 6.5: 联合典型序列集

在定理 6.10的第 3 点中，随机变量序列 $(\tilde{X}^n, \tilde{Y}^n)$ 中 $\tilde{X}^n$ 与 $\tilde{Y}^n$ 相互独立，但 $\tilde{X}_i$ 间并不一定相互独立，$\tilde{Y}_i$ 间并也不一定相互独立。i.i.d. 随机变量序列 X^n 的典型集 $A_\epsilon^{(n)}(X)$ 中含有约 $2^{nH(X)}$ 个元素，i.i.d. 随机变量序列 Y^n 的典型集 $A_\epsilon^{(n)}(Y)$ 中含有约 $2^{nH(Y)}$ 个元素，这两个典型集所能组成的集合约有 $2^{n(H(X)+H(Y))}$ 个元素。但这里面不是所有的元素都是联合典型序列，其中只有约 $2^{nH(X,Y)}$ 个元素属于联合典型序列集 $A_\epsilon^{(n)}(X,Y)$。这两个集合元素个数的比值为

$$\frac{|A_\epsilon^{(n)}(X,Y)|}{|A_\epsilon^{(n)}(X) \times A_\epsilon^{(n)}(Y)|} = \frac{2^{nH(X,Y)}}{2^{n(H(X)+H(Y))}} = 2^{-nI(X;Y)} \tag{6.32}$$

联合典型序列集的元素个数与概率关系如图 6.10所示。

回到刚刚的信道编码问题，由公式 6.20、6.21和 6.22可知，在联合典型序列中对 X^n 与 Y^n 的假设与离散无记忆信道中对 X^n 与 Y^n 的假设是一致的。因此对于离散无记忆信道，任取一个输入输出对 (x^n, y^n)，它属于联合典型序列集 $A_\epsilon^{(n)}(X,Y)$ 的概率趋于 1，即

$$Pr\{(X^n, Y^n) \in A_\epsilon^{(n)}(X,Y)\} \to 1 \tag{6.33}$$

如果再随机取另一个输入输出对 $(\hat{x}^n, \hat{y}^n)$，将这次写做另一个随机变量对 $(\hat{X}^n, \hat{Y}^n)$，也有

$$Pr\{(\hat{X}^n, \hat{Y}^n) \in A_\epsilon^{(n)}(X,Y)\} \to 1 \tag{6.34}$$

由于这两次取序列是从同一分布下（可以假设序列抽样的方法都是均匀抽样）的独立抽样，那么 (X^n, Y^n) 与 $(\hat{X}^n, \hat{Y}^n)$ 是 i.i.d. 的。考虑随机变量对 $(\hat{X}^n, Y^n)$，即在离散无记忆信道中输入为 $\hat{x}^n$ 而输出却是 y^n，也就是发生了传输错误，由于 (X^n, Y^n) 与 $(\hat{X}^n, \hat{Y}^n)$ 是 i.i.d. 的，有 $\hat{X}^n$ 与 Y^n 是独立

的，且 $\hat{X}^n$ 与 (X^n, Y^n) 对 X^n 的边际分布相同。那么 $(\hat{X}^n, Y^n)$ 就符合定理 6.10中第 3 点的假设。因此，有

$$Pr\{(\hat{X}^n, Y^n) \in A_\epsilon^{(n)}(X,Y)\} \leq 2^{-n(I(X;Y)-3\epsilon)} \tag{6.35}$$

是一个很小的概率。也就是说对于一个充分长的离散无记忆信道，随机抽取一个输入输出对 (x^n, y^n)，它属于联合典型序列集的概率趋于 1，即输入是 x^n 输出是 y^n 的概率趋于 1，或说正确传输的概率趋于 1；但如果输入是针对另一个信源的编码 $\hat{x}^n$，经过噪声信道后却得到 y^n 这样的输出，这个事件只能以很小的概率属于联合典型序列集，且发生概率趋于 0。这一重要结论就是信道编码定理的证明思路。

信道编码定理是在信源在信源字母表上服从均匀分布的条件下证明的，尤其是信道编码定理的逆定理部分。其原因之一是在定义码率的时候，就是按照信源是均匀分布的假设下定义的。

6.5 信道编码定理

定理 6.11. （信道编码定理）*对于离散无记忆信道，小于信道容量 $C^{(I)}$ 的所有码率都是可达的。具体来说，$\forall R < C^{(I)}$，存在一个 $(\lceil 2^{nR} \rceil, n)$ 码序列，它的错误率 $P_e^{(n)} \xrightarrow{n\to\infty} 0$。*
反之，任何满足 $P_e^{(n)} \xrightarrow{n\to\infty} 0$ 的 $(\lceil 2^{nR} \rceil, n)$ 码序列必定有 $R \leq C^{(I)}$。

证明. 假设离散无记忆信道输入 $\{X_i\}$ 的分布为 $X_i \sim p(x)$，对于任意的 $\epsilon > 0$ 和 $R < I(X;Y) - 3\epsilon$，如果存在一个 $(\lceil 2^{nR} \rceil, n)$ 码，且它的错误率 $P_e^{(n)} \xrightarrow{n\to\infty} 0$，则可证明该定理的正向过程。

首先构造这样的一个 $(\lceil 2^{nR} \rceil, n)$ 码，在编码上，用独立同分布的方式选择 M 个随机变量序列 $X^n(1), X^n(2), \ldots, X^n(M)$，每个随机变量序列 $X^n(j) \sim X^n$，其中 j 为随机变量序列 $X^n(j)$ 所对应的信源。由渐近均分性可知，当 $n \to \infty$，$X^n(j)$ 将以概率 1 属于典型集 $A_\epsilon^{(n)}$。

在解码上，当收到的 Y^n 与 $X^n(j)$ 是联合典型的，并且 Y^n 与其他任何 $X^n(k), \forall k \neq j$ 不是联合典型的，则认为是传输正确，即 $\hat{B}^m = j$；其他情况，也就是找不到与 Y^n 联合典型的序列或有不止一个联合典型序列，都认为是在传输过程中出现了错误，此时给一个标志错误的解码，即 $\hat{B}^m = e$（就像二元擦除信道一样）。这种解码器称为联合典型解码器

(joint typicality decoder)。即

$$\hat{B}^m = \begin{cases} j, & \text{if } (X^n(j), Y^n) \in A_\epsilon^{(n)}(X,Y) \\ & \text{and } (X^n(k), Y^n) \notin A_\epsilon^{(n)}(X,Y), \forall k \neq j \\ e, & \text{o.w.} \end{cases} \tag{6.36}$$

用这个 $(\lceil 2^{nR} \rceil, n)$ 码时，错误率为

$$\begin{aligned} P_e^{(n)} &= Pr\{\hat{B}^m \neq B^m\} \\ &= \sum_{j=1}^{M} Pr\{\hat{B}^m \neq B^m | B^m = j\} Pr\{B^m = j\} \\ \text{信源均匀分布} &= \sum_{j=1}^{M} \frac{1}{M} Pr\{\hat{B}^m \neq B^m | B^m = j\} \\ \text{编码 i.i.d.} &= Pr\{\hat{B}^m \neq B^m | B^m = j\} \end{aligned} \tag{6.37}$$

这里 $Pr\{\hat{B}^m \neq B^m | B^m = j\}$ 为发送的信源是 j 但接收的不是 j 的概率，它包括：1）发送的是 j 但接收的 Y^n 与 $X^n(j)$ 不是联合典型；2）发送的是 j 但接收的 Y^n 与 $X^n(k)$，$k \neq j$ 是联合典型；这两种非互斥的情况。于是有

$$\begin{aligned} & Pr\{\hat{B}^m \neq B^m | B^m = j\} \\ \leq & Pr\{(X^n(j), Y^n) \notin A_\epsilon^{(n)}(X,Y) | B^m = j\} \\ & + \sum_{k=1, k\neq j}^{M} Pr\{(X^n(k), Y^n) \in A_\epsilon^{(n)}(X,Y) | B^m = j\} \\ \text{编码 i.i.d.} = & Pr\{(X^n(1), Y^n) \notin A_\epsilon^{(n)}(X,Y) | B^m = 1\} \\ & + \sum_{k=2}^{M} Pr\{(X^n(k), Y^n) \in A_\epsilon^{(n)}(X,Y) | B^m = 1\} \\ X^n(1) \sim X^n = & Pr\{(X^n, Y^n) \notin A_\epsilon^{(n)}(X,Y)\} \\ \text{见公式6.35} \quad & + (M-1) Pr\{(\hat{X}^n, Y^n) \in A_\epsilon^{(n)}(X,Y)\} \\ \leq & 2^{-n(H(X,Y)-\epsilon)} + (\lceil 2^{nR} \rceil - 1) \times 2^{-n(I(X;Y)-3\epsilon)} \\ < & 2^{-n(H(X,Y)-\epsilon)} + (2^{nR} + 1 - 1) \times 2^{-n(I(X;Y)-3\epsilon)} \\ R < I(X;Y) - 3\epsilon = & 2^{-n(H(X,Y)-\epsilon)} + 2^{-n(I(X;Y)-3\epsilon-R)} \xrightarrow{n\to\infty} 0 \end{aligned} \tag{6.38}$$

因此，

$$P_e^{(n)} = Pr\{\hat{B}^m \neq B^m | B^m = j\} \xrightarrow{n\to\infty} 0 \tag{6.39}$$

以上，证明了当使用独立同分布选择编码，使用联合典型判断解码，对于任意小于 $C^{(I)}$ 的码率 R，都是可达的。定理的”反之“部分，将在引入费诺不等式后给出证明。 □

定理 6.12. （费诺不等式（*Fano's Inequality*））如果 X 是离散随机变量，$\hat{X} = \hat{X}(Y)$ 是一个根据另一离散随机变量 Y 对 X 的猜测，猜测的错误率 $P_e = Pr\{X \neq \hat{X}\}$。那么有

$$H(X|Y) \leq h_2(P_e) + P_e \log(|\mathcal{X}| - 1) \tag{6.40}$$

其中，$h_2(P_e)$ 是二元伯努利分布 $Ber(P_e)$ 的熵。

证明. 假设随机变量 $V = 1_{X \neq \hat{X}}$，即若 $X \neq \hat{X}$，$V = 1$；若 $X = \hat{X}$，$V = 0$。

$$\begin{aligned}
H(X|Y) \leq & H(X, V|Y) \\
= & H(V|Y) + H(X|V, Y) \\
\text{条件作用熵变小} \leq & H(V) + H(X|V, Y) \\
= & H(V) + \sum_{v,y} P(V = v, Y = y) H(X|V = v, Y = y) \\
= & H(V) + \sum_{y} P(V = 0, Y = y) H(X|V = 0, Y = y) \\
& + \sum_{y} P(V = 1, Y = y) H(X|V = 1, Y = y) \\
\text{见下文} = & H(V) + \sum_{y} P(V = 1, Y = y) H(X|V = 1, Y = y)
\end{aligned} \tag{6.41}$$

$$\begin{aligned}
\text{最大熵分布} \leq & H(V) + \log(|\mathcal{X}| - 1) \sum_{y} P(V = 1, Y = y) \\
= & H(V) + \log(|\mathcal{X}| - 1) P(V = 1) \\
= & h_2(P_e) + P_e \log(|\mathcal{X}| - 1)
\end{aligned} \tag{6.42}$$

等式 6.41是由于 $V = 0$，即 $X = \hat{X} = \hat{X}(Y)$。也就是说 X 是 Y 的函数，当 Y 确定后 X 唯一确定，那么 $H(X|V = 0, Y = y)$ 中，$Y = y$ 唯一确定，此时 X 也就唯一确定了，因此 $H(X|V = 0, Y = y) = 0$。 □

费诺不等式有一个更松一点的版本，

$$H(X|Y) \leq 1 + P_e \log(|\mathcal{X}|) \tag{6.43}$$

或等价地

$$P_e \geq \frac{H(X|Y)-1}{\log(|\mathcal{X}|)} \tag{6.44}$$

之后会被用于信源编码定理逆向的证明。费诺不等式可以理解为**如果已知 Y 后，X 仍很不确定，那么任何基于 Y 来对 X 去做的估计，都会有一定的误差**。

现在我们继续证明信道编码定理的逆向过程。

证明. 对任意的 $(\lceil 2^{nR}\rceil, n)$ 码有

$$\begin{aligned}
\log\lceil 2^{nR}\rceil - H(B^m|Y^n) &< \log 2^{nR} - 1 - H(B^m|Y^n) \\
\text{信源均匀分布} &= H(B^m) - H(B^m|Y^n) - 1 \\
&= I(B^m;Y^n) - 1 \\
&= H(Y^n) - H(Y^n|B^m) - 1 \\
\text{条件熵链式法则} &= \sum_{i=1}^{n}(H(Y_i|Y^{i-1}) - H(Y_i|Y^{i-1},B^m)) - 1 \\
\text{条件使熵变小} &\leq \sum_{i=1}^{n}(H(Y_i) - H(Y_i|Y^{i-1},B^m)) - 1 \\
\text{条件使熵变小} &\leq \sum_{i=1}^{n}(H(Y_i) - H(Y_i|Y^{i-1},X_i,B^m)) - 1 \\
\text{离散无记忆} &= \sum_{i=1}^{n}(H(Y_i) - H(Y_i|X_i)) - 1 \\
&= \sum_{i=1}^{n} I(X_i;Y_i) - 1 \\
&\leq nC^{(I)} - 1
\end{aligned} \tag{6.45}$$

那么，若其码率 $\frac{\log\lceil 2^{nR}\rceil}{n} > C^{(I)}$，由 Fano 不等式有

$$
\begin{aligned}
P_e &\geq \frac{H(B^m|\hat{B}^m)-1}{\log\lceil 2^{nR}\rceil} \\
Y^n\text{与}\hat{B}^m\text{是 1-1 映射} &= \frac{H(B^m|Y^n)-1}{\log\lceil 2^{nR}\rceil} \\
&> \frac{\log\lceil 2^{nR}\rceil - nC^{(I)} + 1 - 1}{\log\lceil 2^{nR}\rceil} \\
&= 1 - \frac{nC^{(I)}}{\log\lceil 2^{nR}\rceil} \\
&> 1 - \frac{nC^{(I)}}{nR-1} \\
&= 1 - \frac{C^{(I)}}{R-1/n} \\
&\xrightarrow{n\to\infty} 1 - \frac{C^{(I)}}{R} \\
&> 0
\end{aligned}
\tag{6.46}
$$

即对任意码率大于 $C^{(I)}$ 的 $(\lceil 2^{nR}\rceil, n)$ 码，其错误率都无法趋于 0。 □

信道编码定理对正向过程的证明中的 $(\lceil 2^{nR}\rceil, n)$ 码构造如图 6.6所示。编码器将独立同分布的编码赋予每个信源，我们假设 $x^n(j)$ 是信源 j 的编码。对于解码器，如果收到的编码 y^n 与 $x^n(j)$ 为联合典型序列且 y^n 与其他信源 k 编码 $x^n(k)$ 都不为联合典型序列，则认为 y^n 是 j 正确传输后的码，并将其解码为 j；如果收到的编码 y^n 与 $x^n(j)$ 不为联合典型序列或 y^n 与 $x^n(j)$、$x^n(k)$ 同为联合典型序列，则认为 y^n 发生了传输错误，将其解码为 e。使用这种编解码方式，我们证明了其误差率趋于 0。主要因为 y^n 与 $x^n(j)$ 为联合典型序列的概率趋于 1，而 y^n 与 $x^n(k)$ 为联合典型序列的概率趋于 0，即图中“解码器认为解码正确”的半月形浅色区域发生的概率趋于 1。

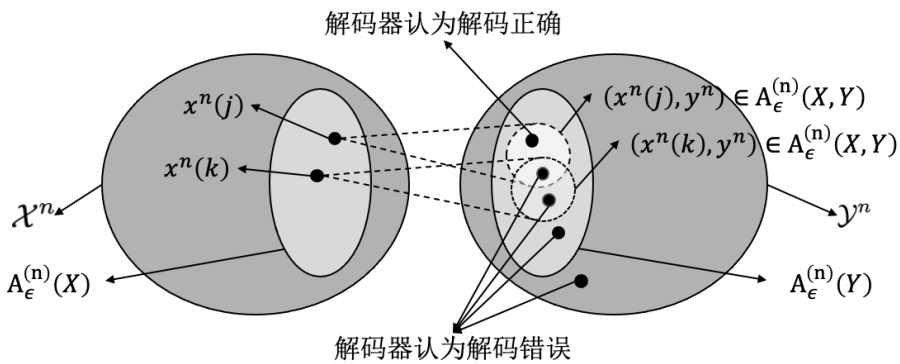

图 6.6: 信道编码定理正向证明 $(\lceil 2^{nR} \rceil, n)$ 码构造

7 微分熵与高斯信道

7.1 微分熵（differential entropy）

微分熵是连续随机变量的熵，它在许多方面与离散随机变量的熵相似，但仍存在一些差别。

定义 7.1. 若随机变量 X 的概率密度函数为 $f(x)$，使 $f(x) > 0$ 的所有 x 构成的集合称为 X 的支撑集（*support set*）。

定义 7.2. 概率密度为 $f(x)$ 的随机变量 X 的微分熵（*differential entropy*）$h(X)$ 定义为

$$h(X) = -\int_S f(x) \log f(x) dx \tag{7.1}$$

其中 S 是 X 的支撑集。

和离散随机变量的熵一样，微分熵只依赖于随机变量的分布（概率密度函数）。

当随机变量 X 在 $[0, a]$ 上均匀分布，它的微分熵是

$$h(X) = -\int_0^a \frac{1}{a} \log \frac{1}{a} dx = \log a \tag{7.2}$$

当 $a < 1$ 时，$h(X) = \log a < 0$，因此微分熵可以为负数。

当随机变量 X 服从均值为 0，方差为 σ^2 的正态分布，若以奈特为单位，它的微分熵是

$$
\begin{aligned}
h(X) &= -\int \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} \ln \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} dx \\
&= -\int \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} (-\frac{x^2}{2\sigma^2} - \ln \sigma\sqrt{2\pi}) dx \\
&= \int \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} (\frac{x^2}{2\sigma^2}) dx + \int \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} (\ln \sigma\sqrt{2\pi}) dx \\
&= \frac{E[X^2]}{2\sigma^2} + \frac{1}{2} \ln 2\pi\sigma^2 \\
&= \frac{1}{2} + \frac{1}{2} \ln 2\pi\sigma^2 \\
&= \frac{1}{2} \ln 2\pi e\sigma^2
\end{aligned} \tag{7.3}
$$

若以比特为单位

$$
h(X) = \frac{1}{2} \log 2\pi e\sigma^2 \tag{7.4}
$$

7.2 微分熵与离散熵的关系

连续随机变量 X 的概率密度函数是 $f(x)$，若将 X 的定义域分割为长为 Δ 的若干小区间，并假定 $f(x)$ 在每个小区间内是连续的。由中值定理可知，在每个小区间内存在一个值 x_i 使得

$$
f(x_i)\Delta = \int_{i\Delta}^{(i+1)\Delta} f(x)dx \tag{7.5}
$$

这样，我们重新定义一个离散变量 X^Δ，

$$
X^\Delta = x_i,\ i\Delta \le X < (i+1)\Delta \tag{7.6}
$$

离散随机变量 $X^\Delta = x_i$ 的概率质量函数为

$$
p_i = \int_{i\Delta}^{(i+1)\Delta} f(x)dx = f(x_i)\Delta \tag{7.7}
$$

由于 $\sum f(x_i)\Delta = \int f(x) = 1$，因此 X^Δ 的熵为

$$\begin{aligned}
H(X^\Delta) &= -\sum_{-\infty}^{\infty} p_i \log p_i \\
&= -\sum_{-\infty}^{\infty} f(x_i)\Delta \log f(x_i)\Delta \\
&= -\sum_{-\infty}^{\infty} f(x_i)\Delta \log f(x_i) - \sum_{-\infty}^{\infty} f(x_i)\Delta \log \Delta \\
&= -\sum_{-\infty}^{\infty} f(x_i)\Delta \log f(x_i) - \log \Delta \\
&\xrightarrow{\Delta\to 0} h(X) - \log \Delta
\end{aligned} \tag{7.8}$$

若取 $\Delta = \frac{1}{2^n}$，有

$$\begin{aligned}
H(X^\Delta) &\xrightarrow{\Delta\to 0} h(X) - \log \frac{1}{2^n} \\
&= h(X) + n
\end{aligned} \tag{7.9}$$

也就意味着，如果我们要用描述一个连续随机变量 X，如果描述的精度为 $\frac{1}{2^n}$，那么平均意义下需要 $h(X)+n$ 比特的信息。

例如，如果随机变量 X 在 $[0, \frac{1}{8}]$ 上是均匀分布的，那么理论上如果描述精度为 $\frac{1}{2^n}$，需要 $h(X)+n = n-3$ 比特的信息量。我们把 $[0, \frac{1}{8}]$ 上的小数用二进制表示，有 $.000\ldots$，即小数点后三位是 0，其余的位数则可以表示 $[0, \frac{1}{8}]$ 上所有的小数。那如果描述精度为 $\frac{1}{2^n}$，也就是表示到小数点后第 n 位，此时一共需要 $n-3$ 位的信息去描述，这与理论上是一致的。

7.3 联合微分熵与条件微分熵

定义 7.3. 联合概率密度函数为 $p(x_1, x_2, \ldots, x_n)$ 的一组随机变量 $X_1, X_2, \ldots, X_n$ 的<u>联合微分熵</u> 定义为

$$h(X_1, X_2, \ldots, X_n) = -\int f(x^n) \log f(x^n) dx^n \tag{7.10}$$

定义 7.4. 如果随机变量 X 与 Y 的联合密度函数为 $f(x,y)$，定义条件微分熵 $h(Y|X)$ 为

$$h(Y|X) = -\int f(x,y) \log f(y|x) dx dy \tag{7.11}$$

由于 $f(y|x)=\frac{f(x,y)}{f(x)}$，所以

$$\begin{aligned}
h(Y|X) &= -\int f(x,y)\log f(y|x)dxdy \\
&= -\int f(x,y)\log\frac{f(x,y)}{f(x)}dxdy \\
&= -\int f(x,y)(\log f(x,y)-\log f(x))dxdy \\
&= h(X,Y)-h(X)
\end{aligned} \tag{7.12}$$

定理 7.5. （多元正态分布微分熵）设 $X_1,X_2,\ldots,X_n$ 服从均值为 μ，协方差为 K 的多元正态分布，记做 $N_n(\mu,K)$，则

$$h(X_1,X_2,\ldots,X_n)=h(N_n(\mu,K))=\frac{1}{2}\log(2\pi e)^n|K|\ bit \tag{7.13}$$

其中 $|K|$ 是 K 的行列式。

证明. 多元正态分布的概率密度函数为

$$f(\boldsymbol{x})=\frac{1}{(\sqrt{2\pi})^n|K|^{1/2}}e^{-\frac{1}{2}(\boldsymbol{x}-\mu)^TK^{-1}(\boldsymbol{x}-\mu)} \tag{7.14}$$

则

$$
\begin{aligned}
h(X^n) &= -\int f(\boldsymbol{x})[-\frac{1}{2}(\boldsymbol{x}-\mu)^T K^{-1}(\boldsymbol{x}-\mu) - \ln(\sqrt{2\pi})^n |K|^{1/2}]d\boldsymbol{x} \\
&= \frac{1}{2}E[\sum_{i,j}(X_i-\mu)^T(K^{-1})_{i,j}(X_j-\mu)] + \frac{1}{2}\ln(2\pi)^n|K| \\
&= \frac{1}{2}\sum_{i,j}E[(X_i-\mu)(K^{-1})_{i,j}(X_j-\mu)] + \frac{1}{2}\ln(2\pi)^n|K| \\
&= \frac{1}{2}\sum_{i,j}E[(X_i-\mu)(X_j-\mu)](K^{-1})_{i,j} + \frac{1}{2}\ln(2\pi)^n|K| \\
&= \frac{1}{2}\sum_{i,j}K_{i,j}(K^{-1})_{i,j} + \frac{1}{2}\ln(2\pi)^n|K| \\
&= \frac{1}{2}\sum_{i,j}I_{i,j} + \frac{1}{2}\ln(2\pi)^n|K| \\
&= \frac{n}{2} + \frac{1}{2}\ln(2\pi)^n|K| \\
&= \frac{1}{2}\ln(2\pi e)^n|K| \text{ 奈特} \\
&= \frac{1}{2}\log(2\pi e)^n|K| \text{ 比特}
\end{aligned}
\tag{7.15}
$$

□

7.4 相对熵与互信息

定义 7.6. 两个概率密度函数为 f 和 g 的相对熵 或K-L 散度$D(f||g)$ 定义为

$$D(f||g) = \int f \log \frac{f}{g} \tag{7.16}$$

只有当 f 的支撑集包含在 g 的支撑集中时，$D(f||g)$ 才不是无穷。

定义 7.7. 联合概率密度函数为 $f(x,y)$ 的两个随机变量的互信息$I(X;Y)$ 定义为

$$I(X;Y) = \int f(x,y)\log\frac{f(x,y)}{f(x)f(y)}dxdy \tag{7.17}$$

类似于离散随机变量的互信息，有

$$I(X;Y) = h(X) - h(X|Y) = h(Y) - h(Y|X) = h(X) + h(Y) - h(X,Y) \tag{7.18}$$

$$I(X;Y) = D(f(x,y)||f(x)f(y)) \tag{7.19}$$

如果像微分熵那样，对连续随机变量的互信息构造离散随机变量，那么有

$$\begin{aligned} I(X^\Delta;Y^\Delta) &= H(X^\Delta) - H(X^\Delta|Y^\Delta) \\ &\xrightarrow{\Delta\to 0} h(X) - \log\Delta - (h(X|Y) - \log\Delta) \\ &= h(X) - h(X|Y) \\ &= I(X;Y) \end{aligned} \tag{7.20}$$

即离散随机变量的互信息与连续随机变量的互信息在信息的度量上的意义是相同的。

例如，随机变量 (X,Y) 服从 $N(0,K)$，其中

$$K = \begin{bmatrix} \sigma^2 & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 \end{bmatrix} \tag{7.21}$$

那么，$h(X) = h(Y) = \frac{1}{2}\log(2\pi e\sigma^2)$，

$$\begin{aligned} h(X,Y) &= \frac{1}{2}\log((2\pi e)^2|K|) \\ &= \frac{1}{2}\log((2\pi e)^2\sigma^4(1-\rho^2)) \end{aligned} \tag{7.22}$$

$$I(X;Y) = h(X) + h(Y) - h(X,Y) = -\frac{1}{2}\log(1-\rho^2) \tag{7.23}$$

当 $\rho = 0$ 时，X 与 Y 互相独立，此时互信息为 0；当 $\rho = \pm 1$ 时，X 与 Y 完全相关，此时互信息无穷大。

7.5 微分熵、相对熵及互信息的性质

定理 7.8.

$$D(f||g) \geq 0 \tag{7.24}$$

当且仅当几乎处处（*almost everywhere*，*a.e.*）$f = g$ 等号成立。

证明. 设 S 为 f 的支撑集，

$$\begin{aligned}
-D(f||g) &= \int_S f \log \frac{g}{f} \\
\text{Jensen 不等式} &\leq \log \int_S f \frac{g}{f} \\
&= \log \int_S g \\
&\leq \log 1 = 0
\end{aligned} \tag{7.25}$$

当且仅当 Jensen 不等式中等号成立取等，即当且仅当 $f = g$ a.e. 等号成立。 □

推论 7.9. $I(X;Y) \geq 0$ 当且仅当 X 与 Y 相互独立，等号取等。

推论 7.10. $h(Y|X) \leq h(Y)$ 当且仅当 X 与 Y 相互独立，等号取等。

推论 7.11.

$$h(X_1, X_2, \ldots, X_n) = \sum_{i=1}^{n} h(X_i|X_1, X_2, \ldots, X_{i-1}) \tag{7.26}$$

推论 7.12.

$$h(X_1, X_2, \ldots, X_n) \leq \sum_{i=1}^{n} h(X_i) \tag{7.27}$$

定理 7.13. *(平移不改变微分熵)*

$$h(X + c) = h(X) \tag{7.28}$$

定理 7.14.

$$h(aX) = h(X) + \log |a| \tag{7.29}$$

证明. 另 $Y = aX$，$f_Y(y) = \frac{1}{|a|} f_X(\frac{y}{a})$，

$$\begin{aligned}
h(aX) &= -\int f_Y(y) \log f_Y(y) dy \\
&= -\int \frac{1}{|a|} f_X(\frac{y}{a}) \log \frac{1}{|a|} f_X(\frac{y}{a}) dy \\
&= -\int f_X(x) \log f_X(x) dx + \log |a| \\
&= h(X) + \log |a|
\end{aligned} \tag{7.30}$$

□

定理 7.15. (最大微分熵分布) 随机变量 $X \sim f_X$ 的均值为 0, 方差 $K \le \sigma^2$, 则 $h(X) \le \frac{1}{2}\log 2\pi e\sigma^2$, 当且仅当 $X \sim N(0,\sigma^2)$ 等号成立。

证明. 假设 $f_N := N(0,\sigma^2)$, $Y \sim f_N$

$$\begin{aligned}
0 \le D(f_X||f_N) &= \int f_X \log \frac{f_X}{f_N} dx \\
&= \int f_X \log f_X dx - \int f_X \log f_N dx \\
&= -h(X) - \int f_X \log f_N dx \\
&= -h(X) - \int f_X \log \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}} dx \\
&= -h(X) - \log \frac{1}{\sigma\sqrt{2\pi}} + \frac{E[X^2]}{2\sigma^2 \ln 2} \\
&\le -h(X) - \log \frac{1}{\sigma\sqrt{2\pi}} + \frac{E[Y^2]}{2\sigma^2 \ln 2} \\
&= -h(X) - \int f_N \log \frac{1}{\sigma\sqrt{2\pi}} dy + \int f_N \frac{y^2}{2\sigma^2 \ln 2} dy \\
&= -h(X) - \int f_N \log \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{y^2}{2\sigma^2}} dy \\
&= -h(X) + h(Y)
\end{aligned} \tag{7.31}$$

当且仅当 $f_X = f_N$ 时取等。 □

7.6 连续随机变量的渐近均分性

定理 7.16. 随机变量 $X_1, X_2, \ldots, X_n$ 为服从概率密度函数为 $f(x)$ 的独立同分布序列。有

$$-\frac{1}{n}\log f(X_1, X_2, \ldots, X_n) \to E[-\log f(X)] = h(X) \text{ 依概率} \tag{7.32}$$

定义 7.17. 对于任意 $\epsilon > 0$, 支撑集为 S 的 $f(x)$ 的典型集为

$$A_\epsilon^{(n)=\{(x_1,\ldots,x_n)\in S^n : |-\frac{1}{n}\log f(x_1,x_2,\ldots,x_n) - h(X)| \le \epsilon\}} \tag{7.33}$$

其中 $f(x_1, x_2, \ldots, x_n) = \prod_{i=1}^n f(x_i)$。

定义 7.18. 集合 $A \in \mathbb{R}^n$ 的体积 $Vol(A)$ 为

$$Vol(A) = \int_A dx_1 dx_2 \ldots dx_n \tag{7.34}$$

定理 7.19. 典型集 $A_\epsilon^{(n)}$ 有如下性质

1. 对于充分大的 n，$Pr(A_\epsilon^{(n)}) > 1-\epsilon$。
2. 对于所有的 n，$Vol(A_\epsilon^{(n)}) \le 2^{(nh(X)+\epsilon)}$。
3. 对于充分大的 n，$Vol(A_\epsilon^{(n)}) \ge (1-\epsilon)2^{(nh(X)-\epsilon)}$。

定理 7.20. 在所有概率大于等于 $1-\epsilon$ 的集合中，$A_\epsilon^{(n)}$ 是体积最小的。

7.7 高斯信道

定义 7.21. 加性高斯白噪声信道（*additive white gaussian noise channel, AWGN*）的输入为 X_i，输出为 $Y_i = X_i + Z_i$，其中 Z_i 是独立同分布服从 $\mathcal{N}(0,\sigma^2)$ 且独立于 X_i 的高斯白噪声。*AWGN* 在功率限制为 P 下的信道容量为

$$C^{(I)}(P) = \max_{f(x),E[X^2]\le P} I(X;Y) \tag{7.35}$$

如果 $\sigma^2 = 0$，即 X_i 与 Y_i 完全相关，那么 $I(X;Y) = \infty$（连续随机变量所含信息量为无穷），也就有信道容量为无穷大。如果 $\sigma^2 \ne 0$，但对 X_i 没有限制，这时 $\sigma^2 < \infty$，可以取 X_i 任意分散使得错误率趋于 0，同样也有信道容量为无穷大。因此，在讨论信道容量时，一般要求对输入信号的功率加以限制，$E[X^2] \le P$。这样的通信信道可以模拟许多实际的信道，比如无线电和卫星通讯。

定理 7.22. （高斯信道的信道容量）在功率限制为 P 下，方差为 σ^2 的高斯信道的信道容量为

$$C^{(I)}(P) = \frac{1}{2}\log(1+\frac{P}{\sigma^2}) \tag{7.36}$$

证明.

$$\begin{aligned} I(X;Y) &= h(Y) - h(Y|X) \\ &= h(Y) - h(X+Z|X) \\ &= h(Y) - h(Z|X) \\ &= h(Y) - h(Z) \end{aligned} \tag{7.37}$$

在给定

$$E[Y^2] = E[(X+Z)^2] = E[X^2] + E[Z^2] + 2E[X]E[Z] = P + \sigma^2 \tag{7.38}$$

的条件下，正态分布会使熵达到最大，那么

$$h(Y) \le \frac{1}{2}\log(2\pi e(P+\sigma^2)) \tag{7.39}$$

因此

$$\begin{aligned} I(X;Y) &\le \frac{1}{2}\log(2\pi e(P+\sigma^2)) - h(Z) \\ &= \frac{1}{2}\log(2\pi e(P+\sigma^2)) - \frac{1}{2}\log(2\pi e\sigma^2) \\ &= \frac{1}{2}\log(1+\frac{P}{\sigma^2}) \end{aligned} \tag{7.40}$$

即高斯信道的信道容量

$$C^{(I)}(P) = \max_{f(x), E[X^2]\le P} I(X;Y) = \frac{1}{2}\log(1+\frac{P}{\sigma^2}) \tag{7.41}$$

□

这里的 $\frac{P}{\sigma^2}$ 也经常被称为信噪比（signal-to-noise ratio，SNR）。

定理 7.23. （高斯信道的信道编码定理）在功率限制为 P 下，方差为 σ^2 的高斯信道的可达码率上确界为

$$C(P) = \frac{1}{2}\log(1+\frac{P}{\sigma^2}) \tag{7.42}$$

证明. 在此我们只给出证明的基本思路。

对于 AWGN 信道，对于任意一个长度为 n 的输入，它的每一位 X_i 的输出 $Y_i = X_i + \mathcal{N}(0,\sigma^2)$ 是以 $E[X_i]$ 为均值，以 σ^2 为方差的高斯分布。那么 Y_i 出现在 $[E[X_i]-\sqrt{n\sigma^2}, E[X_i]+\sqrt{n\sigma^2}]$ 这个区间的概率趋于 1。如果像离散随机变量的信道编码定理那样，取独立同分布的 $X_i, \forall i \le n$，则 Y^n 出现在以 $E[X^n]$ 为中心，以 $\sqrt{n\sigma^2}$ 为半径的 n 维球中的概率趋于 1，这个球的体积为 $V_n(r) = v_n r^n = v_n(n\sigma^2)^{\frac{n}{2}}$，其中 v_n 为一个常数。

对于一个 $(2^{nC(P)}, n)$ 码，如果给每一个输入 $x^n(m), \forall m \le nC(P)$ 一个半径为 $\sqrt{n\sigma^2}$ 的球且所有球不相交，那么他们对应的输出 $y^n(m)$ 以趋于 1

的概率出现在各自的球里，使错误率趋于 0。此时，所有球所需体积为

$$
\begin{aligned}
2^{nC(P)}V_n(r) &= 2^{nC(P)}v_n(n\sigma^2)^{\frac{n}{2}} \\
&= 2^{\frac{n}{2}\log(1+\frac{P}{\sigma^2})}v_n(n\sigma^2)^{\frac{n}{2}} \\
&= (1+\frac{P}{\sigma^2})^{\frac{n}{2}}v_n(n\sigma^2)^{\frac{n}{2}} \\
&= v_n(n(\sigma^2+P))^{\frac{n}{2}}
\end{aligned} \tag{7.43}
$$

由于输入功率不大于 P，即 $E[X^2] \leq P$，$E[Y^2] \leq P+\sigma^2$。因为 $Y^n(m)$ 是独立同分布的，因此 $\frac{1}{n}\sum_{i=1}^{n}(y_i)^2 \to E[Y^2]$，因此 Y 被限制在一个半径为 $\sqrt{n(P+\sigma^2)}$ 的 n 维球中，该球恰可包含 $2^{nC(P)}$ 个小球，使错误率趋于 0。 □

8 有损压缩与率失真理论

在第五章中，我们讨论了无损压缩，即编码可以覆盖随机变量的所有取值，在解码的时候只需要使用与编码一一对应的取值就能毫无错误地复原压缩之前的信源。在第六章中，我们讨论了通信问题，即信息在无损编码后，在发送过程中可能出现错误，在解码时采用与编码一一对应的取值进行解码，会发生有时解码出现错误，使得通信速率下降的现象。在本章中，将讨论有损压缩，即我们有意只对部分取值进行编码，通过合适的解码，使得解码之后的信息并不会失真太多。有损压缩与无损压缩和通信问题有一定的区别，由于有损压缩的编码是非奇异的，那么在解码的时候就不再采用一一对应的解码方式，一个解码可能会与多个编码相对应，而且解码字母表也不一定等同于编码字母表。

比如，当我们需要对任意实数编码时，由于实数有无穷的小数位，就需要无穷比特，就无法做到使用奇异码来编码。进一步，对于连续随机变量，取值空间是连续的，所以对连续随机变量进行编码的时候，有限比特一定无法正确编码。那如果需要对连续随机变量进行编码，我们只能找一个有限比特的编码，使其“足够准确”。也就是说，对连续随机变量进行编码，我们只能做有损压缩。那如何使编码损失尽可能小的时候还使编码尽可能短？本章将引入失真度量的概念，用以衡量随机变量与其编码之间的距离。基于失真度量来讨论，在需要满足一定失真限制的时候，最短的编码是多长？同样的，在给定的编码长度下，可以达到最小的失真是多少？

先来看一个例子，假设 X 是服从 $\mathcal{N}(0,\sigma^2)$ 的随机变量，如图 8.1所示，如果我们想用一个长为 1bit 的码来表示 X，我们可以简单的把 X 分成 $X<0$ 和 $X\geq 0$ 两个区间，然后分别用两个值 x_1 和 x_2 来编码这两个区间。这时我们所表征的 X 其实是

$$\hat{X}(x)=\begin{cases}x_1, & x<0\\ x_2, & x\geq 0\end{cases} \tag{8.1}$$

因为我们用 1bit 的码来表示 X，我们实际上无法完全编码 X，只能编码 X 的一个近似表示 $\hat{X}$。当然我们也可以不以 0 为表示区间的切分点，只不过在这个例子中，显然从 0 来切分更为准确。现在所能做的事情是，如何选取 x_1 和 x_2 使得这种编码表示最准确。这里 $\hat{X}$ 的取值集合 $\{x_1,x_2\}$ 称为再生点(reproduction point) 或者码点（code point）。

假设我们用平方误差 $d(x,\hat{x})=(x-\hat{x})^2$ 来度量“真实随机变量取值

为 x 但只能用再生点 $\hat{x}$ 来表示”的时候这之间的距离，用平方误差的期望 $E[d(X,\hat{X})]$ 来度量失真度。要使得在给定编码长度为 1bit 的时候，失真度最小，那么再生点的选取要

$$\arg\min_{x_1,x_2} E[d(X,\hat{X})] \tag{8.2}$$

$$= \arg\min_{x_1,x_2} \int_{-\infty}^{0} f(x)(x-x_1)^2 dx + \int_{0}^{\infty} f(x)(x-x_2)^2 dx \tag{8.3}$$

其中，$f(x)$ 是 X 的概率密度函数，即正态分布的概率密度函数。只需要分别找到 x_1 和 x_2，而且由于前后两个部分是对称的，我们以 x_1 为例，

$$\arg\min_{x_1} \int_{-\infty}^{0} f(x)(x-x_1)^2 dx = \arg\min_{x_1} \sqrt{\frac{2}{\pi}}\sigma x_1 + \frac{1}{2}x_1^2 = -\sqrt{\frac{2}{\pi}}\sigma \tag{8.4}$$

所以最优的再生点为

$$\hat{X}(x) = \begin{cases} -\sqrt{\frac{2}{\pi}}\sigma, & x < 0 \\ \sqrt{\frac{2}{\pi}}\sigma, & x \geq 0 \end{cases} \tag{8.5}$$

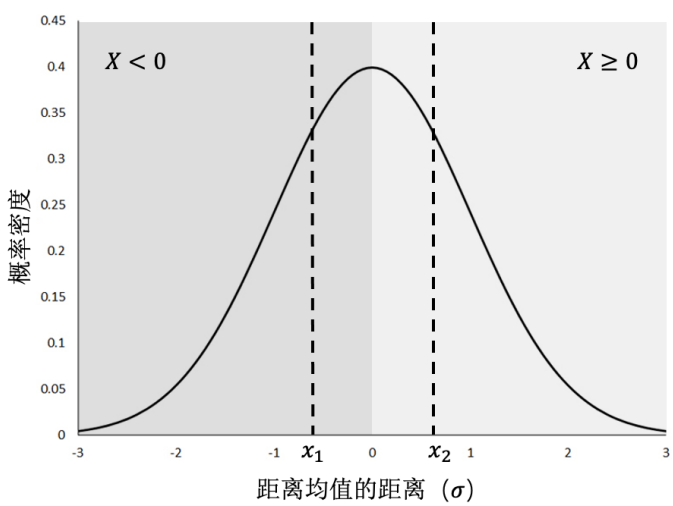

图 8.1: 高斯随机变量的 1bit 有损压缩

当可以用更长的码来编码高斯分布，就会更复杂一些，区间的分割与最优再生点的定位会变得更为复杂，这时可以通过“分割区间-定位再生点”的迭代优化的方式来完成。然而，如果要编码一组独立同分布的高斯分布，将

整个随机变量序列一起编码将比对每个随机变量独立编码，可以达到更低的失真，这将是本章的重要结论之一。

8.1 压缩问题

定义 8.1. 压缩问题包括有损压缩与无损压缩）由以下部分构成：

1. 信源序列：$X^m = (X_1, X_2, \ldots, X_m)$，
   $X_1, X_2, \ldots, X_m$ *i.i.d.* $\sim X$，$X \in \mathcal{X}$。
2. 编码器：$f : \mathcal{X}^m \to \{0,1\}^n$，
   将 m 个 *i.i.d.* 信源 X^m 映射到 n *bits* 的码。
3. 解码器：$g : \{0,1\}^n \to \hat{\mathcal{X}}^m$，
   将 n *bits* 的码映射到重新构造的（再生的）表示 $\hat{X}^m$ 上，
   $\hat{X}^m = (\hat{X}_1, \hat{X}_2, \ldots, \hat{X}_m)$，$\hat{X}_1, \hat{X}_2, \ldots, \hat{X}_m$ *i.i.d.* $\sim \hat{X}$，$\hat{X} \in \hat{\mathcal{X}}$。
4. 码率：$R = n/m$，平均每个信源使用的编码长度

并用 (m, n, f, g) 来表示一个压缩。

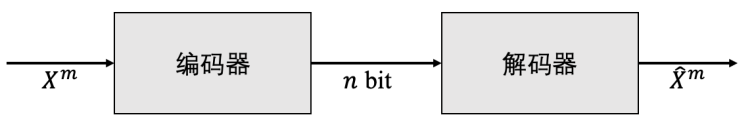

图 8.2: 压缩问题

8.2 率失真函数（rate distortion function）

定义 8.2. 失真函数（*distortion function*）是从信源字母表 $\mathcal{X}$ 与再生字母表 $\hat{\mathcal{X}}$ 的乘积空间到非负实数集上的映射 $d : \mathcal{X} \times \hat{\mathcal{X}} \to \mathbb{R}^+$

就像上面例子中的平方误差那样，失真函数 $d(x, \hat{x})$ 是用来刻画使用 $\hat{x}$ 表示 x 时的代价度量。常见的失真函数有

- 平方误差失真：

$$d(x, \hat{x}) = (x - \hat{x})^2 \tag{8.6}$$

平方误差失真是连续字母表（连续随机变量）最常用的失真度量。因为其较为简单，与最小二乘法联系紧密，很多性质已经被分析得较为清晰，所以较为常用。

- 汉明（误差概率）失真：

$$d(x,\hat{x}) = \begin{cases} 0, & x = \hat{x} \\ 1, & x \neq \hat{x} \end{cases} \tag{8.7}$$

当我们像之前的例子那样考虑 $E[d(X,\hat{X})]$，会发现如果选用汉明失真 $E[d(X,\hat{X})] = Pr(X \neq \hat{X})$，因此又叫做误差概率失真。

定义 8.3. x^m 与 $\hat{x}^m$ 序列间的失真是序列中每个分量失真的平均，即

$$d(x^m,\hat{x}^m) = \frac{1}{m}\sum_{i=1}^{m} d(x_i,\hat{x}_i) \tag{8.8}$$

定义 8.4. 随机变量 X^m 与 $\hat{X}^m$ 间的失真（*distortion*）定义为

$$D \equiv E[d(X^m, g(f(X^m)))] = \sum_{x^n \in \mathcal{X}^n} p(x^n) d(x^m, g(f(x^m))) \tag{8.9}$$

不难发现，压缩问题的码率与失真直接存在一个权衡，即如果提高码率，会导致编码长度降低，进而导致失真增大；而降低失真，需要编码长度增加，导致码率的降低。一般地，我们希望保持一定失真的条件下，使得码率尽量的高。

定义 8.5. 称率失真对（*rate/distortion pair*）(R,D) 是**可达（*achievable*）**的，若 $\forall \epsilon > 0$，$\exists (m,n,f,g)$ 使得

$$\frac{n}{m} \leq R + \epsilon \tag{8.10}$$

$$E[d(X^m, g(f(X^m)))] \leq D + \epsilon \tag{8.11}$$

上述定义中 $R+\epsilon$ 和 $D+\epsilon$ 是指，当 $m \to \infty$ 时，$\frac{n}{m}$ 和 $E[d(X^m, g(f(X^m)))]$ 可以从右侧收敛到 R 和 D。

定义 8.6. 率失真函数（*rate-distortion function*）是对于给定的失真 D，所有可达的率失真对 (R,D) 中码率 R 的下确界

$$R(D) \equiv \inf\{R' : (R',D) \ \textit{is achievable}\} \tag{8.12}$$

率失真函数表示在给定失真时，可以达到的最好的码率。和信道容量类似，我们要定义一个与互信息相关的码率，称为信息率失真函数。

定义 8.7. 信息率失真函数（*information rate-distortion function*）定义为

$$R^{(I)}(D) \equiv \min_{E[d(X,\hat{X})]\leq D} I(X,\hat{X}) \tag{8.13}$$

与信道容量相似，率失真理论的主要定理

定理 8.8. 对于独立同分布的信源 X，若其失真函数 $d(x,\hat{x})$ 有界，（即 $\max_{x\in\mathcal{X},\hat{x}\in\hat{\mathcal{X}}} d(x,\hat{(x)}) < \infty$），那么其率失真函数与对应的信息率失真函数有

$$R(D) = R^{(I)}(D) \tag{8.14}$$

8.3 率失真函数计算的例子

定理 8.8 给出了在理论上找到率失真函数的方法，即通过计算信息率失真函数。我们假设定理 8.8 成立，在之后的章节中再来证明。

定理 8.9. 信源 $X \sim Bern(p)$ 在汉明失真函数下，率失真函数为

$$R(D) = \begin{cases} h_2(p) - h_2(D), & 0 \leq D \leq \min\{p, 1-p\} \\ 0, & D > \min\{p, 1-p\} \end{cases} \tag{8.15}$$

证明. 由于是二元 Bernoulli 分布，那不妨假设 $p < \frac{1}{2}$，因为对于 $p \geq \frac{1}{2}$ 的时候，相当于信源取值对调了一下。这样式 8.16 可简化为

$$R(D) = \begin{cases} h_2(p) - h_2(D), & 0 \leq D \leq p \\ 0, & D > p \end{cases} \tag{8.16}$$

对于 $D > p$ 的情形，我们可以构造一个 0 bit 的解码，即无论 X 如何取值，$\hat{X}$ 等于概率比较大的 X 的取值。因为 $\hat{X}$ 是固定的，所以完全不需要编码，即编码为 0 bit。又因为刚假设 $p < 1/2$，所以 $\hat{X}$ 取概率为 $1-p$ 的 X 的取值。此时失真为

$$D = E[d(X,\hat{X})] = p \times 1 = p \tag{8.17}$$

因此，当需要失真大于 p 时，只需要 0 bit 的编码就能达到。

对于 $D \le p$ 的情形，由定理 8.8 ，有

$$R(D) = \min_{E[d(X,\hat{X})] \le D} I(X, \hat{X}) \tag{8.18}$$

但直接优化 $I(X, \hat{X})$ 比较困难，我们先给出 $I(X, \hat{X})$ 的一个下界，然后证明这个下界是可达的。用 $\oplus$ 表示模 2 加法运算，即

$$0 \oplus 0 = 0,\ 0 \oplus 1 = 1,\ 1 \oplus 0 = 1,\ 1 \oplus 1 = 0 \tag{8.19}$$

不难发现 $\oplus$ 也等价于计算机中二进制的“异或”（xor）操作，即如果两个值相同，结果为 0；如果两个值不同，结果为 1。所以有 $X \oplus \hat{X} = (X \ne \hat{X})$。

$$\begin{aligned}
I(X; \hat{X}) &= H(X) - H(X|\hat{X}) \\
&= H(X) - H(X \oplus \hat{X}|\hat{X}) \\
\text{条件使熵减少} &\ge h_2(p) - H(X \oplus \hat{X}) \\
&= h_2(p) - H(X \ne \hat{X}) \\
&= h_2(p) - h_2(Pr(X \ne \hat{X}))
\end{aligned} \tag{8.20}$$

取等条件为 $X \oplus \hat{X}$ 与 $\hat{X}$ 独立。对于汉明失真函数，对于一个可达的失真 D，有

$$D \ge E[d(X, \hat{X})] = Pr(X \ne \hat{X}) \tag{8.21}$$

于是

$$\begin{aligned}
I(X; \hat{X}) &\ge h_2(p) - h_2(Pr(X \ne \hat{X})) \\
h_2\text{在}D \le 1/2\text{时单调递增} &\ge h_2(p) - h_2(D)
\end{aligned} \tag{8.22}$$

取等条件为 $D = Pr(X \ne \hat{X})$。因此，率失真函数的下界为

$$R(D) \ge h_2(p) - h_2(D) \tag{8.23}$$

接下来我们证明这个下界是可以达到的。为了达到这个下界，需要两个不等式都取等，即 $X \oplus \hat{X}$ 与 $\hat{X}$ 独立，同时 $D = Pr(X \ne \hat{X})$。其中，$D = Pr(X \ne \hat{X})$ 等价于 $X \oplus \hat{X} \sim Bern(D)$。假设 $\hat{X} \sim Bern(q)$，有

$$p = Pr(X = 1) \tag{8.24}$$

$$= Pr(\hat{X} = 0, X \oplus \hat{X} = 1) + Pr(\hat{X} = 1, X \oplus \hat{X} = 0) \tag{8.25}$$

$$= Pr(\hat{X} = 0)Pr(X \oplus \hat{X} = 1) + Pr(\hat{X} = 1)Pr(X \oplus \hat{X} = 0) \tag{8.26}$$

$$= (1 - q)D + q(1 - D) \tag{8.27}$$

可以得到

$$q = \frac{p - D}{1 - 2D} \tag{8.28}$$

因此，当 $\hat{X} \sim Bern(\frac{p-D}{1-2D})$，$X \oplus \hat{X} \sim Bern(D)$ 时，

$$R(D) = I(X; \hat{X}) = h_2(p) - h_2(D) \tag{8.29}$$

□

图 8.3 画出了 Bernoulli(1/2) 信源的率失真函数，可以看到当要求 $D = 0$ 时，即无损压缩时，需要 1 bit 的编码；当要求 $D \geq 1/2$ 时，需要 0 bit 的编码。Bernoulli(1/2) 信源的率失真函数是单调函数，同时是凸函数。

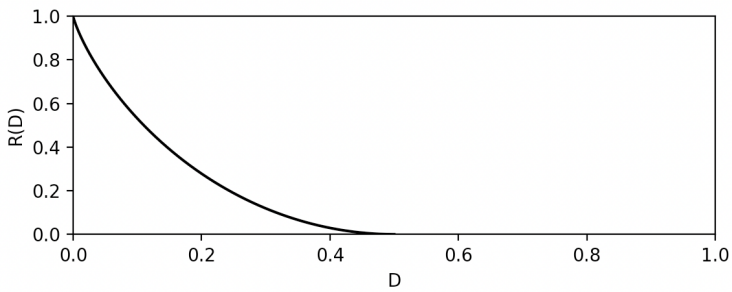

图 8.3: Bernoulli(1/2) 信源的率失真函数

9 型方法（type）

定义 9.1. 序列 $x_1, x_2, \ldots, x_n$（以下记做 x^n）的<u>型</u>P_{x^n}（或经验概率分布）是 $\mathcal{X}$ 中每个字符在该序列中出现次数的相对比例（对任意的 $a \in \mathcal{X}$，$P_{x^n}(a) = \frac{N(a|x^n)}{n}$，其中 $N(a|x^n)$ 表示字符 a 在序列 x^n 中出现的次数）。

定义 9.2. $\mathcal{P}_n$ 为长度为 n 的所有型构成的集合。

例如，若 $\mathcal{X} = \{0, 1\}$，那么长度为 n 的所有型构成的集合为

$$\mathcal{P}_n = \{(P(0), P(1)) : (\frac{0}{n}, \frac{n}{n}), (\frac{1}{n}, \frac{n-1}{n}), \ldots, (\frac{n}{n}, \frac{0}{n})\} \tag{9.1}$$

定义 9.3. 若 $P \in \mathcal{P}_n$，长度为 n 且型为 P 的序列全体称为 P 的<u>型类（*type class*）</u>，记为 $T(P)$，

$$T(P) = \{x^n \in \mathcal{X}^n : P_{x^n} = P\} \tag{9.2}$$

例如，若 $\mathcal{X} = \{1, 2, 3\}$，$x^5 = 11321$，则型 P_x 为 $P_{x^5}(1) = \frac{3}{5}$，$P_{x^5}(2) = \frac{1}{5}$，$P_{x^5}(3) = \frac{1}{5}$。P_{x^5} 的型类是长度是 5，含有 3 个 1，1 个 2 和 1 个 3 的所有序列，即

$$T(P_{x^5}) = 11123, 11132, 11213, \ldots, 32111 \tag{9.3}$$

$T(P_{x^5})$ 中元素的个数为

$$|T(P_{x^5})| = C_5^3 C_2^1 = \frac{5!}{3!2!} * \frac{2!}{1!1!} = \frac{5!}{3!1!1!} = 20 \tag{9.4}$$

定理 9.4.

$$|\mathcal{P}_n| \leq (n+1)^{|\mathcal{X}|} \tag{9.5}$$

证明. P 的每一个分量至多有 $n+1$ 个取值可能，即 $\frac{0}{n}, \frac{1}{n}, \ldots, \frac{n}{n}$，一共有 $|\mathcal{X}|$ 个分量。 □

定理 9.5. 若 X^n 为 *i.i.d.* 且 $X_i \sim Q(x)$，则 x^n 的概率仅依赖于它的型，且有等式

$$Q^n(x^n) = 2^{-n(H(P_{x^n}) + D(P_{x^n}||Q))} \tag{9.6}$$

证明.

$$
\begin{aligned}
Q^n(x^n) &= \prod_{i=1}^{n} Q(x_i) \\
&= \prod_{a\in\mathcal{X}} Q(a)^{N(a|x^n)} \\
&= \prod_{a\in\mathcal{X}} Q(a)^{nP_{x^n}(a)} \\
&= \prod_{a\in\mathcal{X}} 2^{nP_{x^n}(a)\log Q(a)} \\
&= \prod_{a\in\mathcal{X}} 2^{n(P_{x^n}(a)\log Q(a) - P_{x^n}(a)\log Px^n(a) + P_{x^n}(a)\log Px^n(a))} \\
&= \prod_{a\in\mathcal{X}} 2^{n(-P_{x^n}(a)\log\frac{P_{x^n}(a)}{Q(a)} + P_{x^n}(a)\log Px^n(a))} \\
&= 2^{n\sum_{a\in\mathcal{X}}(-P_{x^n}(a)\log\frac{P_{x^n}(a)}{Q(a)} + P_{x^n}(a)\log Px^n(a))} \\
&= 2^{-n(H(P_{x^n}) + D(P_{x^n}||Q))} \qquad (9.7)
\end{aligned}
$$

□

推论 9.6. 若 x^n 在 Q 的型类中，则

$$
Q(x^n) = 2^{-nH(Q)} \qquad (9.8)
$$

10 上机实验

10.1 熵、相对熵、联合熵、互信息的 Python 实现

通过本次上机作业，你应该熟悉 Python 和 Python 中函数的使用，同时掌握熵的基本编程方法。

10.1.1 上机作业

首先加载必要的 Python 程序包，包括 *numpy*、*math* 和 *scipy*，*numpy* 是 Python 中最常用的矩阵运算包，*math* 中包含了基本的数学运算程序，*scipy* 是科学运算包，里面含有很多实用且复杂的算法。

```
import numpy as np
import math
import scipy
```

因为熵中标准的对数是以 2 为底的对数，为了方便之后运算，在这里我定义了一个函数 *log*，它执行的是以 2 为底的对数，在下面的程序编写中，可直接调用 *log* 函数。

```
def log(x):
    return math.log(x, 2)
```

第一个需要实现的函数是熵，由于熵只和随机变量的分布有关，这里函数 $entropy(px)$ 的输入只有随机变量 X 的分布 px，px 是一个 list，其中元素是 X 每个取值的概率。函数 $entropy(px)$ 需要返回随机变量 X 的熵。

```
def entropy(px):
    ## YOUR IMPLEMENTATION HERE ##
    # return the entropy of the random variable 'x' with
    probability distribution 'px'
    return -1
```

第二个实现的函数是相对熵，也就是 KL 散度。相对熵是衡量两个分布间距离的量，在这里我们计算的是随机变量 X 的真实分布为 px，但假设其分布为 qx，这两个分布间的距离。

```
def relative_entropy(px, qx):
    ## YOUR IMPLEMENTATION HERE ##
    # return the relative entropy of the random variable 'x'
    with probability distribution 'px' and 'qx'
```

```
    return -1
```

对于随机变量 X 和 Y 的联合熵，函数 $joint_entropy(pxy)$ 的输入 pxy 为 X 和 Y 的联合概率分布函数。pxy 是一个二维 list，每行代表 X 的每个取值，每列代表 Y 的每个取值，里面的元素代表对应取值的概率（当然 pxy 中所有元素的和是 1）。

```
def joint_entropy(pxy):
    ## YOUR IMPLEMENTATION HERE ##
    # return the joint entropy of the random variable 'x' and 'y' with joint p.d. 'pxy'
    return -1
```

互信息计算的是随机变量 X 和 Y 的联合概率分布函数为 pxy，但假设其为 $pxpy$，即假设其独立，的信息损失。

```
def mutual_infomation(px, py, pxy):
    ## YOUR IMPLEMENTATION HERE ##
    # return the mutual information of I(x;y)
    return -1
```

以下是测试环节，不需要做任何改动。这里首先给出了测试用的概率密度分布。随机变量 X 的分布 px 和另一个分布 qx，随机变量 Y 的分布 qy，联合分布 qxy，均匀分布 u。

```
px = [1/2, 1/2,  0]
qx = [5/36, 1/3, 19/36]
qy = [7/18, 11/18]
qxy = [[1/18, 1/12], [1/18, 5/18], [5/18, 1/4]]
u = [1/3, 1/3, 1/3]
```

这里是一个简单的例子展示了如何使用我写的 $log(px)$ 函数。

```
print("An example of how to use the log function:")
print("The logarithmic of px[0] is %.3f" %log(px[0]))
```

第一个测试计算了随机变量 X 和 Y 在不同分布下的熵。

```
# Test 1:
print("Test 1:")
print("The entropy of x with p.d. px is %.3f" % entropy(px))
print("The entropy of x with p.d. qx is %.3f" % entropy(qx))
print("The entropy of x with p.d. qy is %.3f" % entropy(qy))
```

第二个测试计算了分布 px 和 qx 直接的 KL-散度。第三个测试和第四个测试分别计算了联合熵和互信息。

```
# Test 2:
print("Test 2:")
print("The relative entropy of x with p.d. px and qx is %.3f" %
    relative_entropy(px, qx))

# Test 3:
print("Test 3:")
print("The joint entropy of x, y with p.d. qxy is %.3f" %
    joint_entropy(qxy))

# Test 4:
print("Test 4:")
print("The mutual information of x, y with p.d. qxy is %.3f" %
    mutual_infomation(qx, qy, qxy))
```

第五个测试是 $D(px||u) = H(u) - H(px)$，$H(u) = \log(|u|) = \log(|px|)$。

```
# Test 5:
print("Test 5:")
print(relative_entropy(px, u) - log(len(px)) + entropy(px), "
    should be zero")
```

第六个测试是 $H(X,Y) \leq H(X) + H(Y)$，当且仅的 X 与 Y 独立时取等。

```
# Test 6:
print("Test 6:")
print(joint_entropy(qxy) - entropy(qy) - entropy(qx), "should
    be negative")
```

第七个测试是 $I(X,Y) = H(X) + H(Y) - H(X,Y)$，(可能会有计算机舍入误差)。

```
# Test 7:
print("Test 7:")
print(mutual_infomation(qx, qy, qxy) + joint_entropy(qxy) -
    entropy(qx) - entropy(qy), "should be zero")
```

10.2 决策树-特征选择

通过本次上机作业，你应该熟悉互信息的相关理论与应用，掌握决策树是如何使用互信息来选择依据哪个特征来分叉的。

10.2.1 决策树简介

数学学院的小冉同学为了准备即将进行的经管杯羽毛球大赛，准备近一个月的时间去练习打球。不过，他并不是每一天都去练球。通常，有很多因素决定了他是否会来打羽毛球，比如：是否有课、是否有考试、是否有场地、是否有伤、是不是有练球的心情等等。数学学院的小杨有时会去球场找小冉，不过他并不会直接联系小冉问他是否去球场，而是综合已知的信息，猜一下小冉会不会去，如果小冉去，小杨再去球场偶遇小冉。实际上，上述的问题对于小杨来说，是一个典型的智能决策问题。首先，它有一些输入的特征，比如是否有课、是否有考试等等；小杨通过某种特定的算法，对这一系列的特征进行综合判断，从而得出今天是否应该去球场偶遇小冉的决策。可以看到，对一个智能决策系统，它有三个重要的组成部分，即特征、算法、决策。

小杨细心的收集了小冉过去一年是否去打羽毛球与是否有课、是否有考试、是否有场地、是否有伤、是不是有练球的心情等等特征的所有信息。小杨通过这些数据，进行决策。在这个问题中，决策的内容实际上是将结果分成两类，即小冉是（1）否（0）去练球，这一类智能决策问题称为分类问题。决策树是一种简单的处理分类问题的算法。

决策树的本质是由多个判断节点组成的树形函数，以一个样本的特征向量 $X = [X_1, X_2, X_3, \ldots, X_d]$ 作为输入，返回一个“决策”，例如判断具有该特征的样本属于哪个类别。简单地说，我们从一个“树根“节点开始，每次生出几个分叉节点（称为子节点），再将子节点当成新的根节点，继续往下生出新的子节点，如此重复，直到满足某些停止条件停止决策树的生长。当一棵决策树建立完毕后，我们称最下面的节点（无子节点）为叶节点。其他的节点成为非叶节点。每个非叶节点与一个特征属性相关联，根据此特征属性的值的不同，进行子节点的分叉操作。

10.2.2 经验熵

假设对随机变量 Y 独立同分布采样 N 次，得到数据集 D。在 D 中，Y 有 K 个不同的取值，每个取值的集合记为 D_k，$k=1,\ldots,K$。记 $|D|$ 为 D 中元素的个数，即 $|D|=N$。同理，记 $|D_k|$ 为集合 D_k 中元素的个数。那么随机变量 Y 在样本集 D 下的经验熵 为

$$H(Y)=-\sum_{k=1}^{K}\frac{|D_k|}{|D|}\log_2\frac{|D_k|}{|D|} \tag{10.1}$$

相当于，Y 的第 k 个取值的概率 $p(y_k)=\frac{|D_k|}{|D|}$。

10.2.3 经验条件熵

假设有随机变量 X 和 Y，对他们进行独立同分布采样 N 次，得到数据集 $D=\{(x_1,y_1),\ldots,(x_N,y_N)\}$，$X$ 和 Y 的每个取值对的集合记为 D_{ik}，$i=1,\ldots,I$，$k=1,\ldots,K$。那么随机变量 X 对 Y 在样本集 D 下的经验条件熵 为

$$H(Y|X)=-\sum_{i=1}^{I}\frac{|D_i|}{|D|}\sum_{k=1}^{K}\frac{|D_{ik}|}{|D_i|}\log_2\frac{|D_{ik}|}{|D_i|} \tag{10.2}$$

其中，D_i 为 D_{ik} 在所有 k 下的并集。相当于，$p(y_k|x_i)=\frac{|D_{ik}|}{|D_i|}$。

10.2.4 决策树中的经验条件熵

在决策树中，我们希望使用一个指标（也叫特征）去进行判断（分叉），当我们选择的那个特征，可以最大限度的降低判断的不确定性，这个特征就是最优的选择。假设我们想要判断的输出是随机变量 Y，我们使用的特征是 X，那不确定性的减少量是 $H(Y)-H(Y|X)$，也就是互信息 $I(X;Y)$。

假设现在需要通过年龄 age、性别 $male$、单身情况 $single$ 三个特征来判断一名同学周日会不会去图书馆 $visit_library_in_Sunday$。数据如表2所示。以我们的数据集为例，首先计算输出 Y 的经验熵，即 $visit_library_in_Sunday$ 的经验熵。在数据集中，一共 15 个样本，$visit_library_in_Sunday=True$ 的样本有 9 个。

$$H(Y)=-\frac{9}{15}\log_2\frac{9}{15}-\frac{6}{15}\log_2\frac{6}{15}=0.971 \tag{10.3}$$

表 2: 决策树数据

	X			Y
index	age	male	single	visit_library_in_Sunday
1	19	False	False	False
2	19	False	False	False
3	19	True	False	True
4	19	True	True	True
5	19	False	False	False
6	20	False	False	False
7	20	True	True	True
8	20	False	True	True
9	20	False	True	True
10	21	False	True	True
11	21	False	True	True
12	21	True	False	True
13	21	True	False	True
14	21	False	False	False

然后计算特征 X_1：*age* 的对输出的条件经验熵，

$$H(Y|X_1) = -\frac{1}{3} * \frac{2}{5}\log_2\frac{2}{5} - \frac{1}{3} * \frac{3}{5}\log_2\frac{3}{5} \tag{10.4}$$

$$-\frac{1}{3} * \frac{3}{5}\log_2\frac{3}{5} - \frac{1}{3} * \frac{2}{5}\log_2\frac{2}{5} \tag{10.5}$$

$$-\frac{1}{3} * \frac{4}{5}\log_2\frac{4}{5} - \frac{1}{3} * \frac{1}{5}\log_2\frac{1}{5} \tag{10.6}$$

$$=0.888 \tag{10.7}$$

不确定性的减少量是 $H(Y) - H(Y|X_1) = 0.971 - 0.888 = 0.083$

同理，我们可以计算得到 X_2：*male* 和 X_3：*single* 的条件经验熵与不

确定性减少量

$$H(Y)-H(Y|X_2)=0.971-\frac{5}{15}*\frac{5}{5}\log_2\frac{5}{5}-\frac{5}{15}*\frac{0}{5}\log_2\frac{0}{5} \tag{10.8}$$

$$-\frac{10}{15}*\frac{4}{10}\log_2\frac{4}{10}-\frac{10}{15}*\frac{6}{10}\log_2\frac{6}{10} \tag{10.9}$$

$$=0.324 \tag{10.10}$$

$$H(Y)-H(Y|X_3)=0.971-\frac{6}{15}*\frac{6}{6}\log_2\frac{6}{6}-\frac{6}{15}*\frac{0}{6}\log_2\frac{0}{6} \tag{10.11}$$

$$-\frac{9}{15}*\frac{3}{9}\log_2\frac{3}{9}-\frac{9}{15}*\frac{3}{9}\log_2\frac{3}{9} \tag{10.12}$$

$$=0.420 \tag{10.13}$$

因此，我们选用 *single* 来判断 *visit_library_in_Sunday* 时，不确定性减少的最多，准确率也最高。

10.2.5 上机作业

为了使决策树程序更具有复用性（方便在不同的场景中多次重复使用），我创建了一个名为 $decision_tree$ 的 class。这个 *class* 的初始化设置由 $__init__$ 函数来控制。每次在创建 $decision_tree$ 时，$__init__$ 函数都会自动先执行一遍，完成对 class 的初始化。在这里，*decision_tree* 这个 class 初始化的时候需要 3 个输入参数，分别是 *features*、*output* 和 *dataset*。*features* 是一个 list，里面每个元素是使用的特征的名字。*output* 是一个字符串，是输出变量的名字。*dataset* 是数据集。

```
import numpy as np

class decision_tree:
    def __init__(self, features, output, dataset):
        self.features = features
        self.output = output
        self.dataset = dataset
```

在本次上机中提供了三个基础函数，第一个是计算 log_2 的；第二个是计算经验概率分布的，函数的输入是一个数列，可以是 list，也可以是 np.array；第三个是计算熵的，输入也是一个数列，与第一次上机中的熵函数一样。

```
    def log(self, x):
        return np.log2(x)

    # you can use this function to calculate the empirical probability of a random variable under a dataset
    def get_prob(self, array):
        (unique, counts) = np.unique(array, return_counts=True)
        return counts/len(array)

    # you can use this function to calculate the empirical entropy of a random variable under a dataset
    def entropy(self, array):
        p = self.get_prob(array)
        return -np.sum(p*np.log2(p))
```

首先要实现的两个函数是输出的经验熵 $H(Y)$，它的输入都包含在变量 $self$ 里面。

```
    def output_entropy(self):
        ## YOUR IMPLEMENTATION HERE ##
        # calculate the empirical entropy of the output
        return -1
```

接下来要实现的是输出对任意输入特征 $feature$ 的条件经验熵 $H(Y|X_d)$。

```
    def conditional_entropy(self, feature):
        ## YOUR IMPLEMENTATION HERE ##
        # calculate the empirical conditional entropy of the output relative to the "feature"
        return -1
```

最终需要找出使得不确定性减少最多的特征，作为决策树的分类依据（分叉节点），也就是互信息最大的特征。函数 $feature_selection$ 返回互信息最大的特征的名字。

```
    def feature_selection(self):
        ## YOUR IMPLEMENTATION HERE ##
        # select the feature has maximum mutual information
        return "a"
```

以下是测试代码，首先给出数据集。

```
dataset = [
```

```
    {"age": 19, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 19, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 19, "male": True,  "single": False, "visit_library_in_Sunday": True},
    {"age": 19, "male": True,  "single": True,  "visit_library_in_Sunday": True},
    {"age": 19, "male": False, "single": False, "visit_library_in_Sunday": False},

    {"age": 20, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 20, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 20, "male": True,  "single": True,  "visit_library_in_Sunday": True},
    {"age": 20, "male": False, "single": True,  "visit_library_in_Sunday": True},
    {"age": 20, "male": False, "single": True,  "visit_library_in_Sunday": True},

    {"age": 21, "male": False, "single": True,  "visit_library_in_Sunday": True},
    {"age": 21, "male": False, "single": True,  "visit_library_in_Sunday": True},
    {"age": 21, "male": True,  "single": False, "visit_library_in_Sunday": True},
    {"age": 21, "male": True,  "single": False, "visit_library_in_Sunday": True},
    {"age": 21, "male": False, "single": False, "visit_library_in_Sunday": False}
]
```

然后创建一个 *decision_tree* 的 class，叫做 *my_tree*。

```
my_tree = decision_tree(\
    ["age", "male", "single"], "visit_library_in_Sunday", dataset)
```

三个测试分别测试输出的经验熵、对特征 age 的经验条件熵和最终的特征选择的结果。

```
# Test 1:
print(my_tree.output_entropy(), "should be around 0.971")

# Test 2:
print(my_tree.conditional_entropy("age"), "should be around
    0.888")

# Test 3:
print(my_tree.feature_selection(), "should be single")
```

10.3 决策树-训练与预测

10.3.1 决策树的构建

在机器学习中，最常见的一类问题是分类问题，就是通过观察数据的特点（特征），构造一个函数，将数据分为特定的类别。比如说其中一个最直观的应用“图像分类”，就是通过观察图像中每个像素的值，来分类图像（图像中是猫还是狗）。在我们这次上机作业中，我们需要通过观察学生的“年龄”、“性别”和“单身情况”，来判断学生是否“周日会去图书馆”。

在上次上机作业中，我们发现，当选择那个让熵减少最多的特征用于分类时，分类得最准确。即选取“单身情况”作为分类依据，可以达到 80% 的准确率。这时，我们的分类函数为，“如果学生单身，则判断周末会去图书馆，如果不单身则判断周末不去图书馆”。

在本次上机作业中，我们将建立一个决策树算法，综合考虑所有特征，建立复杂的分类函数。决策树是机器学习中应用最广泛的非线性分类器，在很多实际问题中基于决策树的算法都是当前效果最好的算法，例如 XGBOOST 等，很多时候会优于深度学习算法。

决策树是一个树状的决策器（分类器），比如我们上机作业的例子中，决策器的分类方法是：先看学生是否单身，如果单身，再看学生性别，如果是男，再看年龄，如果 19 岁则判断周末会去图书馆。如下图

本次上机作业需要构造一个可以自动适应任意类似的数据的决策树。构造决策树需要以下的步骤：

1. 像上次作业一样，找出使熵下降最多的特征，下称“最优特征”。

2. 对最优特征的每一个取值可能，在剩下的特征中找到“最优特征”。
3. 以此递归。
4. 如果只剩一个特征，那么就不再需要找最优特征了，这时，对该特征的每个取值对应的决策器的输出，是该取值下最多的那一类。

我们从一个具体例子开始，1. 像上次上机一样，选择“single”作为最优特征。
2. ”single” 特征有两个取值“True”和“False”,我们先看“True”。在”single=True”的这一支，只剩下
{”age”: 19, ”male”: True, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 20, ”male”: True, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 20, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 20, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 21, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 21, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
这些可能，此时我们来到决策树的第二层，在这些数据里选择“最优特征”，作为这一层的节点。例如，通过计算，我们发现“male”是此子数据集下的最优特征，那么第二层的节点就是“male”。3. 然后我们考虑”male” 的所有取值。“male” 有两个取值“True” 和“False” 我们先看“False”。在”male=False”的这一支，只剩下
{”age”: 20, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 20, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 21, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
{”age”: 21, ”male”: False, ”single”: True, ”visit_library_in_Sunday”: True},
这些数据，此时我们来到决策树的第三层，这时只有一个特征了，就是“age”，那”age”作为这一层的节点。4. 此时”age”有两种可能“20”和

“20”，当”age=20” 时，”visit_library_in_Sunday” 最多的取值是 True（因为 True 有 2 个，False 有 0 个）。5. 然后我们依次计算剩下的所有的取值可能，最终构建出整个决策树。

上机作业中需要完成的”predict” 函数，需要对任意给定的一行数据，给出学生是否周日会去图书馆的判断。**注意，该决策树不应只针对这一个数据集，换成另一个完全不同的数据集也应该可以使用**。例如，下面这种判断是否生病的例子
{”height”: 170, ”weight”: 60, ”age”: 20, ”exercise”: True, ”eat_breakfast”: True, ”disease”: False},

10.3.2 上机作业

```python
import numpy as np

# You can modify the code as what you want

class decision_tree:
    def __init__(self, features, output, dataset):
        self.features = features
        self.output = output
        self.dataset = dataset

    def log(self, x):
        return np.log2(x)

    # you can use this function to calculate the emprical probability of a random variable under a dataset
    def get_prob(self, array):
        (unique, counts) = np.unique(array, return_counts=True, axis=0)
        return counts/len(array)

    # you can use this function to calculate the emprical entropy of a random variable under a dataset
    def entropy(self, array):
        p = self.get_prob(array)
        return -np.sum(p*np.log2(p))

```

```
    def output_entropy(self):
        # calculate the emprical entropy of the output
        # you can use your code in the last assignment
        return

    def conditional_entropy(self, feature):
        # calculate the emprical conditional entropy of the output relative to the "feature"
        # you can use your code in the last assignment
        return

    def feature_selection(self):
        # select the feature has maximum mutual information
        # you can use your code in the last assignment
        return

    def predict(self, data):
        # make prediction for an arbitrary data input
        return

dataset = [
    {"age": 19, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 19, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 19, "male": True,  "single": False, "visit_library_in_Sunday": True},
    {"age": 19, "male": True,  "single": True,  "visit_library_in_Sunday": True},
    {"age": 19, "male": False, "single": False, "visit_library_in_Sunday": False},

    {"age": 20, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 20, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 20, "male": True,  "single": True,  "visit_library_in_Sunday": True},
```

```
    {"age": 20, "male": False, "single": True,  "visit_library_in_Sunday": True},
    {"age": 20, "male": False, "single": True,  "visit_library_in_Sunday": True},

    {"age": 21, "male": False, "single": True,  "visit_library_in_Sunday": True},
    {"age": 21, "male": False, "single": True,  "visit_library_in_Sunday": True},
    {"age": 21, "male": True,  "single": False, "visit_library_in_Sunday": True},
    {"age": 21, "male": True,  "single": False, "visit_library_in_Sunday": True},
    {"age": 21, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 21, "male": False, "single": False, "visit_library_in_Sunday": False},
    {"age": 21, "male": False, "single": False, "visit_library_in_Sunday": True}
]

my_tree = decision_tree(\
    ["age", "male", "single"], "visit_library_in_Sunday", dataset)


# Test 1
print(my_tree.predict({"age": 19, "male": False, "single": False}), "should be 0 or False")

# Test 2
# use the feature "single" to classify as last time
def tree_example(data):
    if data["single"]:
        return True
    else:
        return False

true_classification = 0
```

```python

for data in dataset:
    if tree_example(data) == data["visit_library_in_Sunday"]:
        true_classification += 1

print("One feature classification accuracy:", true_classification/len(dataset))

# use a decision tree to classify
true_classification = 0

for data in dataset:
    if my_tree.predict(data) == data["visit_library_in_Sunday"]:
        true_classification += 1

print("Decision tree classification accuracy:", true_classification/len(dataset), "should be around 0.9412")
```

10.4 JPEG 图片压缩